




FACULTAD
DE CIENCIAS
ECONÓMICAS

Econometría I

Segundo semestre 2024

Trabajo práctico grupal N° 2

Catedra: Moneta Pizarro

Integrantes grupo 8:

ALONSO, Aracelli Cecilia (43623975)

ARIAS, María Pia (45348034)

FERIOZZI, Candela (45091097)

GAITERI, Tiziana Sol (44992866)

LOSANO, Julieta (45405384)

Ejercicio 1 (5 de 20 puntos)

Dado el siguiente modelo dinámico: $\mathbf{A(L)}Y_t = \mathbf{B(L)}X_t$, en donde $\mathbf{A(L)} = 1 + 0.80L - 0.16L^2$ y $\mathbf{B(L)} = 2$, simbolizando L el operador de retardos, rezagos o desfasajes, se pide:

a) Calcular los **impactos intermedios** correspondientes a los períodos 0 a 5 inclusive y determinar si el modelo converge a una nueva solución de largo plazo, estableciendo si dicha convergencia, en caso de existir, es monótona u oscilatoria.

$$A(L) * Y_t = B(L) * X_t$$

$$Y_t = \frac{B(L)}{A(L)} * X_t$$

Definiendo a:

$$D(L) = \frac{B(L)}{A(L)}$$

$$D(L) * A(L) = B(L) \quad (1)$$

Además, teniendo en cuenta que:

$$D(L) = \delta_0 + \delta_1 * L + \delta_2 * L^2 + \delta_3 * L^3 + \delta_4 * L^4 + \delta_5 * L^5 + \dots \quad (2)$$

Reemplazando en (1) con $A(L) = 1 + 0.8 * L - 0.16 * L^2$; $B(L) = 2$ y también con (2):

$$(\delta_0 + \delta_1 * L + \delta_2 * L^2 + \delta_3 * L^3 + \delta_4 * L^4 + \delta_5 * L^5 + \dots) * (1 + 0.8 * L - 0.16 * L^2) = 2$$

Aplicando propiedad distributiva y luego haciendo factor común:

$$\begin{aligned} \delta_0 + (0.8 * \delta_0 + \delta_1) * L + (-0.16 * \delta_0 + 0.8 * \delta_1 + \delta_2) * L^2 + (-0.16 * \delta_1 + 0.8 * \delta_2 + \delta_3) * L^3 + \\ + (-0.16 * \delta_2 + 0.8 * \delta_3 + \delta_4) * L^4 + (-0.16 * \delta_3 + 0.8 * \delta_4 + \delta_5) * L^5 + \dots = 2 \end{aligned}$$

Se procede a encontrar los valores de los respectivos multiplicadores, en donde por términos iguales debe cumplirse que:

$$\delta_0 = 2$$

$$\delta_1 = -0.8 * \delta_0 = -0.8 * 2 = -1.6$$

$$\delta_2 = 0.16 * \delta_0 - 0.8 * \delta_1 = 0.16 * 2 - 0.8 * (-1.6) = 1.6$$

$$\delta_3 = 0.16 * \delta_1 - 0.8 * \delta_2 = 0.16 * (-1.6) - 0.8 * 1.6 = -1.536$$

$$\delta_4 = 0.16 * \delta_2 - 0.8 * \delta_3 = 0.16 * 1.6 - 0.8 * (-1.536) = 1.4848$$

$$\delta_5 = 0.16 * \delta_3 - 0.8 * \delta_4 = 0.16 * (-1.536) - 0.8 * 1.4848 = -1.4336$$

Se puede observar a partir de los valores encontrados de los multiplicadores, que los mismos van decreciendo en valor absoluto, de manera tal que a medida que se continúa en la búsqueda de los multiplicadores restantes estos se aproximan a cero. Esto quiere decir que los impactos de X en Y por cambios en periodos pasados son menores que por los cambios provocados más recientemente.

Por lo tanto, se puede decir que el modelo es convergente y en este caso ante cambios en la variable exógena X, se visualiza que la variable endógena Y presenta tanto variaciones positivas como negativas, es decir, que el modelo converge de manera oscilatoria esto se observa a través de que los multiplicadores alternan sus signos a medida que se acercan a cero.

b) Calcular el **efecto total de largo plazo** resultante de incrementar X en una unidad, de una vez y para siempre, a partir de una posición de equilibrio estacionario.

Con los datos obtenidos en el inciso anterior podemos calcular el efecto total de largo plazo:

Multiplicador de largo plazo: $D(1) = \delta_0 + \delta_1 + \delta_2 + \dots = \sum_{i=0}^{\infty} \delta_i$

$$D(1) = \frac{B(1)}{A(1)} = \frac{2}{1 + 0.8(1) - 0.16(1)^2} = 1.219512195$$

En el largo plazo, el equilibrio de Y está dado por:

$$\bar{Y} = D(1) * \bar{X}$$

Si en algún momento se altera este equilibrio al darse ΔX , entonces el nuevo valor de Y en el largo plazo será:

$$\bar{Y}^* = \bar{Y} + D(1) * \Delta X$$

Haciendo $\Delta X = 1$, $D(1)$ mide el efecto total que en el largo plazo provoca un cambio unitario de X en Y. En este caso, un cambio unitario en X provoca una variación en Y igual a 1.219512195.

c) ¿Tiene sentido en este caso calcular los **rezagos medio y mediano**? Justificar la respuesta explicando el significado y la forma de cálculo de estos indicadores.

Cuando los modelos son convergentes monótonos interesa conocer a qué velocidad responde Y a un cambio de X. Esto se puede hacer a través de las siguientes medidas resumen:

- **Rezago medio:** Es la media ponderada de los multiplicadores distribuidos en el tiempo. En este modelo, dado que los efectos de los cambios en X sobre Y decrecen y oscilan, el rezago medio puede ser calculado como el tiempo esperado hasta que el efecto acumulado sobre Y sea máximo. Sin embargo, si los multiplicadores tienden a cero rápidamente, el cálculo del rezago medio puede no tener mucho sentido práctico, ya que los efectos relevantes ocurren en pocos periodos.

Cálculo:

$$\text{REZAGO MEDIO} = \frac{\sum_{i=0}^{\infty} i \cdot \delta_i}{\sum_{i=0}^{\infty} \delta_i}$$

Como: $\sum_{i=0}^{\infty} \delta_i = D(1)$, y además: $\sum_{i=0}^{\infty} i \cdot \delta_i = D'(1)$, podemos escribir:

$$\text{REZAGO MEDIO} = \frac{D'(1)}{D(1)} = \frac{B'(1)}{B(1)} - \frac{A'(1)}{A(1)}$$

- **Rezago mediano:** Es el tiempo en el que la mitad del efecto total ha sido alcanzado. En un modelo oscilatorio como este, en donde los multiplicadores alternan en signo y se acercan a cero, este indicador también pierde su relevancia práctica. Esto se debe a que los efectos oscilatorios dificultan la identificación de un momento claro donde la mitad del efecto total se haya alcanzado.

Cálculo:


$$\text{REZAGO MEDIANO} = i_{j-1} + \frac{0.5 - \sum_{i=0}^{j-1} \frac{\delta_i}{D(1)}}{\sum_{i=0}^j \frac{\delta_i}{D(1)} - \sum_{i=0}^{j-1} \frac{\delta_i}{D(1)}}$$

En este caso particular, debido a que los multiplicadores oscilan y decrecen en magnitud (según lo resuelto en el inciso a), el cálculo de los rezagos medio y mediano no tiene mucho sentido práctico. El comportamiento oscilatorio del modelo implica que los efectos de los rezagos sobre Y no siguen un patrón monótono que permita una interpretación clara de los rezagos promedio o mediano.

d) Obtener las **raíces de la ecuación característica** del polinomio A(L) y relacionar los resultados con la respuesta dada en a). Además, explicar las diferencias de enfoque entre los **economistas matemáticos** y los **estadísticos**

matemáticos por lo que respecta a la ubicación de las raíces del polinomio $A(L)$ dentro o fuera del círculo unitario.

Las raíces de la ecuación característica, obtenidas aplicando Bhaskara, son: $(\lambda_1 = -0,9656; \lambda_2 = 0,1656)$, podemos ver que hay convergencia porque ambas raíces en valor absoluto se encuentran dentro del círculo unitario y la convergencia es del tipo oscilatoria porque los signos de las raíces son distintos. Podemos ver que los resultados son iguales al punto a, en donde los valores de los multiplicadores decrecen hasta aproximarse a cero, confirmando la convergencia del modelo y también vemos que los signos de los multiplicadores cambian entre uno y otro confirmando nuevamente que es un modelo oscilatorio. Por otro lado, destacamos que los economistas matemáticos trabajan directamente con las raíces del polinomio $A(L)$ y los estadísticos matemáticos trabajan con las raíces de la función característica. Las raíces del polinomio $A(L)$ son recíprocas a las raíces de la función característica, esta equivalencia implica que para los estadísticos matemáticos la convergencia existe cuando las raíces están fuera del círculo unitario en valor absoluto y la divergencia cuando están dentro. En este caso las raíces del polinomio $A(L)$ son: $(-1,035; 6.038)$, por lo tanto, se cumple la afirmación anterior.



e) Aplicar la **descomposición en fracciones parciales** del recíproco del polinomio $A(L)$ para verificar si los resultados de a) son correctos. Analizar las ventajas que aporta esta descomposición. **Ayuda:** ver el libro de Harvey (1990).

$$A(L) = 1 + 0.8 * L - 0.16L^2$$

En el inciso d) hemos encontrado las raíces de la ecuación característica $A(L)$, estas son: $\lambda_1 = -0.9656$ y $\lambda_2 = 0.1656$, ambas dentro del círculo unitario, por lo

que el modelo es convergente. Factorizando $A(L)$ usando estas raíces tenemos que: $A(L) = (1 + 0.9656 * L) * (1 - 0.1656 * L)$.

Se busca descomponer el recíproco del polinomio $A(L)$ en fracciones parciales, por lo tanto, determinando dicho recíproco:

$$A(L)^{-1} = \frac{1}{(1+0.9656*L)*(1-0.1656*L)} \quad (1)$$

Ahora debemos descomponer (1) en fracciones parciales:

$$A(L)^{-1} = \frac{k_1}{(1+0.9656*L)} + \frac{k_2}{(1-0.1656*L)} \quad (2)$$

Tomando denominador común en (2):

$$A(L)^{-1} = \frac{k_1(1 - 0.1656 * L) + k_2(1 + 0.9656 * L)}{(1 + 0.9656 * L) * (1 - 0.1656 * L)}$$

Para que se siga cumpliendo (1) es necesario que el numerador sea igual a 1, por lo tanto:

$$k_1(1 - 0.1656 * L) + k_2(1 + 0.9656 * L) = 1$$

Aplicando propiedad distributiva tenemos que:

$$k_1 - 0.1656 * L * k_1 + k_2 + 0.9656 * L * k_2 = 1$$

Reemplazamos los valores de L por las raíces del polinomio $A(L)$, que son las reciprocas de las raíces de la ecuación característica, es decir: $L = -1.0356$ y $L = 6.0386$, entonces:

$$k_1 - 0.1656 * (-1.0356) * k_1 = 1$$

$$(1 + 0.1715) k_1 = 1$$

$$k_1 = \frac{1}{1.1715} = 0.8536$$

$$k_2 + 0.9656 * 6.0386 * k_2 = 1$$

$$(1 + 5.8309) k_2 = 1$$

$$k_2 = \frac{1}{6.8309} = 0.1464$$

Reemplazando estos valores en (2):

$$A(L)^{-1} = \frac{0.8536}{(1+0.9656*L)} + \frac{0.1464}{(1-0.1656*L)} \quad (3)$$

Reemplazando (3) en $D(L) = B(L) * A(L)^{-1}$, siendo $B(L) = 2$

$$D(L) = 2 * \left(\frac{0.8536}{(1+0.9656*L)} + \frac{0.1464}{(1-0.1656*L)} \right)$$

Utilizando la propiedad de las sumas infinitas de progresiones geométricas:

$$D(L) = 2 * \left(0.8536 * \sum_{j=0}^{\infty} -0.9656^j * L^j + 0.1464 * \sum_{j=0}^{\infty} 0.1656^j * L^j \right)$$

$$= 2 * \sum_{j=0}^{\infty} \left(0.8536(-0.9656^j) + 0.1464(0.1656^j) \right) * L^j \quad (4)$$

Obtenemos el multiplicador de largo plazo haciendo $L=1$:

$$D(1) = 2 * \sum_{j=0}^{\infty} \left(0.8536(-0.9656^j) + 0.1464(0.1656^j) \right) * 1^j$$

Así es como se encuentra la ecuación que permite llegar a los valores de los multiplicadores de impacto intermedio, de esta manera se buscan aquellos que se encuentren dentro de los primeros 5 periodos:

Para δ_0 , se conoce que $L^j = 1$ ya que $j=0$.

Por lo tanto, reemplazando en (4) obtenemos el valor de δ_0 .

$$2 * \left(0.8536(-0.9656^0) + 0.1464(0.1656^0) \right) * L^0 = 2 * L^0$$

El coeficiente que acompaña a L^0 es 2, por lo tanto $\delta_0 = 2$

Para δ_1 , se conoce que $j=1$.

$$2 * \left(0.8536(-0.9656^1) + 0.1464(0.1656^1) \right) * L^1 = -1.59 * L$$

El coeficiente que acompaña a L^1 es -1.59, por lo tanto $\delta_1 = -1.6$

Para δ_2 , se conoce que $j=2$.

$$2 * \left(0.8536(-0.9656^2) + 0.1464(0.1656^2) \right) * L^2 = 1.59 * L^2$$

El coeficiente que acompaña a L^2 es 1.59, por lo tanto $\delta_2 = 1.6$

Para δ_3 , se conoce que $j=3$.

$$2 * (0.8536(-0.9656^3) + 0.1464(0.1656^3)) * L^3 = -1.536 * L^3$$

El coeficiente que acompaña a L^3 es -1.536, por lo tanto $\delta_3 = -1.536$.

Para δ_4 , se conoce que $j=4$.

$$2 * (0.8536(-0.9656^4) + 0.1464(0.1656^4)) * L^4 = 1.484 * L^4$$

El coeficiente que acompaña a L^4 es 1.484, por lo tanto $\delta_4 = 1.484$.

Para δ_5 , se conoce que $j=5$.

$$2 * (0.8536(-0.9656^5) + 0.1464(0.1656^5)) * L^5 = -1.433 * L^5$$

El coeficiente que acompaña a L^5 es -1.433, por lo tanto $\delta_5 = -1.433$

Se puede observar que se alcanzaron los mismos valores de los multiplicadores de impacto intermedio que obtuvimos en el inciso a).

La descomposición en fracciones parciales tiene la ventaja de que es posible obtener cualquier multiplicador de impacto intermedio a partir del reemplazo en la formula, sin necesidad de desarrollar los multiplicadores anteriores como en el método empleado en el inciso a).

Ejercicio 2 (5 de 20 puntos)

Buscar en el [Portal de Datos Económicos del Ministerio de Economía](#) los datos mensuales de la serie desestacionalizada del **Estimador Mensual de Actividad Económica** (EMAE) en números índice (base 2004 = 100) del período 2004:01-2024:06 y empleando esta información con ayuda de EViews:

- a) Graficar por un lado la serie en niveles y por otro lado una transformación de esta serie resultado de aplicar logaritmo natural y primera diferencia, en ese orden. ¿Qué características de la serie observada en niveles justifican estas transformaciones según la metodología **ARIMA de Box y Jenkins**?

Grafico de la serie en niveles:




Gráfico 1

Gráfico etapa de identificación adaptado de Eviews.

Nota. Tomado del *portal de datos económicos del Ministerio de Economía*.

El propósito en esta primera etapa de aplicación de la metodología **ARIMA de Box y Jenkins**, es la representación gráfica de la serie para poder predecir sobre la estacionariedad, es decir, observar si la serie presenta tendencias o varianzas no constantes.

Observamos en primera instancia, en la serie en niveles, una tendencia ascendente y relativamente lineal, como así también variaciones no constantes de la varianza.

Gráfico de la serie transformada (en logaritmos):




Gráfico 2

Gráfico etapa de identificación adaptado de Eviews.

Nota. Tomado del *portal de datos económicos del Ministerio de Economía*.

El propósito de esta transformación es estabilizar la varianza y permitir que la serie se ajuste mejor a los supuestos del modelo ARIMA, es decir, buscamos estacionariedad. Las transformaciones logarítmicas son útiles cuando los datos tienen un crecimiento exponencial o la variabilidad aumenta con el nivel de la serie.

Gráfico de la serie transformada (en logaritmos y diferencias):

El siguiente gráfico muestra la serie diferenciada después de aplicar la transformación logarítmica, aquí se observa:




Gráfico 3

Gráfico etapa de identificación adaptado de Eviews.

Nota. Tomado del *portal de datos económicos del Ministerio de Economía*.

- **Estacionariedad:** Supuesto muy importante que debe estar presente. La serie diferenciada es estacionaria en media, ya que las fluctuaciones oscilan alrededor de cero, es decir, con una tendencia lineal nula, donde los valores no crecen ni disminuyen en el tiempo. **Otra interpretación:** cualquier valor hacia el futuro es impredecible, excepto predecir que puede ser igual a cero.
- **Ruido blanco:** Aunque la serie parece tener oscilaciones aleatorias, parece haber un gran pico alrededor del año 2020, posiblemente debido a un evento externo (como la pandemia de COVID-19). Esto sugiere que el componente de "ruido blanco" es en su mayoría presente, pero hay ciertos episodios de alta volatilidad.

La transformación logarítmica y la primera diferencia están justificadas por la necesidad de estabilizar la varianza y remover la no estacionariedad en la serie en niveles(default). Estos pasos son esenciales dentro del enfoque ARIMA para poder capturar los procesos generadores de datos por detrás de las series y ajustar mejor un modelo que pueda prever el comportamiento futuro.

De modo complementario, agregamos un test de contraste de raíz unitaria para probar estadísticamente (y no sólo gráficamente) la estacionariedad de la serie. Este test de Dickey-Fuller Augmented, tiene como hipótesis nula que existe una raíz unitaria, es decir, que la serie no es estacionaria. Por lo tanto, nosotros lo que buscamos comprobar en este estadístico de prueba es que su p-value sea menor al nivel de significancia con el que trabajamos usualmente (0,05). Si sucede esto tenemos evidencia estadística suficiente para rechazar la hipótesis nula de que existe una raíz unitaria, es decir de que nuestra serie no es estacionaria.

Null Hypothesis: DLNEMAE has a unit root
 Exogenous: Constant
 Lag Length: 0 (Automatic - based on SIC, maxlag=15)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-13.72185	0.0000
Test critical values:		
1% level	-3.457061	
5% level	-2.873190	
10% level	-2.573054	

*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation
 Dependent Variable: D(DLNEMAE)
 Method: Least Squares
 Date: 10/08/24 Time: 18:41
 Sample (adjusted): 2004M03 2024M06
 Included observations: 244 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
DLNEMAE(-1)	-0.875244	0.063785	-13.72185	0.0000
C	0.148402	0.151662	0.978508	0.3288
R-squared	0.437588	Mean dependent var		-0.000820
Adjusted R-squared	0.435264	S.D. dependent var		3.144333
S.E. of regression	2.362933	Akaike info criterion		4.565848
Sum squared resid	1351.196	Schwarz criterion		4.594513
Log likelihood	-555.0334	Hannan-Quinn criter.		4.577392
F-statistic	188.2892	Durbin-Watson stat		1.973140
Prob(F-statistic)	0.000000			

Tabla 1

Test de contraste de raíz unitaria, salida de Eviews

Nota. Tomado del *portal de datos económicos del Ministerio de Economía*

Dado el p-value obtenido (0.0000), estamos frente a evidencia estadística de que nuestra serie es estacionaria.

b) Estimar sucesivamente los **modelos autorregresivos** AR(1), AR(2) y AR(3) para la serie transformada utilizando los datos del período 2004:01-2023:12 y comentar los resultados. Incluir una constante en cada modelo y trabajar de aquí en adelante con un nivel de significación de 5 % para evaluar los resultados.

MODELO AR (1)

Dependent Variable: DLNEMAE

Method: ARMA Maximum Likelihood (OPG - BHHH)

Date: 10/08/24 Time: 19:08

Sample: 2004M02 2023M12

Included observations: 239

Convergence achieved after 142 iterations

Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.183911	0.227788	0.807380	0.4203
AR(1)	0.123210	0.018888	6.523319	0.0000
SIGMASQ	5.622776	0.166223	33.82679	0.0000
R-squared	0.015219	Mean dependent var		0.185774
Adjusted R-squared	0.006874	S.D. dependent var		2.394507
S.E. of regression	2.386263	Akaike info criterion		4.589871
Sum squared resid	1343.843	Schwarz criterion		4.633509
Log likelihood	-545.4896	Hannan-Quinn criter.		4.607456
F-statistic	1.823616	Durbin-Watson stat		1.967645
Prob(F-statistic)	0.163709			
Inverted AR Roots	.12			

Tabla 2

Output ecuación AR(1)

Nota. Tomado del *portal de datos económicos del Ministerio de Economía*

Análisis de los siguientes puntos:

- **Prueba T de significancia individual de los coeficientes:** bajo un nivel de significancia del 5% podemos concluir que los coeficientes son significativamente distintos de cero, aportando ambos, poder explicativo al modelo.

- **R cuadrado:** Observamos una baja bondad de ajuste del modelo (0,01521), es decir, tan solo un 1.52% de la variabilidad de los datos es explicado; dándonos indicios de que quizás el modelo no es el más adecuado para nuestros datos.
- **Validez global (F) del modelo:** Obtuvimos un F crítico, con 239 grados de libertad en el numerador y 2 grados de libertad en el denominador, de 19.5, contra un F observado de 1.823616. Asimismo, un p-value de 0.1637 (mayor que 0.05) llegando a la conclusión de que no hay evidencia estadística significativa (al 5%) para rechazar la hipótesis nula de que todos los coeficientes del modelo son iguales a cero.

MODELO AR (1) AR (2)

Dependent Variable: DLNEMAE

Method: ARMA Maximum Likelihood (OPG - BHHH)

Date: 10/08/24 Time: 19:14

Sample: 2004M02 2023M12

Included observations: 239

Convergence achieved after 95 iterations

Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.186725	0.213554	0.874367	0.3828
AR(1)	0.136090	0.029845	4.559935	0.0000
AR(2)	-0.107929	0.053390	-2.021536	0.0444
SIGMASQ	5.556769	0.229164	24.24799	0.0000
R-squared	0.026780	Mean dependent var		0.185774
Adjusted R-squared	0.014356	S.D. dependent var		2.394507
S.E. of regression	2.377257	Akaike info criterion		4.586528
Sum squared resid	1328.068	Schwarz criterion		4.644712
Log likelihood	-544.0901	Hannan-Quinn criter.		4.609975
F-statistic	2.155469	Durbin-Watson stat		1.994010
Prob(F-statistic)	0.093998			
Inverted AR Roots	.07+.32i	.07-.32i		

Tabla 3

Output ecuación AR(1)(2)

Nota. Tomado del *portal de datos económicos del Ministerio de Economía*

Análisis de los siguientes puntos:

- **Prueba T de significancia individual de los coeficientes:** bajo un nivel de significancia del 5% podemos concluir que los coeficientes son significativamente distintos de cero, aportando ambos, poder explicativo al modelo. De todos modos, si quisiéramos utilizar un nivel de significancia del 10%, no sería posible ya que el coeficiente se volvería igual a cero sin aportar poder explicativo al modelo.
- **R cuadrado:** Observamos una baja bondad de ajuste del modelo (0,02678), es decir, tan solo un 2.7% de la variabilidad de los datos es explicado; dándonos indicios de que quizás el modelo no es el más adecuado para nuestros datos.
- **Validez global (F) del modelo:** Obtuvimos un F crítico, con 239 grados de libertad en el numerador y 2 grados de libertad en el denominador, de 19.5, contra un F observado de 2.1554. Asimismo, un p-value de 0.093998 (mayor que 0.05) llegando a la conclusión de que no hay evidencia estadística significativa (al 5%) para rechazar la hipótesis nula de que todos los coeficientes del modelo son iguales a cero.

MODELO AR (1) - AR (2) - AR (3)

Dependent Variable: DLNEMAE

Method: ARMA Maximum Likelihood (OPG - BHHH)

Date: 10/08/24 Time: 19:25

Sample: 2004M02 2023M12

Included observations: 239

Convergence achieved after 156 iterations

Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.186823	0.213076	0.876793	0.3815
AR(1)	0.135825	0.033692	4.031333	0.0001
AR(2)	-0.107625	0.065902	-1.633117	0.1038
AR(3)	-0.002355	0.084541	-0.027851	0.9778
SIGMASQ	5.556737	0.239064	23.24374	0.0000
R-squared	0.026785	Mean dependent var		0.185774
Adjusted R-squared	0.010149	S.D. dependent var		2.394507
S.E. of regression	2.382325	Akaike info criterion		4.594891
Sum squared resid	1328.060	Schwarz criterion		4.667620
Log likelihood	-544.0895	Hannan-Quinn criter.		4.624199
F-statistic	1.610059	Durbin-Watson stat		1.993495
Prob(F-statistic)	0.172495			
Inverted AR Roots	.08+.32i	.08-.32i	-.02	

Tabla 4

Output ecuación AR(1)(2)(3)

Análisis de los siguientes puntos:

- **Prueba T de significancia individual de los coeficientes:** bajo un nivel de significancia del 5% podemos concluir que solamente el coeficiente AR (1) es significativamente distinto de cero (arrojando un p-value de 0,0001), mientras que el resto de los coeficientes arrojan un p-value mayor al nivel de significancia utilizado, concluyendo entonces que no encontramos evidencia estadística significativa para rechazar la hipótesis nula de que estos son iguales a cero.
- **R cuadrado:** Observamos una baja bondad de ajuste del modelo(0,026780), es decir, tan solo un 2.7% de la variabilidad de los datos es explicado; dándonos indicios de que quizás el modelo no es el más adecuado para nuestros datos.
- **Validez global (F) del modelo:** Obtuvimos un F crítico, con 239 grados de libertad en el numerador y 2 grados de libertad en el denominador, de 19.5, contra un F observado de 1.6100. Asimismo, un p-value de 0.17249 (mayor que 0.05) llegando a la conclusión de que no hay evidencia estadística significativa (al 5%) para rechazar la hipótesis nula de que todos los coeficientes del modelo son iguales a cero.

b) Para cada modelo realizar un análisis de **diagnóstico sobre los residuos** mediante **correlogramas** y **pruebas de Ljung y Box**.

Para realizar el análisis de diagnóstico sobre los residuos, debemos introducir dos conceptos fundamentales, a saber:

- **Función de autocorrelación de los residuos:** Esta función muestra la relación entre los residuos contemporáneos y sus observaciones pasadas, permitiendo evaluar si algún efecto del pasado no ha sido capturado por el modelo. Bajo este análisis, consideramos que un buen modelo es aquel en el cual no queda nada por explicar del pasado. En otras palabras, buscamos que los coeficientes de autocorrelación sean cercanos a cero, lo que indica la presencia de "ruido blanco," es decir, que no hay un efecto significativo del pasado sobre el presente.
- **Función de autocorrelación parcial de los residuos:** Esta función examina el efecto de un período pasado sobre el presente, manteniendo constantes los efectos de los otros períodos, un concepto similar al *ceteris paribus* en economía. Es decir, se evalúa el impacto de un mes específico en el pasado, suponiendo que no hubo ningún efecto en los demás meses.

MODELO AR(1)

CORRELOGRAMA Q-STATISTICS

Date: 10/08/24 Time: 19:10

Sample: 2004M01 2023M12

Included observations: 239

Q-statistic probabilities adjusted for 1 ARMA term

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
		1 0.014	0.014	0.0460	
		2 -0.106	-0.106	2.7673	0.096
		3 -0.017	-0.015	2.8417	0.242
		4 0.006	-0.004	2.8518	0.415
		5 0.022	0.019	2.9741	0.562
		6 -0.021	-0.021	3.0783	0.688
		7 0.089	0.095	5.0228	0.541
		8 -0.022	-0.029	5.1462	0.642
		9 -0.113	-0.095	8.3296	0.402
		10 0.014	0.015	8.3783	0.497
		11 -0.053	-0.077	9.0846	0.524
		12 0.004	0.002	9.0896	0.614
		13 -0.008	-0.016	9.1064	0.694
		14 -0.016	-0.022	9.1733	0.760
		15 0.007	0.005	9.1857	0.819
		16 -0.050	-0.034	9.8244	0.831
		17 0.028	0.020	10.028	0.865
		18 0.028	0.021	10.237	0.893
		19 0.034	0.038	10.539	0.913
		20 -0.128	-0.142	14.831	0.733
		21 0.030	0.055	15.074	0.772
		22 -0.011	-0.056	15.108	0.817
		23 0.108	0.126	18.239	0.692
		24 -0.044	-0.068	18.758	0.715
		25 -0.046	-0.024	19.326	0.734
		26 -0.009	-0.025	19.349	0.780
		27 -0.062	-0.048	20.408	0.772
		28 0.024	0.016	20.567	0.806
		29 -0.026	-0.058	20.749	0.836
		30 0.002	0.008	20.749	0.868
		31 0.071	0.050	22.137	0.849
		32 0.002	0.041	22.138	0.879
		33 -0.063	-0.082	23.230	0.871
		34 -0.032	-0.003	23.526	0.888
		35 -0.036	-0.071	23.893	0.902
		36 -0.001	-0.030	23.893	0.922

Correlograma 1

Este correlograma es un diagnóstico de residuos adaptado de Eviews.

Nota. Tomado del portal de datos económicos del Ministerio de Economía.

MODELO AR(1) - AR(2)

CORRELOGRAMA Q-SATISTICS

Date: 10/08/24 Time: 19:22
Sample: 2004M01 2023M12
Included observations: 239
Q-statistic probabilities adjusted for 2 ARMA terms

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
		1 0.000	0.000	3.E-05	
		2 -0.001	-0.001	0.0001	
		3 -0.000	-0.000	0.0002	0.990
		4 -0.005	-0.005	0.0054	0.997
		5 0.029	0.029	0.2114	0.976
		6 -0.025	-0.025	0.3710	0.985
		7 0.082	0.082	2.0466	0.843
		8 -0.024	-0.024	2.1883	0.902
		9 -0.113	-0.113	5.3665	0.615
		10 0.015	0.015	5.4214	0.712
		11 -0.068	-0.067	6.5810	0.681
		12 0.004	-0.002	6.5846	0.764
		13 -0.013	-0.008	6.6300	0.828
		14 -0.022	-0.024	6.7508	0.874
		15 0.010	0.008	6.7765	0.913
		16 -0.051	-0.029	7.4385	0.916
		17 0.031	0.021	7.6883	0.936
		18 0.009	0.009	7.7105	0.957
		19 0.042	0.043	8.1670	0.963
		20 -0.128	-0.147	12.474	0.822
		21 0.048	0.062	13.085	0.834
		22 -0.032	-0.049	13.355	0.862
		23 0.108	0.119	16.479	0.742
		24 -0.049	-0.065	17.111	0.757
		25 -0.041	-0.041	17.566	0.781
		26 -0.008	-0.018	17.583	0.823
		27 -0.072	-0.049	18.974	0.798
		28 0.025	0.020	19.148	0.830
		29 -0.026	-0.047	19.330	0.858
		30 0.003	0.009	19.332	0.888
		31 0.063	0.045	20.430	0.879
		32 -0.002	0.042	20.431	0.905
		33 -0.060	-0.094	21.436	0.900
		34 -0.029	-0.009	21.678	0.916
		35 -0.032	-0.048	21.960	0.928
		36 -0.003	-0.032	21.963	0.945

Correlograma 2

Este correlograma es un diagnóstico de residuos adaptado de Eviews.

Nota. Tomado del *portal de datos económicos del Ministerio de Economía*.

MODELO AR(1) - AR(2) - AR(3)

CORRELOGRAMA Q-STATISTICS

Date: 10/08/24 Time: 19:35
Sample: 2004M01 2023M12
Included observations: 239
Q-statistic probabilities adjusted for 3 ARMA terms

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob	
		1	0.001	0.001	8.E-05	
		2	-0.001	-0.001	0.0003	
		3	0.002	0.002	0.0011	
		4	-0.004	-0.004	0.0052	0.942
		5	0.029	0.029	0.2066	0.902
		6	-0.026	-0.026	0.3694	0.946
		7	0.082	0.082	2.0466	0.727
		8	-0.024	-0.025	2.1892	0.822
		9	-0.113	-0.113	5.3710	0.497
		10	0.015	0.015	5.4264	0.608
		11	-0.068	-0.067	6.5875	0.582
		12	0.003	-0.001	6.5905	0.680
		13	-0.013	-0.008	6.6366	0.759
		14	-0.022	-0.024	6.7578	0.818
		15	0.010	0.008	6.7836	0.872
		16	-0.051	-0.029	7.4449	0.878
		17	0.031	0.020	7.6888	0.905
		18	0.009	0.009	7.7117	0.935
		19	0.042	0.043	8.1641	0.944
		20	-0.128	-0.147	12.449	0.772
		21	0.048	0.061	13.057	0.788
		22	-0.032	-0.050	13.325	0.822
		23	0.108	0.119	16.430	0.690
		24	-0.049	-0.066	17.063	0.707
		25	-0.041	-0.041	17.518	0.734
		26	-0.008	-0.018	17.534	0.782
		27	-0.072	-0.049	18.926	0.756
		28	0.025	0.021	19.100	0.792
		29	-0.026	-0.047	19.282	0.824
		30	0.002	0.009	19.284	0.859
		31	0.063	0.045	20.381	0.850
		32	-0.002	0.042	20.382	0.881
		33	-0.060	-0.094	21.388	0.875
		34	-0.029	-0.009	21.623	0.894
		35	-0.032	-0.048	21.904	0.910
		36	-0.003	-0.032	21.908	0.930

Correlograma 3

Este correlograma es un diagnóstico de residuos adaptado de Eviews.

Nota. Tomado del *portal de datos económicos del Ministerio de Economía*.

Para interpretar los correlogramas correspondientes a cada modelo, comenzamos postulando la hipótesis nula, que plantea la ausencia de correlación de cualquier orden, es decir, que los residuos del modelo son ruido blanco.

En los tres gráficos, observamos que ningún *p-value* es menor al nivel de significancia establecido (0,05). Aunque gráficamente el período 20 podría generar cierta confusión, el *p-value* confirma que no hay motivos de preocupación. Por lo tanto, podemos concluir que en los tres modelos los

residuos son ruido blanco, lo que indica que no queda ningún efecto del pasado sin ser explicado por los modelos.

Con respecto a la prueba de Ljung-Box, esta es un test para detectar autocorrelación en los residuos de un modelo. La hipótesis nula plantea que los errores son independientes, mientras que la hipótesis alternativa sugiere la presencia de autocorrelación en los errores.

$$H_0 = \alpha_0 = \alpha_1 = \alpha_2 = \dots = \alpha_m = 0$$

$$H_0 = \text{Autocorrelacion de los errores}$$

Estadístico:

$$Q = n(n+2) \sum_{k=1}^m \frac{r^2(k)}{n-k}$$

Este estadístico se distribuye asintóticamente como una chi-cuadrado con m grados de libertad, donde m representa el orden de la autocorrelación. Procedemos a calcular este estadístico para varios valores de.

Afortunadamente, los valores Q de este estadístico, salen de los correlogramas realizados anteriormente para los residuos, por lo que:

Para m=1 (nos fijamos en el retardo 1 de nuestro correlograma)

- Modelo 1, Q= 0,0460
- Modelo 2, Q=3.E-0,5
- Modelo 3, Q=8.E-0,5

Estos valores se comparan con el valor crítico de la distribución chi-cuadrado con 1 grado de libertad y un nivel de confianza del 95%:

$$X^2 = 3,84$$

Para m=20 (nos fijamos en el retardo 20 de nuestro correlograma)

- Modelo 1, Q= 14,831
- Modelo 2, Q=12,474
- Modelo 3, Q=12,449

Estos valores se comparan con el valor crítico de la distribución chi-cuadrado con 20 grados de libertad y un nivel de confianza del 95%:

$$X^2 = 31,4$$

En ambos casos, los valores observados de QQ son menores que los valores críticos de la distribución chi-cuadrado. En particular, nos interesaba probar la autocorrelación en el retardo 20, ya que este periodo mostraba indicios

sospechosos en la inspección gráfica inicial. Sin embargo, no encontramos evidencia estadísticamente significativa para rechazar la hipótesis nula. Por lo tanto, no hay autocorrelación de ningún orden, lo que implica que todos los $\alpha=0$. Vale aclarar nuevamente que se puede hacer para la cantidad de m que se quiera, lo hicimos solo para dos grados de m porque de lo contrario el análisis se extiende mucho.

- c) ¿Cuál de los modelos estimados en b) resulta el más satisfactorio? Explicar las razones de la elección sobre la base de los resultados obtenidos en b) y c).

Comenzaremos con un análisis de los criterios de información, que detallamos a continuación. Nuestra regla de decisión será que, cuanto más bajo sea el valor absoluto del criterio, mejor será el modelo. En otras palabras, menos es más: un valor más pequeño indica un mejor ajuste del modelo.

MODELO 1:

Schwarz criterion	4.633509
Hannan-Quinn criter.	4.607456
Durbin-Watson stat	1.967645

MODELO 2:

Schwarz criterion	4.644712
Hannan-Quinn criter.	4.609975
Durbin-Watson stat	1.994010

MODELO 3:

Schwarz criterion	4.667620
Hannan-Quinn criter.	4.624199
Durbin-Watson stat	1.993495

Al comparar los tres modelos, observamos que el Modelo 1 presenta los valores más bajos en los criterios de Schwarz, Hannan-Quinn y Durbin-Watson:

- **Criterio de Schwarz (BIC):** Penaliza más la complejidad del modelo. Un valor más bajo indica un mejor ajuste con menos parámetros innecesarios.
- **Criterio de Hannan-Quinn (HQ):** Similar al BIC, equilibra la bondad de ajuste y la simplicidad del modelo, pero con una penalización más moderada.
- **Estadístico Durbin-Watson (DW):** Evalúa la presencia de autocorrelación en los residuos. Un valor cercano a 2 sugiere ausencia de autocorrelación.

Estos resultados indican que el Modelo 1 es el más adecuado, ya que ofrece un mejor balance entre ajuste y simplicidad, además de no presentar autocorrelación en los residuos.

En cuanto al análisis del inciso b, recordemos que solo en los Modelos 1 y 2 los coeficientes eran significativamente distintos de cero. Sin embargo, en el Modelo 2, esta relación cambiaba al aumentar el nivel de confianza. Por lo tanto, si seguimos un enfoque riguroso, deberíamos preferir el Modelo 1 también en este aspecto.

Por último, en el análisis de diagnóstico de los residuos del inciso c, los tres modelos resultan satisfactorios, brindando un ajuste adecuado.

En conclusión, elegimos el Modelo 1 para realizar la predicción a continuación.

- d) Evaluar la adecuación del modelo seleccionado en d) para la **predicción** de los valores utilizados en la estimación (predicción dentro de la muestra) y para predecir los valores del año 2024 (predicción fuera de la muestra).
Ayuda: para la predicción dentro de la muestra debe utilizarse la opción “static forecast” de Eviews y para la predicción fuera de la muestra la opción “dynamic forecast”.

Predicción dinámica: Esta es adecuada para predecir valores fuera de la muestra, ya que permite ajustar el modelo a datos futuros. En nuestro caso, al cortar la muestra para la estimación, el modelo puede proyectar hacia el futuro. Esto es lo opuesto a una predicción estática, donde el modelo esta frizado una vez estimado.

En cuanto a los criterios de información que aparecen al lado del grafico, podemos decir que mientras más bajos sean estos valores, mejor se considera el ajuste del modelo, es decir, la interpretación "menos es más" sigue aplicando: el modelo con los valores más bajos será el más eficiente.




Gráfico 4

Predicción dinámica del modelo DLNEMAE y evaluación del error

El gráfico muestra la predicción dinámica del modelo para el período fuera de la muestra, con intervalos de confianza de ± 2 errores estándar. Se presenta la evaluación del error mediante el RMSE, MAE, y otros estadísticos.

Nota. Creación propia con datos de EViews.

Interpretación de la información alrededor del gráfico:

- **Root Mean Squared Error (RMSE):** Mide la magnitud promedio de los errores de predicción, en este caso es 2.371726. Un RMSE más bajo nos está indicando un mejor ajuste del modelo.
- **Mean Absolute Error (MAE):** Representa el promedio absoluto de los errores, con un valor de 1.459037. Al igual que el RMSE, un MAE más bajo indica que las predicciones del modelo son más precisas.
- **Theil Inequality Coefficient:** Este valor es 0.929901 y sirve para evaluar la precisión de las predicciones. Valores más cercanos a 0 sugieren un mejor rendimiento del modelo. En este caso, al ser tan alto, no indica que el modelo sea "bueno", sino que el modelo tiene limitaciones en su capacidad predictiva.
- **Bias Proportion:** Es 0.000035, lo que indica que casi no hay sesgo en el modelo de predicción. Un valor bajo es deseable, ya que sugiere que el modelo no está sesgado.
- **Variance Proportion:** Con un valor de 0.997460, indica que la mayor parte del error en la predicción proviene de la varianza entre las observaciones, lo cual es algo esperable en modelos predictivos.
- **Covariance Proportion:** Con un valor bajo de 0.002505, este indicador sugiere que el error debido a la covarianza es mínimo. Esto es deseable, ya que indica que no hay mucha correlación entre los errores de las predicciones y las variables explicativas.
- **Symmetric Mean Absolute Percentage Error (SMAPE):** Es 160.4771, lo cual indica el porcentaje promedio de error entre los valores reales y las predicciones. Un SMAPE más bajo es mejor, claramente en este caso es elevado, lo que nos dice que las predicciones no son precisas.

En resumen, aunque el Modelo 1 es el más adecuado según ciertos criterios, su rendimiento en la predicción es preocupante y se deberá avanzar con cautela en si se lo quiere usar para tomar decisiones.

Ejercicio 3 (6 de 20 puntos)

Retomando el **ejercicio 2 del Trabajo Grupal 1** referido a los datos del archivo **pons.wf1**, volver a estimar por MCO un modelo para la demanda real de dinero (m_2) en función de la tasa de inflación (inflacion), el PBI real (pbi) y el tipo de cambio real (tc), más una constante, y resolver lo siguiente:

- a) Investigar en la bibliografía sobre el contraste de **Jarque y Bera**, describir sus características y con ayuda de EViews utilizar esta prueba para comprobar si se cumple el supuesto de normalidad del error. Continuar trabajando con un nivel de significación del 5 %.

Dependent Variable: M2
 Method: Least Squares
 Date: 10/13/24 Time: 15:09
 Sample: 2016M01 2022M09
 Included observations: 81

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	3.85E+08	1.25E+08	3.077765	0.0029
INFLACION	-8158113.	2642028.	-3.087822	0.0028
PBI	78.75042	433.6084	0.181616	0.8564
TC	-3096995.	7441596.	-0.416173	0.6784
R-squared	0.149403	Mean dependent var	3.62E+08	
Adjusted R-squared	0.116263	S.D. dependent var	33689704	
S.E. of regression	31670781	Akaike info criterion	37.42781	
Sum squared resid	7.72E+16	Schwarz criterion	37.54605	
Log likelihood	-1511.826	Hannan-Quinn criter.	37.47525	
F-statistic	4.508215	Durbin-Watson stat	0.548288	
Prob(F-statistic)	0.005747			

Grafico 1

Estimación por mínimos cuadrados ordinarios.

Nota. Tomado de pons.wf

La prueba de normalidad Jarque Bera es una prueba asintótica, o utilizada en muestras grandes. También se basa en los residuos de MCO. Esta prueba calcula primero la asimetría y la curtosis de los residuos de MCO, con el estadístico de prueba:

$$JB = n \left[\frac{s^2}{6} + \frac{(k-3)^2}{24} \right]$$

donde n es el tamaño de la muestra, S es el coeficiente de asimetría y K el coeficiente de curtosis. Para una variable normalmente distribuida, se determina que S= 0 y K= 3. Por tanto, la prueba de normalidad constituye una prueba de la hipótesis conjunta de que S y K son 0 y 3, respectivamente.

Para este caso plantearemos las siguientes pruebas de hipótesis:

H0: los residuos se encuentran normalmente distribuidos

H1: los residuos no tienen distribución normal




Gráfico 2

Test de normalidad del error.

Nota. Tomado de pons.wf

Si se obtiene el valor crítico JB siendo este 5.992 con 2 grados de libertad y el JB observado 1.520296, se puede concluir que no se rechazara la hipótesis nula de que los errores se encuentran normalmente distribuidos. Además también se puede analizar la normalidad de errores por medio del coeficiente de asimetría $S=0.208689$ y el coeficiente de curtosis $k=3.525599$, pudiendo determinar que S se aproxima a 0, al igual que K se aproxima a 3, por lo que se puede sostener el supuesto de normalidad de los errores.

- b) Explorar gráficamente y aplicar otras pruebas con EViews para contrastar la **normalidad** del error. Comparar con los resultados hallados en a).
Ayuda: revisar las opciones disponibles abriendo la ventana de los residuos (View ® Graph, View ® Descriptive Statistics & Tests ® Empirical Distribution Tests...).

El grafico box plot nos permite resumir y visualizar la distribución de un conjunto de datos. Muestra la mediana, la media, los cuartiles y los posibles valores atípicos.

Para que los residuos tengan una distribución normal se debe observar:

- La caja sea aproximadamente simétrica alrededor de la mediana.
- Se deben mostrar pocos valores atípicos o ningún valor atípico.
- Distribución uniforme: los cuartiles deben estar equilibrados, sin ningún sesgo hacia algunos de los extremos.

Debido a que el grafico cumple con los requerimientos podemos concluir que los residuos presentan una distribución normal.




Grafico 3

Box plot

Nota. Tomado de Pons wf.

Por otro lado, también podemos ver la normalidad de los errores con el grafico de qq plot. En el cual observamos que los puntos se alienan cerca de la diagonal, indicando que los cuantiles de los residuos se distribuyen de manera similar a los cuantiles de una distribución normal, tampoco se dan desviaciones significativas de la recta de 45°.




Grafico 4

Qq plot

Nota. Tomado de pons.wf

Empirical Distribution Test for RESID
Hypothesis: Normal
Date: 10/13/24 Time: 16:07
Sample: 2016M01 2022M09
Included observations: 81

Method	Value	Adj. Value	Probability
Lilliefors (D)	0.069360	NA	> 0.1
Cramer-von Mises (W2)	0.083075	0.083588	0.1862
Watson (U2)	0.082519	0.083029	0.1604
Anderson-Darling (A2)	0.584257	0.589867	0.1241

Gráfico 5

Métodos para determinar la normalidad del error.

Nota. Tomado de pons.wf

Utilizando los distintos métodos (Lilliefors, Cramer-von Mises, Watson y Anderson- Darling) para determinar la distribución normal de los residuos, se puede observar que todos arrojan p-value mayores que el nivel de significación utilizado (0.05); lo cual nos permite concluir que no se debe rechazar la hipótesis nula de la distribución normal de los errores. Finalmente, si los comparamos con los resultados obtenidos en el inciso anterior ambas llegan a la misma conclusión.

- c) Contrastar la posible presencia de autocorrelación en el término de error con el test de **Durbin y Watson**.

El test de Durbin- Watson sirve para determinar la existencia de autocorrelación de primer orden, ósea que $\rho_{ut} = 1 + \epsilon_t$, con $|\rho| < 1$. Este test sirve para muestras pequeñas y no funciona si el modelo tiene retardos en la variable dependiente ya que supone que las variables explicativas del modelo son fijas, y tampoco puede ser empleado en modelos sin constante.

$$H_0: \rho = 0$$

(el termino de perturbacion no sigue un esquema autoregresivo de orden 1)

$$H_1: \rho > 0 \text{ para valores observados de } d < 2$$

$$\text{y } \rho < 0 \text{ para valores observados de } d > 2$$

Siendo el estadístico $d = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_{t=1}^n e_t^2} \sim Dn, k$; siendo n las observaciones de la muestra y k el numero de variables explicativas del modelo además de la constante.

Podemos observar de la regresión realizada, que el valor observado del estadístico de Durbin y Watson es 0.548288 y si se utiliza un nivel de significación

del 0.05, 80 observaciones y k es 4; los valores críticos son $d_l=1.560$ y $d_u=1.715$. Por lo que podemos concluir que se debe rechazar la hipótesis nula, confirmándose la existencia de autocorrelación positiva de primer orden con un $\rho > 0$.

d) ¿Se llega a la misma conclusión del inciso anterior aplicando los contrastes de **Breusch y Godfrey** y **Ljung y Box**?

El primer test sirve para detectar autocorrelación de cualquier orden en modelos con variable dependiente retardada o modelos ARMA, siguiendo los siguientes pasos:

- 1) Estimar por MCO y obtener los residuos.
- 2) Analizar los correlogramas obtenidos de los residuos para determinar el orden p de la parte AR (p) y el orden q de la parte MA(q), si existiera.
- 3) Estimar la regresión por MCO de los residuos obtenidos sobre p términos AR y q términos MA, según corresponda.
- 4) Calcular el estadístico chi-cuadrado con las siguientes hipótesis:
 H_0 : ausencia de autocorrelación.
 H_1 : autocorrelación según el esquema ARMA hallado.
El estadístico se obtiene de la siguiente manera: $(n - p)R^2 \rightarrow \chi^2_p$.
- 5) Comparar el valor observado con el crítico y se decide siguiendo una regla de decisión para la prueba unilateral derecha.

Ya obtenido la estimación por mínimos cuadrados ordinarios podemos obtener el siguiente correlograma de residuos:

Date: 10/13/24 Time: 16:56
Sample: 2016M01 2022M09
Included observations: 81

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob	
		1	0.719	0.719	43.504	0.000
		2	0.542	0.050	68.491	0.000
		3	0.479	0.150	88.232	0.000
		4	0.288	-0.244	95.494	0.000
		5	0.148	-0.049	97.422	0.000
		6	0.127	0.084	98.866	0.000
		7	-0.013	-0.192	98.881	0.000
		8	-0.015	0.194	98.901	0.000
		9	-0.010	-0.097	98.910	0.000
		10	-0.099	-0.082	99.847	0.000
		11	-0.060	0.128	100.19	0.000
		12	-0.018	-0.056	100.22	0.000
		13	-0.183	-0.275	103.53	0.000
		14	-0.218	-0.036	108.32	0.000
		15	-0.226	-0.068	113.54	0.000
		16	-0.277	0.081	121.46	0.000
		17	-0.244	0.003	127.74	0.000
		18	-0.169	0.066	130.80	0.000
		19	-0.175	-0.023	134.13	0.000
		20	-0.159	-0.201	136.90	0.000
		21	-0.199	-0.152	141.35	0.000
		22	-0.243	-0.041	148.09	0.000
		23	-0.247	-0.116	155.17	0.000
		24	-0.221	0.120	160.92	0.000
		25	-0.263	-0.065	169.23	0.000
		26	-0.215	0.060	174.86	0.000
		27	-0.151	0.017	177.70	0.000
		28	-0.044	0.135	177.96	0.000
		29	0.001	-0.147	177.96	0.000
		30	0.055	-0.082	178.36	0.000
		31	0.063	-0.094	178.90	0.000
		32	0.032	-0.083	179.04	0.000
		33	0.020	0.137	179.10	0.000
		34	0.024	0.010	179.18	0.000
		35	0.008	0.046	179.18	0.000
		36	0.038	-0.058	179.40	0.000

Gráfico 6

Correlograma

Nota. Tomado de pons.wf

Analizando FAC Y FAP podemos observar un modelo con $AR(p)$ con FAC es decreciente y una FAP con p rezagos significativamente distintos de cero. Determinado de esta manera que la función de autocorrelación parcial presenta un único rezago significativo, por lo que podemos concluir la existencia de un modelo con $AR(1)$. Por otro lado, al realizar una prueba de autocorrelación serial de LM test se obtiene:

Test Equation:
 Dependent Variable: RESID
 Method: Least Squares
 Date: 10/13/24 Time: 17:57
 Sample: 2016M01 2022M09
 Included observations: 81
 Presample missing value lagged residuals set to zero.

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	1.06E+08	86727853	1.218793	0.2267
PBI	-346.8032	300.2169	-1.155175	0.2516
INFLACION	-73745.99	1815212.	-0.040627	0.9677
TC	-5414655.	5145524.	-1.052304	0.2960
RESID(-1)	0.742327	0.079529	9.334045	0.0000
R-squared	0.534098	Mean dependent var	9.84E-09	
Adjusted R-squared	0.509577	S.D. dependent var	31071280	
S.E. of regression	21759288	Akaike info criterion	36.68872	
Sum squared resid	3.60E+16	Schwarz criterion	36.83653	
Log likelihood	-1480.893	Hannan-Quinn criter.	36.74802	
F-statistic	21.78110	Durbin-Watson stat	2.165372	
Prob(F-statistic)	0.000000			

Gráfico 7

Estimación por mínimos cuadrados ordinarios.

Nota. Tomado de pons.wf

El cual nos permite calcular el estadístico $(81 - 1) * 0.534098 = 42.72784$. Se plantean las siguientes hipótesis:

H0: ausencia de autocorrelacion.

H1: autocorrelacion segun el esquema ARMA hallado.

Teniendo en cuenta que es una prueba unilateral chi-cuadrado podemos obtener su valor critico con un nivel de significancia del 0.05, el cual será: 3.84. Al comparar el valor observado con el crítico, llegamos a la conclusión que se debe rechazar la hipótesis nula, por lo que estamos en presencia de autocorrelación de primer orden.

Por otro lado, también se puede realizar la prueba de Ljung- Box, el cual sirve para muestras grandes y modelos ARIMA; se pueden plantear las siguientes hipótesis:

H0: independencia de errores $\rho_1 = \rho_2 = \dots = \rho_m = 0$

H1: autocorrelacion de los errores.

Y el estadístico es el siguiente: $Q = n(n + 2) \sum_{k=1}^m \frac{r^2(k)}{n-k} \sim \chi^2_m$

Podemos utilizar para esta prueba el correlograma siguiente:

Date: 10/13/24 Time: 18:20

Sample: 2016M01 2022M09

Included observations: 81













Autocorrelation	Partial Correlation		AC	PAC	Q-Stat	Prob
		1	0.719	0.719	43.504	0.000
		2	0.542	0.050	68.491	0.000
		3	0.479	0.150	88.232	0.000
		4	0.288	-0.244	95.494	0.000
		5	0.148	-0.049	97.422	0.000
		6	0.127	0.084	98.866	0.000
		7	-0.013	-0.192	98.881	0.000
		8	-0.015	0.194	98.901	0.000
		9	-0.010	-0.097	98.910	0.000
		10	-0.099	-0.082	99.847	0.000
		11	-0.060	0.128	100.19	0.000
		12	-0.018	-0.056	100.22	0.000
		13	-0.183	-0.275	103.53	0.000
		14	-0.218	-0.036	108.32	0.000
		15	-0.226	-0.068	113.54	0.000
		16	-0.277	0.081	121.46	0.000
		17	-0.244	0.003	127.74	0.000
		18	-0.169	0.066	130.80	0.000
		19	-0.175	-0.023	134.13	0.000
		20	-0.159	-0.201	136.90	0.000
		21	-0.199	-0.152	141.35	0.000
		22	-0.243	-0.041	148.09	0.000
		23	-0.247	-0.116	155.17	0.000
		24	-0.221	0.120	160.92	0.000
		25	-0.263	-0.065	169.23	0.000
		26	-0.215	0.060	174.86	0.000
		27	-0.151	0.017	177.70	0.000
		28	-0.044	0.135	177.96	0.000
		29	0.001	-0.147	177.96	0.000
		30	0.055	-0.082	178.36	0.000
		31	0.063	-0.094	178.90	0.000
		32	0.032	-0.083	179.04	0.000
		33	0.020	0.137	179.10	0.000
		34	0.024	0.010	179.18	0.000
		35	0.008	0.046	179.18	0.000
		36	0.038	-0.058	179.40	0.000

Gráfico 8

Correlograma

Nota. Tomado de pons.wf

El cual nos permite observar que las probabilidades son cero o cercanas a cero (al usar mayor precisión en los decimales), por lo que se puede concluir que se debe rechazar la hipótesis nula, es decir que si existe autocorrelación de los errores.

- e) Aplicar el método iterativo de **Cochrane y Orcutt** para tratar de corregir la autocorrelación. Comentar los resultados. ¿Siguió habiendo autocorrelación? ¿Qué resulta sospechoso a la luz de los resultados? ¿Qué problema tiene la aplicación de la técnica de Cochrane y Orcutt en este caso? **Ayuda:** En la resolución del ejercicio 3.4 de Pérez López

(2006) se muestra cómo se puede aplicar en forma directa la técnica de Cochrane y Orcutt con EViews. También puede ser útil el ejemplo para corregir correlación serial incluido en las páginas 329-330 del documento "EViews Illustrated", disponible entre los PDF Docs del menú de ayuda de EViews. En ambos materiales también hay ayuda para comprender el problema de aplicar Cochrane y Orcutt en este caso.

El método de Cochrane y Orcutt permite corregir autocorrelación en modelos de regresión lineales, se debe aplicar cuando los errores se encuentran correlacionados a lo largo del tiempo, por lo que viola los supuestos de mínimos cuadrados ordinarios.

Luego de realizar la regresión teniendo en cuenta un retardo AR (1), se nota que los valores de los coeficientes han cambiado ampliamente, siendo que esto no debería haber ocurrido, por ejemplo, para la variable PBI su coeficiente es -251.6443 mientras que antes era 78.75042 igualmente ocurre con las demás variables, en las cuales no solo cambian los números sino también los signos. También se da que anteriormente algunas variables no son significativas (no le agregan poder explicativo al modelo) como lo son el PBI, y el TC, con p-value 0.8564 y 0.6784 respectivamente.

Al realizar la estimación con un rezago podemos observar el valor del coeficiente de Durbin Watson con el fin de poder determinar si se sigue dando autocorrelación. Al ser el valor observado 2.013258 y los valores críticos $dl = 1.534$ y $du = 1.743$ con un nivel de significación del 0.05 se puede determinar que ya no existe autocorrelación.

Aunque al realizar la prueba evidenciamos cambios importantes en los coeficientes podemos concluir que no es una buena especificación del modelo, demostrando que posiblemente los errores estándar son sesgados (subestimados o sobrestimados).

Dependent Variable: M2
Method: ARMA Maximum Likelihood (BFGS)
Date: 10/15/24 Time: 19:14
Sample: 2016M01 2022M09
Included observations: 81
Convergence achieved after 7 iterations
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	3.71E+08	2.93E+08	1.266297	0.2093
PBI	-251.6443	1182.425	-0.212820	0.8320
INFLACION	-1247146.	1873346.	-0.665732	0.5076
TC	11202953	9577757.	1.169684	0.2458
AR(1)	0.831841	0.065837	12.63480	0.0000
SIGMASQ	3.83E+14	5.62E+13	6.806760	0.0000
R-squared	0.658599	Mean dependent var	3.62E+08	
Adjusted R-squared	0.635839	S.D. dependent var	33689704	
S.E. of regression	20330300	Akaike info criterion	36.57885	
Sum squared resid	3.10E+16	Schwarz criterion	36.75621	
Log likelihood	-1475.443	Hannan-Quinn criter.	36.65001	
F-statistic	28.93664	Durbin-Watson stat	2.013258	
Prob(F-statistic)	0.000000			

Inverted AR Roots .83

Grafico 9

Método iterativo de Cochrane y Orcutt.

Nota. Tomado de pons.wf

- f) Indagar sobre el método de errores estándares robustos frente a heterocedasticidad y autocorrelación (HAC) de **Newey y West** y aplicarlo a la estimación del modelo original. Comentar los resultados. ¿Qué diferencias evidentes tiene esta alternativa frente a la del inciso anterior?

Los errores estándar de White corregidos mediante heteroscedasticidad también se conocen como errores estándar robustos, mientras que el procedimiento de Newey-West sirve para corregir los errores estándar de MCO, no sólo para situaciones de autocorrelación, sino también para casos de heteroscedasticidad, pues el método HAC puede abordar ambos casos, a diferencia del método White, diseñado específicamente para la heteroscedasticidad.

Dependent Variable: M2
Method: Least Squares
Date: 10/15/24 Time: 21:11
Sample: 2016M01 2022M09
Included observations: 81
HAC standard errors & covariance (Bartlett kernel, Newey-West fixed bandwidth = 4.0000)

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	3.85E+08	1.60E+08	2.406496	0.0185
PBI	78.75042	495.9270	0.158794	0.8742
INFLACION	-8158113.	3243606.	-2.515137	0.0140
TC	-3096995.	11915053	-0.259923	0.7956
R-squared	0.149403	Mean dependent var	3.62E+08	
Adjusted R-squared	0.116263	S.D. dependent var	33689704	
S.E. of regression	31670781	Akaike info criterion	37.42781	
Sum squared resid	7.72E+16	Schwarz criterion	37.54605	
Log likelihood	-1511.826	Hannan-Quinn criter.	37.47525	
F-statistic	4.508215	Durbin-Watson stat	0.548288	
Prob(F-statistic)	0.005747	Wald F-statistic	2.273829	
Prob(Wald F-statistic)	0.086637			

Gráfico 10

Método de Newey- West

Nota. Tomado de pons.wf

Al utilizar el método HAC podemos observar que los valores de los coeficientes de cada una de las variables permanecieron iguales que los originales, mientras que los errores estándar han variado, dando indicios de que los errores estándar sean sesgados (**subestimado o sobreestimado**) por lo que al aplicar métodos como el Cochrane y Orcutt dieran como resultado estimaciones de los coeficientes ampliamente distintas.

Por lo que es probable que haya problemas de heterocedasticidad o autocorrelación en el modelo original el cual generara que los errores estándar sean sesgados, llevando que los estimadores no tengan varianza mínima. Evidenciando que esta conclusión va en la misma línea que la del inciso anterior.

Ejercicio 4 (4 de 20 puntos)

Dado el siguiente sistema de **ecuaciones simultáneas**:

$$\begin{aligned}
 Y_{1t} + \beta_{12} Y_{2t} + \gamma_{11} + \gamma_{12} X_{2t} + \gamma_{14} X_{4t} &= \mu_{1t} \\
 \beta_{21} Y_{1t} + Y_{2t} + \gamma_{21} + \gamma_{23} X_{3t} + \gamma_{24} X_{4t} &= \mu_{2t}
 \end{aligned}$$

en donde las (Y, X) son variables endógenas y exógenas, respectivamente.

- a) Examinar las **condiciones de identificación** de cada una de las ecuaciones del modelo.

En relación con las condiciones de identificación de los modelos, podemos destacar dos. La primera es la **condición de orden**, la cual es necesaria, pero no suficiente para garantizar la identificación del modelo. La segunda es la **condición de rango**, que se considera tanto necesaria como suficiente. A continuación, se presentan detalles sobre cada una de estas condiciones:

Condición de orden: En un modelo de M ecuaciones simultáneas, para que una ecuación esté identificada, el número de variables predeterminadas excluidas de la ecuación no debe ser menor al número de variables endógenas incluidas en la ecuación menos uno.

$$K - k \geq m - 1$$

Donde K es el número de variables predeterminadas en el modelo, k el número de predeterminadas incluidas en la ecuación y m el número de endógenas que participan en la ecuación.

La regla de decisión a tener en cuenta es la siguiente:

$$K - k = m - 1 \quad \text{ecuación exactamente identificada}$$

$$K - k < m - 1 \quad \text{ecuación no identificada}$$

$$K - k > m - 1 \quad \text{ecuación sobreidentificada}$$

Si analizamos nuestro modelo, tenemos 4 variables predeterminadas (K), a saber (la constante, X_{2T} , X_{3T} , X_{4T}).

- **Ecuación 1:** tiene 3 variables predeterminadas y 2 variables endógenas.

$$4 - 3 = 1 = 2 - 1 \quad \text{ecuación exactamente identificada}$$

- **Ecuación 2:** tiene 3 variables predeterminadas y 2 variables endógenas.

$$4 - 3 = 1 = 2 - 1 \quad \text{ecuación exactamente identificada}$$

Condición de rango: En un modelo que contiene M ecuaciones y M variables endógenas, una ecuación está identificada si y solo si puede construirse por lo menos un determinante diferente de cero de orden (M-1)(M-1), a partir de los coeficientes de las variables endógenas y predeterminadas excluidas de esa ecuación particular, pero incluidas en las otras ecuaciones del modelo.

Para aplicar esta condición debemos armar la siguiente matriz

$$\begin{bmatrix} Y_{1T} & Y_{2T} & 1 & X_{2T} & X_{3T} & X_{4T} \\ 1 & \beta_{12} & \gamma_{11} & \gamma_{12} & 0 & \gamma_{14} \\ \beta_{21} & 1 & \gamma_{21} & 0 & \gamma_{23} & \gamma_{24} \end{bmatrix}$$

Para analizar la condición de rango de la ecuación número 1, eliminamos la fila correspondiente a dicha ecuación, así como todas las columnas asociadas a las variables incluidas en ella. Esto da lugar a la siguiente matriz escalar:

$$\begin{bmatrix} X_{3T} \\ \gamma_{23} \end{bmatrix}$$

Debemos encontrar por lo menos un determinante distinto de cero de orden (M-1)(M-1) es decir: 1x1. En este caso **la primera ecuación está identificada** ya que tenemos una

matriz conformada por un escalar cuyo determinante es el mismo escalar, que además es distinto de cero = γ_{23} .

Para analizar la ecuación número dos, procederemos de igual forma y obtenemos la siguiente matriz escalar:

$$\begin{bmatrix} X_{2T} \\ \gamma_{12} \end{bmatrix}$$

Debemos encontrar por lo menos un determinante distinto de cero de orden (M-1)(M-1) es decir: 1x1. Por lo que **podemos decir que la segunda ecuación también está identificada** ya que tenemos una matriz conformada por un escalar cuyo determinante es el mismo escalar, que además es distinto de cero = γ_{12} .

- b) Representar el modelo en la **forma matricial** $BY_t + \Gamma X_t = \mu_t$, identificando claramente los elementos que componen cada una de las matrices y vectores. Luego, obtener la **forma reducida** operando matricialmente.

En las ecuaciones de este ejercicio, reordenamos términos sumando y restando en ambos lados de las igualdades, con el objetivo de facilitar su representación matricial. Para obtener la forma reducida, colocamos todas las variables endógenas en el lado izquierdo, de modo que dependan exclusivamente de las variables exógenas y de los términos de perturbación aleatoria. De esta manera, se llega al siguiente sistema de ecuaciones:

$$\begin{aligned} Y_{1t} + \beta_{12} Y_{2t} &= -\gamma_{11} - \gamma_{12} X_{2t} + 0X_{3t} - \gamma_{14} X_{4t} + \mu_{1t} \\ \beta_{21} Y_{1t} + Y_{2t} &= -\gamma_{21} - 0X_{2t} - \gamma_{23} X_{3t} - \gamma_{24} X_{4t} + \mu_{2t} \end{aligned}$$

Expresando de manera matricial:

$$\begin{bmatrix} 1 & \beta_{12} \\ \beta_{21} & 1 \end{bmatrix} \begin{bmatrix} Y_{1t} \\ Y_{2t} \end{bmatrix} = \begin{bmatrix} -\gamma_{11} & -\gamma_{12} & 0 & -\gamma_{14} \\ -\gamma_{21} & 0 & -\gamma_{23} & -\gamma_{24} \end{bmatrix} \begin{bmatrix} 1 \\ X_{2t} \\ X_{3t} \\ X_{4t} \end{bmatrix} + \begin{bmatrix} \mu_{1t} \\ \mu_{2t} \end{bmatrix}$$

A continuación, explicitamos rango y componentes de cada matriz, a saber:

Matriz B

Una matriz de orden 2x2 de coeficientes de las variables endógenas.

$$\begin{bmatrix} 1 & \beta_{12} \\ \beta_{21} & 1 \end{bmatrix}$$

Matriz Y

Un vector de orden 2x1 de variables endógenas del sistema.

$$\begin{bmatrix} Y_{1t} \\ Y_{2t} \end{bmatrix}$$

Matriz Γ

Una matriz de orden 2x4 de coeficientes de las variables exógenas

$$\begin{bmatrix} -\gamma_{11} & -\gamma_{12} & 0 & -\gamma_{14} \\ -\gamma_{21} & 0 & -\gamma_{23} & -\gamma_{24} \end{bmatrix}$$

Matriz X

Un vector de orden 4x1 de variables exógenas.

$$\begin{bmatrix} 1 \\ X_{2t} \\ X_{3t} \\ X_{4t} \end{bmatrix}$$

Matriz μ

Vector de orden 2x1 que contiene las perturbaciones aleatorias de cada una de las ecuaciones del sistema.

$$\begin{bmatrix} \mu_{1t} \\ \mu_{2t} \end{bmatrix}$$

Para obtener la forma reducida debemos alcanzar la siguiente ecuación:

$$Y_t = B^{-1}(-\Gamma)X_t + B^{-1}\mu_t \quad (1)$$

Lo que es equivalente a expresar:

$$Y_t = \Pi_t X_t + v$$

Para ello debemos encontrar la matriz B^{-1} :

$$B^{-1} = \frac{\text{Adj. } B^T}{\det B}$$

Donde

- el $\det(B) = 1 - \beta_{12}\beta_{21}$
- $\text{Adj. } B^T = \begin{bmatrix} 1 & -\beta_{12} \\ -\beta_{21} & 1 \end{bmatrix}$

Por lo tanto, la matriz B^{-1} es

$$B^{-1} = \begin{bmatrix} \frac{1}{(1-\beta_{12}\beta_{21})} & \frac{-\beta_{12}}{(1-\beta_{12}\beta_{21})} \\ \frac{-\beta_{21}}{(1-\beta_{12}\beta_{21})} & \frac{1}{(1-\beta_{12}\beta_{21})} \end{bmatrix}$$

Reemplazando en (1) lo obtenido recientemente y expresando todos los términos en forma matricial, queda:

$$\begin{bmatrix} Y_{1t} \\ Y_{2t} \end{bmatrix} = \frac{1}{(1 - \beta_{12}\beta_{21})} \begin{bmatrix} 1 & -\beta_{12} \\ -\beta_{21} & 1 \end{bmatrix} \begin{bmatrix} -\gamma_{11} & -\gamma_{12} & 0 & -\gamma_{14} \\ -\gamma_{21} & 0 & -\gamma_{23} & -\gamma_{24} \end{bmatrix} \begin{bmatrix} 1 \\ X_{2t} \\ X_{3t} \\ X_{4t} \end{bmatrix} + \frac{1}{(1 - \beta_{12}\beta_{21})} \begin{bmatrix} 1 & -\beta_{12} \\ -\beta_{21} & 1 \end{bmatrix} \begin{bmatrix} \mu_{1t} \\ \mu_{2t} \end{bmatrix}$$

Haciendo producto de matrices en cada termino, se llega a la ecuación de la forma reducida:

$$\begin{bmatrix} Y_{1t} \\ Y_{2t} \end{bmatrix} = \frac{1}{(1 - \beta_{12}\beta_{21})} \begin{bmatrix} -\gamma_{11} + \beta_{12}\gamma_{21} & -\gamma_{12} & \beta_{12}\gamma_{23} & -\gamma_{14} + \beta_{12}\gamma_{24} \\ \beta_{21}\gamma_{11} - \gamma_{21} & \beta_{21}\gamma_{12} & -\gamma_{23} & \beta_{21}\gamma_{14} - \gamma_{24} \end{bmatrix} \begin{bmatrix} 1 \\ X_{2t} \\ X_{3t} \\ X_{4t} \end{bmatrix} + \frac{1}{(1 - \beta_{12}\beta_{21})} \begin{bmatrix} \mu_{1t} - \mu_{2t}\beta_{12} \\ -\beta_{21}\mu_{1t} + \mu_{2t} \end{bmatrix}$$

Es decir, hemos obtenido:

$$Y_t = \Pi_t X_t + v$$

Que se puede desarmar en dos ecuaciones reducidas, que son en esencia, reexpresión del modelo estructural de manera tal que las variables endógenas quedaron exclusivamente en función de exógenas y errores aleatorios.

$$Y_{1t} = \frac{\beta_{12}\gamma_{21} - \gamma_{11}}{1 - \beta_{12}\beta_{21}} - \frac{\gamma_{12}}{1 - \beta_{12}\beta_{21}} X_{2t} + \frac{\beta_{12}\gamma_{23}}{1 - \beta_{12}\beta_{21}} X_{3t} + \frac{\beta_{12}\gamma_{24} - \gamma_{14}}{1 - \beta_{12}\beta_{21}} X_{4t} + \frac{\mu_{1t} - \mu_{2t}\beta_{12}}{1 - \beta_{12}\beta_{21}}$$

$$Y_{2t} = \frac{\beta_{21}\gamma_{11} - \gamma_{21}}{1 - \beta_{12}\beta_{21}} + \frac{\beta_{21}\gamma_{12}}{1 - \beta_{12}\beta_{21}} - \frac{\gamma_{23}}{1 - \beta_{12}\beta_{21}} + \frac{\beta_{21}\gamma_{14} - \gamma_{24}}{1 - \beta_{12}\beta_{21}} + \frac{-\beta_{21}\mu_{1t} + \mu_{2t}}{1 - \beta_{12}\beta_{21}}$$

c) Al estimar por mínimos cuadrados ordinarios (MCO) los parámetros de la **forma reducida** se obtuvo el siguiente resultado:

$$\hat{\Pi} = \begin{bmatrix} -1.489362 & -1.063830 & 1.914894 & -3.191489 \\ -0.851064 & 0.106383 & -3.191489 & -4.680851 \end{bmatrix}$$

Aplicar y describir detalladamente el procedimiento para estimar los parámetros de la **forma estructural** por **mínimos cuadrados indirectos** (MCI) mediante la resolución de la ecuación matricial $\hat{B}\hat{\Pi} + \hat{\Gamma} = \emptyset$, en donde $\emptyset$ es una matriz nula conformable. Analizar la relación existente entre los cálculos aquí planteados y el punto a) sobre identificación.

Se estiman los parámetros de la forma estructural por MCI:

$$1) -1.489362 = \frac{\beta_{12}\gamma_{21} - \gamma_{11}}{1 - \beta_{12}\beta_{21}}$$

$$2) -1.063830 = \frac{-\gamma_{12}}{1 - \beta_{12}\beta_{21}}$$

$$3) 1.914894 = \frac{\beta_{12}\gamma_{23}}{1 - \beta_{12}\beta_{21}}$$

$$4) -3.191489 = \frac{\beta_{12}\gamma_{24} - \gamma_{14}}{1 - \beta_{12}\beta_{21}}$$

$$5) -0.851064 = \frac{\beta_{21}\gamma_{11} - \gamma_{21}}{1 - \beta_{12}\beta_{21}}$$

$$6) 0.106383 = \frac{\beta_{21}\gamma_{12}}{1 - \beta_{12}\beta_{21}}$$

$$7) -3.191489 = \frac{-\gamma_{23}}{1 - \beta_{12}\beta_{21}}$$

$$8) -4.680851 = \frac{\beta_{12}\gamma_{14} - \gamma_{24}}{1 - \beta_{12}\beta_{21}}$$

Sistema de 8 incógnitas ($\gamma_{11}, \gamma_{12}, \gamma_{14}, \gamma_{21}, \gamma_{23}, \gamma_{24}, \beta_{12}, \beta_{21}$) con 8 ecuaciones en base a los coeficientes de la forma reducida ($\widehat{\pi}_{11}, \widehat{\pi}_{12}, \widehat{\pi}_{13}, \widehat{\pi}_{14}, \widehat{\pi}_{21}, \widehat{\pi}_{22}, \widehat{\pi}_{23}, \widehat{\pi}_{24}$), por lo tanto pueden identificarse, el sistema es compatible y por lo tanto tiene solución.

Se continua resolviendo a partir de la ecuación $B\widehat{\Pi} + \Gamma = \emptyset$

Si se resta Γ de ambos lados y multiplicamos por B^{-1} obtenemos:

$$\widehat{\Pi} = -B^{-1} - \Gamma$$

Al resolver la ecuación se llegan a las 8 ecuaciones obtenidas anteriormente. A partir de las mismas, se trabaja hasta alcanzar todos los valores de los coeficientes.

Primero se dividen las ecuaciones 3 y 7:

$$\frac{3}{7} = \frac{1.914894}{-3.191489} = \frac{\beta_{12}\gamma_{23}}{\gamma_{23}} = \beta_{12} = \mathbf{0,60000019}$$

Luego se repiten los mismos pasos para las ecuaciones 2 y 6:

$$\frac{2}{6} = \frac{-1.063830}{0.106383} = \frac{-\gamma_{12}}{\beta_{21}\gamma_{12}} = \beta_{21} = \mathbf{0,1}$$

A partir de los valores obtenidos anteriormente, se obtiene el valor del denominador que tienen todas las ecuaciones:

$$(1 - \beta_{12}\beta_{21}) = (1 - 0.6 * 0.1) = 0.94$$

De la ecuación 7, reemplazando los valores obtenidos anteriormente, se logra llegar al valor de γ_{23} :

$$-3.191489 * 0.94 = -\gamma_{23}$$

$$\gamma_{23} = \mathbf{2.999}$$

De la ecuación 2, reemplazando los valores obtenidos anteriormente, se puede llegar al valor de γ_{12} :

$$-1.063830 * 0.94 = -\gamma_{12}$$

$$\gamma_{12} = \mathbf{1}$$

De 1:

$$-1.489362 * 0.94 = -\gamma_{11} + 0.6 \gamma_{21}$$

$$\gamma_{11} = 1.40000028 + 0.6\gamma_{21} \quad (1')$$

De 5:

$$-0.851064 * 0.94 = 0.1\gamma_{11} - \gamma_{21}$$

Se reemplaza en la ecuación anterior lo obtenido en (1'):

$$-0.80000016 = 0.1 * (1.40000028 + 0.6\gamma_{21}) - \gamma_{21}$$

Despejando y resolviendo se llega a que:

$$\gamma_{21} = \mathbf{1.0000002}$$

Reemplazando el valor de γ_{21} en la ecuación (1') se obtiene:

$$\gamma_{11} = \mathbf{2.0000004}$$

De la ecuación 4, despejando se llega a:

$$\gamma_{14} = 3.191489 * 0.94 + 0.6\gamma_{24} = 2.999 + 0.6\gamma_{24} \quad (*)$$

Y de la ecuación 8, despejando:

$$\gamma_{24} = 4.680851 * 0.94 + 0.1\gamma_{14}$$

Reemplazando en la ecuación anterior lo obtenido en (*)

$$\gamma_{24} = 4.680851 * 0.94 + 0.1 * (2.999 + 0.6\gamma_{24})$$

Despejando y resolviendo se llega al valor de γ_{24}

$$\gamma_{24} = \mathbf{4.999893553}$$

Utilizando el valor al cual se llegó anteriormente se obtiene el valor de γ_{14} a partir de la ecuación (*), por lo tanto:

$$\gamma_{14} = \mathbf{5.998936132}$$

De esta manera fue como se lograron llegar a las estimaciones de los parámetros estructurales.

d) Tratar de rehacer el punto anterior, pero suponiendo ahora que el modelo tiene la siguiente estructura:

$$Y_{1t} + \beta_{12} Y_{2t} + \gamma_{11} + \gamma_{12} X_{2t} + \gamma_{14} X_{4t} = \mu_{1t}$$

$$\beta_{21} Y_{1t} + Y_{2t} + \gamma_{21} + \gamma_{23} X_{3t} = \mu_{2t}$$

¿Se obtienen estimaciones únicas o múltiples de los parámetros de la forma estructural? Explicar detalladamente por qué y proponer una técnica de estimación apropiada para este caso particular.

Condición de orden:

- **Ecuación 1:** tiene 3 variables predeterminadas y 2 variables endógenas.
 $4 - 3 = 1 = 2 - 1$ *ecuación exactamente identificada*
- **Ecuación 2:** tiene 2 variables predeterminadas y 2 variables endógenas.
 $4 - 2 = 2 > 1 = 2 - 1$ *ecuación sobreidentificada.*

Condición de rango:

$$Y_{1t} + \beta_{12} Y_{2t} + \gamma_{11} + \gamma_{12} X_{2t} + \gamma_{14} X_{4t} = \mu_{1t}$$

$$\beta_{21} Y_{1t} + Y_{2t} + \gamma_{21} + \gamma_{23} X_{3t} = \mu_{2t}$$

$$\begin{bmatrix} Y_{1t} & Y_{2t} & 1 & X_{2t} & X_{3t} & X_{4t} \\ 1 & \beta_{12} & \gamma_{11} & \gamma_{12} & 0 & \gamma_{14} \\ \beta_{21} & 1 & \gamma_{21} & 0 & \gamma_{23} & 0 \end{bmatrix}$$

Ecuación 1:

$$\begin{bmatrix} Y_{1t} & Y_{2t} & 1 & X_{2t} & X_{3t} & X_{4t} \\ \beta_{21} & 1 & \gamma_{21} & 0 & \gamma_{23} & 0 \end{bmatrix}$$

$$\begin{bmatrix} X_{3t} \\ \gamma_{23} \end{bmatrix}$$

Si se quiere encontrar el determinante de la matriz anterior, puede notarse que la matriz es un escalar, por lo cual su determinante será el propio escalar.

Al obtener un determinante distinto de cero puede, por lo tanto, determinarse una ecuación como identificada.

Ecuación 2:

$$\begin{bmatrix} Y_{1t} & Y_{2t} & 1 & X_{2t} & X_{3t} & X_{4t} \\ 1 & \beta_{12} & \gamma_{11} & \gamma_{12} & 0 & \gamma_{14} \end{bmatrix}$$

$$\begin{bmatrix} X_{2t} & X_{4t} \\ \gamma_{12} & \gamma_{14} \end{bmatrix}$$

Como puede notarse, nos quedan dos determinantes para dos ecuaciones. Cada determinante proviene de una matriz de orden 1×1 , lo cual es correcto, pues las matrices deben ser de orden $(M-1)$, y aquí $M=2$. Por ende, se sabe que el determinante de un escalar es el propio escalar, y efectivamente la ecuación está identificada.

Con esto puede concluirse que no es factible realizar una estimación de los parámetros de la forma estructural mediante el Método de Mínimos Cuadrados Indirectos porque, por la condición de orden sabemos que la ecuación 2 está sobreidentificada, entonces al estimar los coeficientes, obtendremos múltiples estimaciones para un mismo parámetro.

Para este caso en particular, puede establecerse otro método de estimación, ya que no puede llegarse a un valor único para cada parámetro mediante el Método de Mínimos

Cuadrados Indirectos. Una técnica viable es mediante el Método de Variables Instrumentales, en el cual, para el caso de la ecuación sobreestimada se pueden utilizar promedios ponderados de los instrumentos, ya que se encontraría el caso en el que existen más instrumentos de los necesarios; otra forma sería utilizar como instrumentos a los valores ajustados de las variables endógenas, que surgen de estimar la forma reducida del modelo. Otra manera factible sería estimar mediante el Método de Mínimos Cuadrados en dos Etapas, el cual consiste en reemplazar las variables endógenas del lado derecho de la ecuación por sus valores ajustados obtenidos de estimar por MCO ecuación por ecuación de la forma reducida. En lugar de usar los valores ajustados como instrumentos, se utilizan como regresores, pero las estimaciones resultan idénticas al método de Variables Instrumentales.

Bibliografía:

Gujarati, D. N., & Porter, D. C. (2010). *Econometría* (5a ed.). McGraw-Hill Interamericana.

López, C. P. (2006). *Problemas resueltos de econometría*. Thomson.

Harvey, A. C. (1990).

Moneta Pizarro, A. M. *Notas de cátedra de econometría I*. Editorial Económicas, Universidad Nacional de Córdoba