



FACULTAD
DE CIENCIAS
ECONÓMICAS

Econometría II

Primer semestre 2025

Trabajo práctico grupal N° 2

Cátedra: Moneta Pizarro

Integrantes grupo 6:

ARIAS, Maria Pia (45348034)

FERIOZZI, Candela (45091097)

LOSANO, Julieta (45405384)

ROMERO PAVANI, Francisco (42358355)

Trabajo Grupal Segunda Parte

Consignas generales

- Elaborar y entregar la resolución en un documento de **Word** (.docx) en el buzón de la tarea del aula virtual.
- El nombre del archivo debe tener el siguiente formato: **Trabajo2_GrupoXX**, en donde XX es el número del grupo.
- No hace falta que cada integrante del grupo realice la entrega por separado porque la plataforma está configurada para que pueda hacer la entrega **uno solo en representación de todo el equipo**.
- Reproducir las **consignas** de cada ejercicio intercaladas en la resolución. Esto facilitará luego la corrección.
- En todos los ejercicios se pide **trabajar con R** (o RStudio). No obstante, quienes se animen pueden agregar el código alternativo de **Python**.
- Los códigos (*scripts*) de R (obligatorios) y de Python (opcionales) utilizados deben estar insertados en el documento de Word en forma de **porciones de código** (*chunks*) que se distingan claramente de las salidas (editadas) y del resto del texto de las respuestas.
- Se recomienda la elaboración de una **portada** y un **índice**, también la **numeración de las páginas** y, en forma consecutiva, de las **tablas y figuras**.
- Es muy importante apoyar las respuestas, especialmente las teóricas, en **referencias bibliográficas** y citar en forma correcta la bibliografía utilizada. Incluir una sección final destinada a las referencias bibliográficas citadas en el texto. Utilizar el sistema de [citas](#) y [referencias](#) de las **normas APA 7ª. Edición**.
- **Plazo máximo de entrega:** miércoles **5 de junio** (inclusive).

Ejercicio de la unidad 4

Resolver el **ejercicio 11.3.7** de las páginas 467 y 468 del libro de [Judge, G. G., Hill, R. C., Griffiths, W. E., Luetkepohl, H. y Lee, T. C. \(1988\), Introduction to the Theory and Practice of Econometrics, Second Edition, Wiley, New York.](#)

Explicar primero en forma breve, pero cuidadosamente, la **interpretación económica** de las diferentes restricciones que se plantean en dicho libro de texto. ¿Qué supuestos sobre el comportamiento del consumidor implican estas restricciones?

Algunas **referencias bibliográficas** importantes que analizan detalladamente el sentido microeconómico de las restricciones son:

- Fernández de Castro, J. y Tugores Ques, J. (1997), Microeconomía, McGrawHill, Madrid. Se puede ubicar como: T 338.5 – F 45415 en la Biblioteca Manuel Belgrano.

· [Layard, P.R.G. y Walters, A.A. \(1978\), Microeconomic Theory, McGrawHill, New York, Cap. 5.](#)

· [Silberberg, E. y Suen, W. \(1990\), The Structure of Economics – A Mathematical Analysis, McGrawHill, New York.](#)

Luego, resolver **con ayuda de R** los ítems del ejercicio indicados en el libro teniendo en cuenta, además, lo siguiente:

- Para el ítem b), indagar por qué los autores piden estimar el modelo irrestricto por OLS y el restringido por SUR (¿son comparables?), en lugar de estimar el mismo modelo por ambos métodos. Explicar qué ocurriría haciendo esto último. ¿Es el mismo modelo el que estimamos? o son modelos distintos? son comparables?
- En el ítem c), tener cuidado con los residuos que se utilicen para el contraste.
- En el punto d), si recurren a la función `linear.hypothesis` de R o alguna de sus variantes para poner a prueba la validez de las restricciones, entonces cuidado con la opción utilizada para el argumento `test`. Considerar la advertencia que hacen los autores del libro sobre este asunto.

Implicancias de las restricciones sobre los parámetros impuestas al modelo:

1. **Condición de Engel: se gasta todo el presupuesto**
 - Identidad básica del presupuesto: $\sum p_i q_i = y$.
 - Si el ingreso sube 1 %, el gasto total debe subir también 1 %. Por eso la suma ponderada de las elasticidades-ingreso (usando las participaciones de gasto w_i) debe ser uno: $\sum w_i \beta_{i4} = 1$.
 - Supuestos implícitos:
 - El consumidor no ahorra dentro del período estudiado.
 - Las demandas varían de manera continua y diferenciable con el ingreso.
2. **Homogeneidad de grado cero: importan los precios relativos y el poder de compra**
 - Propiedad: $q_i(t p, t y) = q_i(p, y)$. Duplicar todos los precios y el ingreso no cambia las cantidades demandadas.
 - En forma log-lineal esto impone que los coeficientes de precios e ingreso sumen cero en cada ecuación: $\beta_{i1} + \beta_{i2} + \beta_{i3} + \beta_{i4} = 0$.
 - Supuesto clave: el consumidor carece de ilusión monetaria; decide en función de precios **relativos** y de su ingreso **real**, no de valores nominales.
3. **Simetría de Slutsky: reciprocidad en los efectos de sustitución**
 - El efecto de variar el precio del bien j sobre la demanda del bien i debe ser idéntico (ajustado por w_i y w_j) al efecto inverso: $\beta_{ij} / w_j = \beta_{ji} / w_i$ (con $i \neq j$).
 - Supuestos detrás de la simetría:
 - Existe una función de utilidad bien comportada (continua, convexa y dos veces diferenciable).
 - Los efectos de sustitución son consistentes y la matriz de Slutsky es simétrica y negativa semidefinida.

Imponer estas restricciones implica que el sistema econométrico, aparte de ajustarse a los datos, respeta las bases de la teoría del consumidor. Esto permite que los resultados tales como las elasticidades y efectos cruzados que se obtienen pueden interpretarse como reflejos reales de la elección racional de los mismos. Las tres restricciones clásicas —la condición de Engel, la homogeneidad de grado cero y la simetría de Slutsky, garantizan que el modelo represente a una persona que maximiza su utilidad con un presupuesto limitado.

Ejercicio 11.3.7

a)

$$\underbrace{\begin{bmatrix} 0 & 1 & 1 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 1 & 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 1 & 1 & 1 \\ 0 & 0 & 1/w_2 & 0 & 1 & 0 & -1/w_1 & 0 & 0 & -1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1/w_3 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & -1/w_1 & 0 & 0 & -1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1/w_3 & 1 & 0 & 0 & -1/w_2 & 0 & -1 \\ 0 & 0 & 0 & 0 & w_1 & 0 & 0 & 0 & 0 & w_2 & 0 & 0 & 0 & 0 & w_3 \end{bmatrix}}_R \begin{bmatrix} \beta_{10} \\ \beta_{11} \\ \beta_{12} \\ \beta_{13} \\ \beta_{14} \\ \beta_{20} \\ \beta_{21} \\ \beta_{22} \\ \beta_{23} \\ \beta_{24} \\ \beta_{30} \\ \beta_{31} \\ \beta_{32} \\ \beta_{33} \\ \beta_{34} \end{bmatrix} = \underbrace{\begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}}_r$$

b) En esta unidad, debido a que analizamos los modelos SUR, empezamos nuestro recorrido estimando un sistema de ecuaciones de demanda y comparando entre dos métodos, por un lado MCO y por otro lado el método SUR.

MCO SCRIPT:

```
#como primer paso nos aseguramos de haber cargado bien la base.
exists("Tabla_11_3_Judge_1988_")
#directamente llamamos a la tabla como datos para simplificar la
notación del código

datos <- data.frame(
  lnq1 = log(Tabla_11_3_Judge_1988_$q1),
  lnq2 = log(Tabla_11_3_Judge_1988_$q2),
  lnq3 = log(Tabla_11_3_Judge_1988_$q3),
  ln p1 = log(Tabla_11_3_Judge_1988_$p1),
  ln p2 = log(Tabla_11_3_Judge_1988_$p2),
  ln p3 = log(Tabla_11_3_Judge_1988_$p3),
  ln y = log(Tabla_11_3_Judge_1988_$y)
)
```

```

install.packages("systemfit")

library(systemfit)

eq1 <- lnq1 ~ lnp1 + lnp2 + lnp3 + lny
eq2 <- lnq2 ~ lnp1 + lnp2 + lnp3 + lny
eq3 <- lnq3 ~ lnp1 + lnp2 + lnp3 + lny

sistema_ec <- list(
  ecuacion1 = eq1,
  ecuacion2 = eq2,
  ecuacion3 = eq3
)

modelo_mco <- systemfit(sistema_ec, method = "OLS", data = datos)

summary(modelo_mco)

```

SALIDA DE CONSOLA:

```

> #como primer paso nos aseguramos de haber cargado bien la base.
> exists("Tabla_11_3_Judge_1988_")
[1] TRUE
> datos <- data.frame(
+   lnq1 = log(Tabla_11_3_Judge_1988_$q1),
+   lnq2 = log(Tabla_11_3_Judge_1988_$q2),
+   lnq3 = log(Tabla_11_3_Judge_1988_$q3),
+   lnp1 = log(Tabla_11_3_Judge_1988_$p1),
+   lnp2 = log(Tabla_11_3_Judge_1988_$p2),
+   lnp3 = log(Tabla_11_3_Judge_1988_$p3),
+   lny  = log(Tabla_11_3_Judge_1988_$y)
+ )
> library(systemfit)
> eq1 <- lnq1 ~ lnp1 + lnp2 + lnp3 + lny
> eq2 <- lnq2 ~ lnp1 + lnp2 + lnp3 + lny
> eq3 <- lnq3 ~ lnp1 + lnp2 + lnp3 + lny
> sistema_ec <- list(
+   ecuacion1 = eq1,
+   ecuacion2 = eq2,
+   ecuacion3 = eq3
+ )
> modelo_mco <- systemfit(sistema_ec, method = "OLS", data = datos)
> summary(modelo_mco)

```

systemfit results
method: OLS

	N	DF	SSR	detRCov	OLS-R2	McElroy-R2
system	90	75	9.76762	0.000131	0.713936	0.982341

	N	DF	SSR	MSE	RMSE	R2	Adj R2
ecuacion1	30	25	3.847074	0.153883	0.392279	0.654497	0.599217
ecuacion2	30	25	5.236240	0.209450	0.457657	0.561826	0.491718
ecuacion3	30	25	0.684307	0.027372	0.165446	0.938128	0.928228

The covariance matrix of the residuals

	ecuacion1	ecuacion2	ecuacion3
ecuacion1	0.1538830	-0.0144478	-0.0468902
ecuacion2	-0.0144478	0.2094496	-0.0388696
ecuacion3	-0.0468902	-0.0388696	0.0273723

The correlations of the residuals

	ecuacion1	ecuacion2	ecuacion3
ecuacion1	1.0000000	-0.0804761	-0.722489
ecuacion2	-0.0804761	1.0000000	-0.513352
ecuacion3	-0.7224894	-0.5133520	1.000000

OLS estimates for 'ecuacion1' (equation 1)

Model Formula: $\ln q_1 \sim \ln p_1 + \ln p_2 + \ln p_3 + \ln y$

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-4.8569518	1.5059379	-3.22520	0.0034932 **
lnp1	-0.5729425	0.2200483	-2.60371	0.0152952 *
lnp2	0.0724907	0.1683398	0.43062	0.6704338
lnp3	-0.2033165	0.1382473	-1.47067	0.1538550
lny	1.4265101	0.2276915	6.26510	1.4846e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.392279 on 25 degrees of freedom

Number of observations: 30 Degrees of Freedom: 25

SSR: 3.847074 MSE: 0.153883 Root MSE: 0.392279

Multiple R-Squared: 0.654497 Adjusted R-Squared: 0.599217

OLS estimates for 'ecuacion2' (equation 2)

Model Formula: $\ln q_2 \sim \ln p_1 + \ln p_2 + \ln p_3 + \ln y$

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-4.311034	1.756918	-2.45375	0.02145119 *
lnp1	0.190879	0.256722	0.74353	0.46409384
lnp2	-0.632340	0.196395	-3.21973	0.00354045 **

```

lnp3      0.135133    0.161288    0.83784 0.41006037
lny       1.140617    0.265639    4.29387 0.00023225 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.457657 on 25 degrees of freedom
Number of observations: 30 Degrees of Freedom: 25
SSR: 5.23624 MSE: 0.20945 Root MSE: 0.457657
Multiple R-Squared: 0.561826 Adjusted R-Squared: 0.491718

OLS estimates for 'ecuacion3' (equation 3)
Model Formula: lny ~ lnp1 + lnp2 + lnp3 + lny

              Estimate Std. Error   t value   Pr(>|t|)
(Intercept)  1.0165905   0.6351368    1.60059   0.122031
lnp1         -0.2503892   0.0928065   -2.69797   0.012316 *
lnp2         -0.1442914   0.0709981   -2.03233   0.052873 .
lnp3         -0.9651710   0.0583065  -16.55341 5.5511e-15 ***
lny          0.8797076   0.0960300    9.16076 1.8239e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.165446 on 25 degrees of freedom
Number of observations: 30 Degrees of Freedom: 25
SSR: 0.684307 MSE: 0.027372 Root MSE: 0.165446

```

INTERPRETACIÓN:

En todos los modelos estimados se puede ver efectivamente la relación negativa con el precio de ese bien demandado (a través de sus coeficientes), pues cuando aumenta el precio del bien su demanda cae haciendo referencia a la ley de demanda. Por otro lado es importante ver los R^2 ya que nos indican la proporción de variabilidad que es explicada por las variables independientes del modelo; teniendo en cuenta que el modelo 3 sería el mejor explicado bajo este criterio, pues un 93.81% de la demanda del bien 3 es explicado por las variables planteadas en el propio modelo. Asimismo, consideramos la interpretación de los coeficientes como elasticidades, ya que hemos transformado el modelo a logaritmos.

Vemos las interpretaciones ecuación por ecuación:

- Ecuación 1: el coeficiente del ingreso (1.427) indica una elasticidad ingreso positiva y significativa, es decir, es un bien de lujo (elasticidad >1). Por otro lado, el coeficiente del precio del bien dos es no significativo, lo que sugiere que el bien dos no afecta significativamente a las cantidades del bien uno.
- Ecuación 2: vemos que también es un bien de lujo (elasticidad ingreso positiva 1.141) y observamos que es significativamente sensible a su propio precio pero no está claro que lo sea a los demás
- Ecuación 3: a diferencia de los otros dos bienes, es un bien normal (lo sabemos debido a su elasticidad ingreso menor a uno), asimismo presenta una fuertísima elasticidad precio propia (-0.965).

Un último comentario que hacemos al respecto de la salida anterior, es en relación a la correlación negativa de los residuos, en particular nos pone en alerta la resultada en rojo,

frente a la cual prendemos todas las luces porque una correlación residual alta implica que hay información compartida entre las ecuaciones, implicando que cuando el modelo sobreestima o subestima la demanda del bien 1 tiende a sobreestimar o subestimar la del bien 3. Este hecho justifica la adopción de un estimador más eficiente, como lo es el SUR.

SUR SCRIPT:

```
#antes cargamos el paquete
install.packages("systemfit")
library(systemfit)

#METODO SUR PORQUE SOSPECHAMOS QUE POSIBLEMENTE DEPENDAN DE VBLES NO
OBSERVADAS COMUNES A AMBAS ECUACIONES(RESTRICCIONES)

#restricciones del modelo de demanda
w1 <- mean(Tabla_11_3_Judge_1988_$p1 * Tabla_11_3_Judge_1988_$q1 /
Tabla_11_3_Judge_1988_$y)
w2 <- mean(Tabla_11_3_Judge_1988_$p2 * Tabla_11_3_Judge_1988_$q2 /
Tabla_11_3_Judge_1988_$y)
w3 <- mean(Tabla_11_3_Judge_1988_$p3 * Tabla_11_3_Judge_1988_$q3 /
Tabla_11_3_Judge_1988_$y)

#creamos restricciones a continuación

# Hay 15 coeficientes: 5 por ecuación (constante, lnp1, lnp2, lnp3, lny)
R <- matrix(0, nrow = 7, ncol = 15)
q <- matrix(0, nrow = 7, ncol = 1)

# Restricciones de homogeneidad
R[1, 2:4] <- 1 # eq1: beta11 + beta12 + beta13
R[2, 7:9] <- 1 # eq2
R[3, 12:14] <- 1 # eq3

# Restricciones de simetría (igualdad entre parámetros cruzados
ajustados por w y beta_4)
R[4, 3] <- 1 / w2 # beta12
R[4, 14] <- -1 # -beta34
R[4, 9] <- -1 / w1 # -beta21
R[4, 4] <- 1 # beta14

R[5, 4] <- 1 / w3
R[5, 13] <- -1
R[5, 10] <- -1 / w1
R[5, 5] <- 1
```



```

R[6, 9] <- 1 / w3
R[6, 5] <- 1
R[6, 14] <- -1 / w2
R[6, 10] <- -1

# Restricción de Engel
R[7, c(5,10,15)] <- c(w1, w2, w3)
q[7,1] <- 1

#estimación SUR con restricciones

SUR_restringido <- systemfit(sistema_ec, method = "SUR", data = datos,
restrict.matrix = R, restrict.rhs = q)
summary(SUR_restringido)

```

SALIDA DE CONSOLA:

```

#METODO SUR PORQUE SOSPECHAMOS QUE POSIBLEMENTE DEPENDAN DE VBLES NO
OBSERVADAS COMUNES A AMBAS ECUACIONES(RESTRICCIONES)
>
>
> #restricciones del modelo de demanda
> w1 <- mean(Tabla_11_3_Judge_1988_$p1 * Tabla_11_3_Judge_1988_$q1 /
Tabla_11_3_Judge_1988_$y)
> w2 <- mean(Tabla_11_3_Judge_1988_$p2 * Tabla_11_3_Judge_1988_$q2 /
Tabla_11_3_Judge_1988_$y)
> w3 <- mean(Tabla_11_3_Judge_1988_$p3 * Tabla_11_3_Judge_1988_$q3 /
Tabla_11_3_Judge_1988_$y)
>
> #creamos restricciones a continuación
>
> # Hay 15 coeficientes: 5 por ecuación (constante, lnp1, lnp2, lnp3,
lny)
> R <- matrix(0, nrow = 7, ncol = 15)
> q <- matrix(0, nrow = 7, ncol = 1)
>
> # Restricciones de homogeneidad
> R[1, 2:4] <- 1 # eq1: beta11 + beta12 + beta13
> R[2, 7:9] <- 1 # eq2
> R[3, 12:14] <- 1 # eq3
>
> # Restricciones de simetría (igualdad entre parámetros cruzados
ajustados por w y beta_4)
> R[4, 3] <- 1 / w2 # beta12

```

```

> R[4, 14] <- -1          # -beta34
> R[4, 9] <- -1 / w1      # -beta21
> R[4, 4] <- 1            # beta14
>
> R[5, 4] <- 1 / w3
> R[5, 13] <- -1
> R[5, 10] <- -1 / w1
> R[5, 5] <- 1
>
> R[6, 9] <- 1 / w3
> R[6, 5] <- 1
> R[6, 14] <- -1 / w2
> R[6, 10] <- -1
>
> # Restricción de Engel
> R[7, c(5,10,15)] <- c(w1, w2, w3)
> q[7,1] <- 1
>
> #estimación SUR con restricciones

> SUR_restringido <- systemfit(sistema_ec, method = "SUR", data = datos,
restrict.matrix = R, restrict.rhs = q)
> summary(SUR_restringido)

```

systemfit results

method: SUR

	N	DF	SSR	detRCov	OLS-R2	McElroy-R2
system	90	82	23.3326	0.02052	0.316659	0.387059

	N	DF	SSR	MSE	RMSE	R2	Adj R2
eq1	30	25	5.20798	0.200307	0.447557	0.532275	0.478307
eq2	30	25	7.13767	0.274526	0.523952	0.402712	0.333794
eq3	30	25	10.98691	0.422574	0.650057	0.006608	-0.108015

The covariance matrix of the residuals used for estimation

	eq1	eq2	eq3
eq1	0.19206822	0.00126614	0.0615218
eq2	0.00126614	0.28067744	-0.0538430
eq3	0.06152176	-0.05384296	0.4209614

The covariance matrix of the residuals

	eq1	eq2	eq3
eq1	0.20030711	-0.00845113	0.0871500
eq2	-0.00845113	0.27452586	-0.0586032
eq3	0.08715005	-0.05860316	0.4225735

The correlations of the residuals

	eq1	eq2	eq3
eq1	1.0000000	-0.0360392	0.299549
eq2	-0.0360392	1.0000000	-0.172059
eq3	0.2995493	-0.1720594	1.000000

SUR estimates for 'eq1' (equation 1)

Model Formula: $\ln q_1 \sim \ln p_1 + \ln p_2 + \ln p_3 + \ln y$

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-6.0489063	1.3621618	-4.44067	2.7758e-05 ***
lnp1	-0.2010881	0.1286409	-1.56317	0.12186
lnp2	0.0534735	0.0906656	0.58979	0.55695
lnp3	0.1476146	0.1287345	1.14666	0.25486
lny	1.3892017	0.2280168	6.09254	3.4456e-08 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.447557 on 25 degrees of freedom

Number of observations: 30 Degrees of Freedom: 25

SSR: 5.207985 MSE: 0.200307 Root MSE: 0.447557

Multiple R-Squared: 0.532275 Adjusted R-Squared: 0.478307

SUR estimates for 'eq2' (equation 2)

Model Formula: $\ln q_2 \sim \ln p_1 + \ln p_2 + \ln p_3 + \ln y$

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.4128160	0.4409329	-0.93623	0.3519024
lnp1	0.4126379	0.1705691	2.41918	0.0177682 *
lnp2	-0.4926131	0.1702751	-2.89304	0.0048851 **
lnp3	0.0799752	0.1246192	0.64176	0.5228210
lny	0.3837547	0.0722363	5.31249	9.0969e-07 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.523952 on 25 degrees of freedom

Number of observations: 30 Degrees of Freedom: 25

SSR: 7.137672 MSE: 0.274526 Root MSE: 0.523952

Multiple R-Squared: 0.402712 Adjusted R-Squared: 0.333794

SUR estimates for 'eq3' (equation 3)

Model Formula: $\ln q_3 \sim \ln p_1 + \ln p_2 + \ln p_3 + \ln y$

```

              Estimate Std. Error  t value   Pr(>|t|)
(Intercept) -2.4297483  0.4945390 -4.91316 4.5150e-06 ***
lnp1         0.1304123  0.1951577  0.66824  0.50586
lnp2        -0.2816284  0.1875135 -1.50191  0.13696
lnp3         0.1512161  0.0357903  4.22506 6.1553e-05 ***
lny          1.0058350  0.0805730 12.48352 < 2.22e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.650057 on 25 degrees of freedom
Number of observations: 30 Degrees of Freedom: 25
SSR: 10.986911 MSE: 0.422574 Root MSE: 0.650057
Multiple R-Squared: 0.006608 Adjusted R-Squared: -0.108015

```

Estimamos el modelo con el método sur, sospechando y observando en la salida anterior que los errores están correlacionados entre sí, esto es bastante intuitivo y tiene sentido, ya que hay shocks que pueden estar afectando a varios bienes a la vez, es decir, variables explicativas (que dejamos fuera del modelo) COMUNES a todos los bienes, por ejemplo pueden ser políticas de precios, las cuales no afectan a un solo bien sino a una canasta de bienes, por lo que nos parece un interesante valor agregado tener en cuenta esto. La cuestión primordial radica en que a pesar de usar SUR, que es un modelo más eficiente teóricamente, se obtuvo un peor resultado en términos de ajuste. Sin embargo, sería un error caer en esta mala lectura del panorama, simplemente porque no son dos modelos comparables entre sí. Pasando en limpio, estimamos el modelo irrestricto por MCO porque no impone restricciones y todas las ecuaciones tienen las mismas variables explicativas, por lo tanto no hay ganancia al tratarlo como un sistema con SUR: en ese caso, MCO y SUR producen estimadores idénticos. En cambio, el modelo restringido incorpora restricciones teóricas (homogeneidad, simetría, Engel) que vinculan parámetros entre ecuaciones, y esto sólo puede imponerse correctamente mediante SUR, que realiza el sistema completo.

Por lo tanto, no estimamos el mismo modelo dos veces, sino dos modelos diferentes: uno más empírico (el que es irrestricto) y otro más teórico (el restringido). La comparación entre ambos no debe ser cuál "ajusta mejor", sino que deberíamos buscar evaluar si las restricciones teóricas son compatibles con los datos.

c)

TEST DE CORRELACIÓN CONTEMPORÁNEA

Siguiendo el libro de Judge (1988) y sus fórmulas para poder encontrar el lambda de este test tenemos que:

SCRIPT:

```
# Estimación por MCO con restricciones:

modelo_mco_rest <- systemfit(sistema_ec, method = "OLS", data = datos,
restrict.matrix = R, restrict.rhs = q )
summary(modelo_mco_rest)

# guardamos los residuos:
residuos_mcoRest <- resid(modelo_mco_rest); residuos_mcoRest

# Extraemos los residuos de cada restriccion:
res1 <- residuos_mcoRest[, 1]
res2 <- residuos_mcoRest[, 2]
res3 <- residuos_mcoRest[, 3]

# Calculamos las varianzas de esos residuos:
s11 <- var(res1)
s22 <- var(res2)
s33 <- var(res3)

# Calculamos las covarianzas entre ellas:
s12 <- cov(res1, res2)
s13 <- cov(res1, res3)
s23 <- cov(res2, res3)

# Calculamos las correlaciones al cuadrado r^2:
r12_2 <- ((s12) / (s11 * s22))^2
r13_2 <- ((s13) / (s11 * s33))^2
r23_2 <- ((s23) / (s22 * s33))^2

#armamos el estadístico del multiplicador de lagrange:
suma_rs <- (r12_2 + r13_2 + r23_2)
lambda <- (30*(suma_rs))
lambda
```

SALIDA DE CONSOLA:

```
# Estimación por MCO con restricciones:

> modelo_mco_rest <- systemfit(sistema_ec, method = "OLS", data = datos,
restrict.matrix = R, restrict.rhs = q )
> summary(modelo_mco_rest)

systemfit results
```

method: OLS

	N	DF	SSR	detRCov	OLS-R2	McElroy-R2
system	90	82	23.2364	0.021065	0.319476	0.383385

	N	DF	SSR	MSE	RMSE	R2	Adj R2
ecuacion1	30	25	4.99377	0.192068	0.438256	0.551513	0.499765
ecuacion2	30	25	7.29761	0.280677	0.529790	0.389328	0.318866
ecuacion3	30	25	10.94500	0.420961	0.648815	0.010397	-0.103788

The covariance matrix of the residuals

	ecuacion1	ecuacion2	ecuacion3
ecuacion1	0.19206822	0.00126614	0.0615218
ecuacion2	0.00126614	0.28067744	-0.0538430
ecuacion3	0.06152176	-0.05384296	0.4209614

The correlations of the residuals

	ecuacion1	ecuacion2	ecuacion3
ecuacion1	1.00000000	0.00545319	0.216361
ecuacion2	0.00545319	1.00000000	-0.156640
ecuacion3	0.21636144	-0.15664049	1.000000

OLS estimates for 'ecuacion1' (equation 1)

Model Formula: $\ln q_1 \sim \ln p_1 + \ln p_2 + \ln p_3 + \ln y$

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5.702839	1.678669	-3.39724	0.0010524 **
lnp1	-0.156377	0.151248	-1.03391	0.3042158
lnp2	0.077505	0.102471	0.75636	0.4516004
lnp3	0.078872	0.160553	0.49125	0.6245596
lny	1.330394	0.280919	4.73586	9.0221e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.438256 on 25 degrees of freedom

Number of observations: 30 Degrees of Freedom: 25

SSR: 4.993774 MSE: 0.192068 Root MSE: 0.438256

Multiple R-Squared: 0.551513 Adjusted R-Squared: 0.499765

OLS estimates for 'ecuacion2' (equation 2)

Model Formula: $\ln q_2 \sim \ln p_1 + \ln p_2 + \ln p_3 + \ln y$

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.1581993	0.5037015	-0.31407	0.754263
lnp1	0.4121116	0.1734863	2.37547	0.019860 *
lnp2	-0.5139620	0.1739223	-2.95512	0.004079 **
lnp3	0.1018504	0.1385934	0.73489	0.464505
lny	0.3409579	0.0826633	4.12466	8.8522e-05 ***

```

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.52979 on 25 degrees of freedom
Number of observations: 30 Degrees of Freedom: 25
SSR: 7.297613 MSE: 0.280677 Root MSE: 0.52979
Multiple R-Squared: 0.389328 Adjusted R-Squared: 0.318866

OLS estimates for 'ecuacion3' (equation 3)
Model Formula: lnq3 ~ ln p1 + ln p2 + ln p3 + ln y

      Estimate Std. Error  t value  Pr(>|t|)
(Intercept) -2.5803430   0.5970646 -4.32171 4.3188e-05 ***
lnp1         0.0794561   0.1618872  0.49081 0.62487067
lnp2        -0.2329525   0.1578679 -1.47562 0.14387654
lnp3         0.1534964   0.0418161  3.67075 0.00042921 ***
lny          1.0324786   0.0986668 10.46430 < 2.22e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.648815 on 25 degrees of freedom
Number of observations: 30 Degrees of Freedom: 25
SSR: 10.944996 MSE: 0.420961 Root MSE: 0.648815
Multiple R-Squared: 0.010397 Adjusted R-Squared: -0.103788

> # guardamos los residuos:
> residuos_mcoRest <- resid(modelo_mco_rest); residuos_mcoRest
      ecuacion1  ecuacion2  ecuacion3
1  0.0282648688  0.225761482 -0.11675100
2  0.3513684225 -1.174033822 -0.96758842
3 -0.3819111371 -0.418252777  0.75452397
4  0.3284862695  0.140577824  0.93902022
5 -0.8213263323  0.406619870 -0.94486271
6  0.0504133146  0.464888214 -0.88744479
7  0.2513866244  0.873581278  0.23569847
8  0.6297160240 -0.817326539  0.70958373
9 -0.1010471574  0.327380904 -0.24837661
10 -0.1681070102  0.211538502  0.82212723
11 -0.2182298401  0.065198213 -0.47892182
12 -0.4217319695  0.049108014 -0.44453062
13 -0.0004389387  0.488144603 -0.50933384
14  0.4414051111 -0.542654632  0.28562217
15 -0.1443900255 -0.205528053  0.40690124
16  0.3580930394  0.594333733  0.01531313
17 -0.5715547563 -0.197402112 -0.17715322
18  0.1756619301  0.224986265  1.22297288
19 -0.4292476055  0.495439484 -0.34753745
20 -0.3017461860  0.211413317 -0.77640077
21  0.0710500233  0.020558416  0.82945922

```

```

22 -0.1186059315 -0.701480870 0.41278338
23 0.8514761905 0.599759880 0.06820506
24 0.2214489738 0.073872417 -0.05425219
25 -0.6736025475 -0.331852033 -0.07455264
26 -0.1070902178 -1.184621069 0.28521313
27 0.6744763592 0.001648337 0.36089867
28 0.2238192784 0.099263715 -0.44738931
29 0.3780534262 0.081462689 -1.03583702
30 -0.5760902001 -0.082385247 0.16260989

```

```

> # Extraemos los residuos de cada restriccion:
> res1 <- residuos_mcoRest[, 1]
> res2 <- residuos_mcoRest[, 2]
> res3 <- residuos_mcoRest[, 3]
> # Calculamos las varianzas de esos residuos:
> s11 <- var(res1)
> s22 <- var(res2)
> s33 <- var(res3)
> # Calculamos las covarianzas entre ellas:
> s12 <- cov(res1, res2)
> s13 <- cov(res1, res3)
> s23 <- cov(res2, res3)
> # Calculamos las correlaciones al cuadrado r^2:
> r12_2 <- ((s12) / (s11 * s22))^2
> r13_2 <- ((s13) / (s11 * s33))^2
> r23_2 <- ((s23) / (s22 * s33))^2
> #armamos el estadístico del multiplicador de lagrange:
> suma_rs <- (r12_2 + r13_2 + r23_2)
> lambda <- (30*(suma_rs))
> lambda
[1] 29.37996

```

Realizamos la prueba de correlación contemporánea con el principal objetivo de analizar si los mínimos cuadrados aplicados por separado a cada ecuación son totalmente eficientes o es necesario aplicar el estimador de regresión aparentemente no relacionada.

En este sentido, utilizando un estadístico de prueba adecuado como lo es el multiplicador de Lagrange determinamos la hipótesis nula (H_0) de que las tres covarianzas son iguales a cero, contra la alternativa (H_1) de que al menos una covarianza es distinta de cero, es decir, bajo hipótesis nula el estadístico tiene una distribución chi-cuadrado asintótica con tres grados de libertad ($M*(M-1)/2$), por lo tanto la H_0 se rechaza ya que lambda es mayor que el valor crítico ($= 7.815$), considerando un nivel de significancia de 0.05. Con eso se concluye en que al menos alguna de las covarianzas es distinta de cero. Por lo tanto, no da igual aplicar mínimos cuadrados por separado a cada ecuación que aplicar el estimador de regresión aparentemente no relacionada, en este sentido, hay una ganancia de eficiencia que debemos considerar.

d)

Comparamos la validez de las restricciones de la teoría de la demanda

SCRIPT:

```
#inciso d)
# Sumas de cuadrados de residuos
res_sinres <- resid(modelo_mco)
res_res <- resid(SUR_restringido)
SSR_sinres <- sum(res_sinres^2)
SSR_res <- sum(res_res^2)

# Grados de libertad
J <- 7 # Número de restricciones (Engel, Homogeneidad x3, Simetría x3)
N <- nrow(datos)
M <- 3
K <- length(coef(modelo_mco)) / M # Número de parámetros por ecuación
(5 en este caso)

# Estadístico F ( $\lambda_F$ )
lambda_F <- ((SSR_res - SSR_sinres)/J) / (SSR_sinres / (N*M - K*M))

# Valor crítico F al 5% de significancia
F_critico <- qf(0.95, J, N*M - K*M)

# Resultado
cat("Lambda_F:", lambda_F, "\nValor crítico F:", F_critico, "\n")

# Decisión:
if (lambda_F > F_critico) {
  cat("Rechazamos H0: las restricciones no son válidas.\n")
} else {
  cat("No se rechaza H0: las restricciones son válidas.\n")
}
```

SALIDA DE CONSOLA:

```
> #inciso d)
> # Sumas de cuadrados de residuos
> res_sinres <- resid(modelo_mco)
> res_res <- resid(SUR_restringido)
> SSR_sinres <- sum(res_sinres^2)
> SSR_res <- sum(res_res^2)
>
> # Grados de libertad
> J <- 7 # Número de restricciones (Engel, Homogeneidad x3, Simetría x3)
> N <- nrow(datos)
> M <- 3
> K <- length(coef(modelo_mco)) / M # Número de parámetros por ecuación (5 en
```

```

este caso)
>
> # Estadístico F ( $\lambda_F$ )
> lambda_F <- ((SSR_res - SSR_sinres)/J) / (SSR_sinres / (N*M - K*M))
>
> # Valor crítico F al 5% de significancia
> F_critico <- qf(0.95, J, N*M - K*M)
>
> # Resultado
> cat("Lambda_F:", lambda_F, "\nValor crítico F:", F_critico, "\n")
Lambda_F: 14.87964
Valor crítico F: 2.134314
>
> # Decisión:
> if (lambda_F > F_critico) {
+   cat("Rechazamos H0: las restricciones no son válidas.\n")
+ } else {
+   cat("No se rechaza H0: las restricciones son válidas.\n")
+ }
Rechazamos H0: las restricciones no son válidas.

```

En este punto del análisis, principalmente estamos contrastando si la teoría se cumple en la realidad, es decir, lo que llamamos análisis empírico.

Realizamos un análisis de restricciones lineales de los coeficientes, que tienen el valor agregado de imponer y probar restricciones que relacionan los coeficientes de una ecuación con los coeficientes de las demás, lo cual es de un especial interés en economía.

Para tal fin, calculamos un estadístico propuesto en Judge (1988) con distribución F (siempre y cuando los errores se comporten normal) que fue simple calcular ya que se puede demostrar que el denominador converge en probabilidad a uno.

Debido a que rechazamos la hipótesis nula, podemos decir que el comportamiento observado en nuestra base de datos no es totalmente compatible con las predicciones en la teoría microeconómica. Sugerimos que la teoría económica no tiene demasiada utilidad aplicada a estos datos, o dicho de otra manera, los datos no apoyan a las restricciones.

En la bibliografía de la materia observamos que la hipótesis nula se rechaza con menos frecuencia si se utiliza el divisor $T-(K/M)$, importante tenerlo en cuenta.

Restricciones por grupos, es decir, cada grupo por separado:

SCRIPT:

```

# A continuación realizamos la prueba por grupos, es decir, serian 3
tests,utilizando el mismo estadístico propuesto en la bibliografía

# Número de observaciones, ecuaciones y parámetros por ecuación
N <- nrow(datos)
M <- 3

```

```

K <- length(coef(modelo_mco)) / M

# Test de HOMOGENEIDAD (3 restricciones)
R_hom <- matrix(0, nrow = 3, ncol = 15)
R_hom[1, 2:4] <- 1      # eq1
R_hom[2, 7:9] <- 1      # eq2
R_hom[3, 12:14] <- 1    # eq3
q_hom <- matrix(0, nrow = 3, ncol = 1)

modelo_hom <- systemfit(sistema_ec, method = "SUR", data = datos,
                        restrict.matrix = R_hom, restrict.rhs = q_hom)
SSR_hom <- sum(resid(modelo_hom)^2)

lambdaF_hom <- ((SSR_hom - SSR_sinres)/3) / (SSR_sinres / (N*M - K*M))
F_crit <- qf(0.95, 3, N*M - K*M)
cat("Homogeneidad:\nLambda_F =", lambdaF_hom, " | F_crit =", F_crit,
    "\n")
if (lambdaF_hom > F_crit) {
  cat("⇒ Rechazamos H0: la homogeneidad no se cumple.\n\n")
} else {
  cat("⇒ No se rechaza H0: la homogeneidad se cumple.\n\n")
}

```

```

# Test de SIMETRÍA (3 restricciones)
R_sim <- matrix(0, nrow = 3, ncol = 15)
q_sim <- matrix(0, nrow = 3, ncol = 1)

```

```

R_sim[1, 3] <- 1 / w2
R_sim[1, 14] <- -1
R_sim[1, 9] <- -1 / w1
R_sim[1, 4] <- 1

R_sim[2, 4] <- 1 / w3
R_sim[2, 13] <- -1
R_sim[2, 10] <- -1 / w1
R_sim[2, 5] <- 1

R_sim[3, 9] <- 1 / w3
R_sim[3, 5] <- 1
R_sim[3, 14] <- -1 / w2
R_sim[3, 10] <- -1

```

```

modelo_sim <- systemfit(sistema_ec, method = "SUR", data = datos,

```

```

restrict.matrix = R_sim, restrict.rhs = q_sim)
SSR_sim <- sum(resid(modelo_sim)^2)

lambdaF_sim <- ((SSR_sim - SSR_sinres)/3) / (SSR_sinres / (N*M - K*M))
cat("Simetría:\nLambda_F =", lambdaF_sim, " | F_crit =", F_crit, "\n")
if (lambdaF_sim > F_crit) {
  cat("⇒Rechazamos H0: la simetría no se cumple.\n\n")
} else {
  cat("⇒No se rechaza H0: la simetría se cumple.\n\n")
}

```

```

# Test de la RESTRICCIÓN DE ENGEL (1 restricción)
R_engel <- matrix(0, nrow = 1, ncol = 15)
R_engel[1, c(5,10,15)] <- c(w1, w2, w3)
q_engel <- matrix(1, nrow = 1, ncol = 1)

modelo_engel <- systemfit(sistema_ec, method = "SUR", data = datos,
                          restrict.matrix = R_engel, restrict.rhs =
q_engel)
SSR_engel <- sum(resid(modelo_engel)^2)

lambdaF_engel <- ((SSR_engel - SSR_sinres)/1) / (SSR_sinres / (N*M -
K*M))
F_crit_1 <- qf(0.95, 1, N*M - K*M)
cat("Engel:\nLambda_F =", lambdaF_engel, " | F_crit =", F_crit_1, "\n")
if (lambdaF_engel > F_crit_1) {
  cat("⇒Rechazamos H0: la restricción de Engel no se cumple.\n\n")
} else {
  cat("⇒No se rechaza H0: la restricción de Engel se cumple.\n\n")
}

```

SALIDA DE CONSOLA:

```

> # A continuación realizamos la prueba por grupos, es decir, serian 3
tests,utilizando el mismo estadístico propuesto en la bibliografía

> # Número de observaciones, ecuaciones y parámetros por ecuación
> N <- nrow(datos)
> M <- 3
> K <- length(coef(modelo_mco)) / M
> # Test de HOMOGENEIDAD (3 restricciones)
> R_hom <- matrix(0, nrow = 3, ncol = 15)
> R_hom[1, 2:4] <- 1      # eq1
> R_hom[2, 7:9] <- 1      # eq2
> R_hom[3, 12:14] <- 1    # eq3
> q_hom <- matrix(0, nrow = 3, ncol = 1)

```

```

> modelo_hom <- systemfit(sistema_ec, method = "SUR", data = datos,
+                          restrict.matrix = R_hom, restrict.rhs = q_hom)
> SSR_hom <- sum(resid(modelo_hom)^2)
> lambdaF_hom <- ((SSR_hom - SSR_sinres)/3) / (SSR_sinres / (N*M - K*M))
> F_crit <- qf(0.95, 3, N*M - K*M)
> cat("Homogeneidad:\nLambda_F =", lambdaF_hom, " | F_crit =", F_crit,
"\n")
Homogeneidad:
Lambda_F = 8.578408 | F_crit = 2.726589
> if (lambdaF_hom > F_crit) {
+   cat("⇒Rechazamos H0: la homogeneidad no se cumple.\n\n")
+ } else {
+   cat("⇒No se rechaza H0: la homogeneidad se cumple.\n\n")
+ }
⇒Rechazamos H0: la homogeneidad no se cumple.

```

```

> # Test de SIMETRÍA (3 restricciones)
> R_sim <- matrix(0, nrow = 3, ncol = 15)
> q_sim <- matrix(0, nrow = 3, ncol = 1)
> R_sim[1, 3] <- 1 / w2
> R_sim[1, 14] <- -1
> R_sim[1, 9] <- -1 / w1
> R_sim[1, 4] <- 1
> R_sim[2, 4] <- 1 / w3
> R_sim[2, 13] <- -1
> R_sim[2, 10] <- -1 / w1
> R_sim[2, 5] <- 1
> R_sim[3, 9] <- 1 / w3
> R_sim[3, 5] <- 1
> R_sim[3, 14] <- -1 / w2
> R_sim[3, 10] <- -1
> modelo_sim <- systemfit(sistema_ec, method = "SUR", data =
datos,
+                          restrict.matrix = R_sim, restrict.rhs =
q_sim)
> SSR_sim <- sum(resid(modelo_sim)^2)
> lambdaF_sim <- ((SSR_sim - SSR_sinres)/3) / (SSR_sinres / (N*M -
K*M))
> cat("Simetría:\nLambda_F =", lambdaF_sim, " | F_crit =", F_crit,
"\n")
Simetría:
Lambda_F = 32.10208 | F_crit = 2.726589
> if (lambdaF_sim > F_crit) {

```

```

+   cat("⇒ Rechazamos H0: la simetría no se cumple.\n\n")
+ } else {
+   cat("⇒ No se rechaza H0: la simetría se cumple.\n\n")
+ }
⇒ Rechazamos H0: la simetría no se cumple.

```

```

> # Test de la RESTRICCIÓN DE ENGEL (1 restricción)
> R_engel <- matrix(0, nrow = 1, ncol = 15)
> R_engel[1, c(5,10,15)] <- c(w1, w2, w3)
> q_engel <- matrix(1, nrow = 1, ncol = 1)
> modelo_engel <- systemfit(sistema_ec, method = "SUR", data =
datos,
+                           restrict.matrix = R_engel, restrict.rhs
= q_engel)
> SSR_engel <- sum(resid(modelo_engel)^2)
> lambdaF_engel <- ((SSR_engel - SSR_sinres)/1) / (SSR_sinres /
(N*M - K*M))
> F_crit_1 <- qf(0.95, 1, N*M - K*M)
> cat("Engel:\nLambda_F =", lambdaF_engel, " | F_crit =",
F_crit_1, "\n")
Engel:
Lambda_F = 0.06630473 | F_crit = 3.968471
> if (lambdaF_engel > F_crit_1) {
+   cat("⇒ Rechazamos H0: la restricción de Engel no se
cumple.\n\n")
+ } else {
+   cat("⇒ No se rechaza H0: la restricción de Engel se
cumple.\n\n")
+ }
⇒ No se rechaza H0: la restricción de Engel se cumple.

```

El hecho de que la única restricción que se cumple sea la de Engel, implica que los datos respaldan el hecho de que los consumidores, en promedio, gastan todo su ingreso en estos tres bienes considerados, esto nos da un indicio de que el sistema demanda fue bien especificado con respecto al ingreso, aparte nos dice que no hay bienes relevantes que hayamos dejado afuera y si los hay su participación no es en lo absoluto importante.

Asimismo, debido a que la homogeneidad no se cumple, podemos conjeturar que los individuos tienen un considerable efecto ingreso, es decir, que cambios proporcionales en todos los precios e ingresos no traen aparejadas respuestas proporcionales por parte de los consumidores, probablemente sufran un engañoso efecto ingreso.

Por último, si la simetría no se cumple, nos da indicios de que los consumidores no se comportan de forma plenamente racional, porque los efectos cruzados no se comportan de manera recíproca.

Concluimos entonces que el modelo no representa a una persona que maximiza su utilidad con un presupuesto limitado o bien que no posee una función de utilidad bien definida (o comportada).

Ejercicio de la unidad 5

En base a los datos del ejemplo de **Kmenta** (1986), págs. 685-687, disponibles en el paquete systemfit de R, se pide:

- a) Verificar las **condiciones de orden y rango** para la identificación de cada una de las ecuaciones del modelo:

$$\text{consump} = b_1 + b_2 \text{ price} + b_3 \text{ income} + m_1$$

$$\text{consump} = b_4 + b_5 \text{ price} + b_6 \text{ farmPrice} + b_7 \text{ trend} + m_2$$

Siguiendo a Moneta Pizarro (2021) definimos la condición de orden y la de rango:

Condición de orden: En un modelo de M ecuaciones simultáneas, para que una ecuación esté identificada, el número de variables predeterminadas excluidas de la ecuación no debe ser menor al número de variables endógenas incluidas en la ecuación menos uno.

$$K - k \geq m - 1$$

Donde K es el número de variables predeterminadas en el modelo, k el número de predeterminadas incluidas en la ecuación y m el número de endógenas que participan en la ecuación.

La regla de decisión a tener en cuenta es la siguiente:

$$K - k = m - 1 \quad \text{Ecuación exactamente identificada.}$$

$$K - k > m - 1 \quad \text{Ecuación sobreidentificada.}$$

$$K - k < m - 1 \quad \text{Ecuación NO identificada.}$$

Analizando nuestro sistema, vemos que tenemos 4 variables predeterminadas (K), estas son: constante, income, farmPrice y trend.

- **Ecuación demanda:** Tiene 2 variables predeterminadas y 2 endógenas (consump y price). Por lo tanto:

$$4 - 2 = 2 > 1 = 2 - 1$$

La ecuación de demanda está sobreidentificada.

- **Ecuación oferta:** Tiene 3 variables predeterminadas y 2 endógenas. Entonces:

$$4 - 3 = 1 = 1 = 2 - 1$$

La ecuación de oferta está exactamente identificada.

Condición de rango: un modelo que contiene M ecuaciones y M variables endógenas, una ecuación está identificada si y sólo si puede construirse por lo menos un determinante diferente de cero de orden (M-1)(M-1), a partir de los coeficientes de las variables endógenas y predeterminadas excluidas de esa ecuación particular, pero incluidas en las otras ecuaciones del modelo.

Reexpresando el modelo como:

$$\begin{aligned} -\beta_1 + \text{consump} - \beta_2 \text{price} - \beta_3 \text{income} &= \mu_1 \\ -\beta_4 + \text{consump} - \beta_5 \text{price} - \beta_6 \text{farmPrice} - \beta_7 \text{trend} &= \mu_2 \end{aligned}$$

y escribiendo la matriz de coeficientes del modelo

1	consump	price	income	farmPrice	trend
$-\beta_1$	1	$-\beta_2$	$-\beta_3$	0	0
$-\beta_4$	1	$-\beta_5$	0	$-\beta_6$	$-\beta_7$

Representando la primera fila a los coeficientes de la ecuación demanda y la segunda fila a los de la ecuación oferta.

Para el caso de la ecuación demanda vemos que al eliminar la fila que la representa, y luego las columnas que en la misma son distintas de cero, el resultado es una matriz de (1x1) igual a $-\beta_3$. El determinante de la misma $|\beta_3|$ es distinto de cero por lo cual la ecuación de demanda está identificada.

En el caso de la ecuación de oferta, al eliminar la fila que la representa y luego eliminar las columnas que corresponden a esa fila que son distintas de cero, obtenemos como resultado una matriz (1x2) igual a $(-\beta_6 \quad -\beta_7)$ con la cual podemos armar dos matrices de orden (M-1xM-1) y verificar sus correspondientes determinantes. La primera es $|\beta_6|$ y la segunda $|\beta_7|$ teniendo ambos determinantes distintos de cero. Dado que al menos una de las matrices es distinta de cero, la ecuación de oferta se encuentra identificada.

En ambos casos se asume que los valores de los β_i son distintos de cero siguiendo los valores teóricos brindados para los mismos por la teoría económica.

b) Estimar por **OLS** los parámetros del modelo e interpretar los resultados.

SCRIPT:

```
library(systemfit)
data("Kmenta")
eqdemanda<- consump~price+income
eqoferta<- consump ~ price+ farmPrice +trend

eqsystem<- list(demanda = eqdemanda , oferta=eqoferta)

estOLS<- systemfit(eqsytem, data= Kmenta); summary(estOLS,
equations= FALSE)
```

SALIDA DE CONSOLA:

```
library(systemfit)
> data("Kmenta")
> eqdemanda<- consump~price+income
> eqoferta<- consump ~ price+ farmPrice +trend
>
> eqsystem<- list(demanda = eqdemanda , oferta=eqoferta)
>
> estOLS<- systemfit(eqsytem, data= Kmenta); summary(estOLS, equations= FALSE)

systemfit results
method: OLS

              N DF      SSR detRCov   OLS-R2 McElroy-R2
system 40 33 155.883 4.43485 0.709298 0.557559

              N DF      SSR      MSE      RMSE      R2      Adj R2
demanda 20 17 63.3317 3.72539 1.93013 0.763789 0.735999
oferta 20 16 92.5511 5.78444 2.40509 0.654807 0.590084

The covariance matrix of the residuals
      demanda oferta
demanda 3.72539 4.13696
oferta 4.13696 5.78444

The correlations of the residuals
      demanda oferta
demanda 1.000000 0.891179
oferta 0.891179 1.000000

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
demanda_(Intercept) 99.8954229 7.5193621 13.28509 2.0906e-10 ***
```

```

demanda_price      -0.3162988  0.0906774 -3.48818 0.00281529 **
demanda_income     0.3346356  0.0454218  7.36729 1.0999e-06 ***
oferta_(Intercept) 58.2754312 11.4629099  5.08383 0.00011056 ***
oferta_price       0.1603666  0.0948839  1.69013 0.11038810
oferta_farmPrice   0.2481333  0.0461879  5.37226 6.2274e-05 ***
oferta_trend       0.2483023  0.0975178  2.54623 0.02156713 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Interpretación: Observamos que el R^2 de McElroy es igual a 0,557559 lo cual nos indica un buen ajuste global.

Estimamos por método MCO ignorando el problema de la simultaneidad:

En el caso de la demanda, observamos que el coeficiente estimado del precio es igual a -0,3162988, con un p-value muy cercano a cero, lo cual nos indica que la variable precio es significativa para explicar la demanda. Además dicho coeficiente es negativo, lo cual nos indica la relación negativa existente entre cantidades demandadas y precio, es decir que cuando el precio aumenta, la demanda disminuye. Por otro lado, el parámetro estimado del ingreso es igual a 0.3346356, con un p-value también muy cercano a cero, por lo que es significativo para explicar la demanda. Vemos que existe una relación positiva entre ambas variables, es decir que cuando el ingreso aumenta, la demanda también lo hace.

En el caso de la oferta, observamos que el coeficiente estimado para la variable precio resulta positivo, lo cual se corresponde con la teoría (al aumentar el precio aumenta la oferta). Sin embargo, observando su p-value vemos que es igual a 0.11038810 y por lo tanto muy elevado, lo que nos llevaría a no rechazar la hipótesis nula de que dicho coeficiente es igual a cero y por ende dicha variable resulta no significativa para explicar la oferta. Por otro lado vemos que los otros dos coeficientes tienen un p-value bastante cercano a cero, por lo que sí resultan significativos para explicar la oferta, además ambos coeficientes poseen signo positivo. Por lo tanto, si aumenta el precio al productor, la oferta también aumenta, y además a medida que pasa el tiempo, la oferta aumentará (esto se puede deber a mejoras tecnológicas, por ejemplo).

c) Analizar la **correlación entre los residuos** de las dos ecuaciones y comentar los problemas de la estimación OLS para este caso.

De la salida anterior, observamos una fuerte correlación positiva entre los residuos de las funciones de oferta y demanda ($=0,891179$). Por lo tanto, además del problema de ecuaciones simultáneas, donde el precio que es una variable endógena aparece como variable explicativa, también tenemos el problema de que los errores de las dos ecuaciones están correlacionados, es decir, tenemos que las variables explicativas no contempladas en el modelo (términos de perturbación aleatoria) son COMUNES a ambas ecuaciones.

Como hemos visto en la teoría, estimar mediante MCO genera estimaciones ineficientes de los parámetros, es decir que estos no tienen varianza mínima, o que no son MELI.

d) Estimar el modelo aplicando el método **SUR**, comentar los resultados y las ventajas de este tipo de estimación respecto a la de OLS.

SCRIPT:

```
estSUR<- systemfit(eqsysteem, method="SUR", data= Kmenta)
summary(estSUR, equations=FALSE)
```

SALIDA DE CONSOLA:

```
> estSUR<- systemfit(eqsysteem, method="SUR", data= Kmenta)
> summary(estSUR, equations=FALSE)

systemfit results
method: SUR

              N DF      SSR  detRCov   OLS-R2 McElroy-R2
system 40 33 169.741 0.879285 0.683453 0.788722

              N DF      SSR      MSE      RMSE      R2  Adj R2
demanda 20 17 65.6829 3.86370 1.96563 0.755019 0.726198
oferta 20 16 104.0584 6.50365 2.55023 0.611888 0.539117

The covariance matrix of the residuals used for estimation
      demanda oferta
demanda 3.72539 4.13696
oferta 4.13696 5.78444

The covariance matrix of the residuals
      demanda oferta
demanda 3.86370 4.92431
oferta 4.92431 6.50365

The correlations of the residuals
      demanda oferta
demanda 1.000000 0.982348
oferta 0.982348 1.000000

Coefficients:
              Estimate Std. Error  t value  Pr(>|t|)
demanda_(Intercept) 99.3328942 7.5144525 13.21891 2.2597e-10 ***
demanda_price       -0.2754857 0.0885091 -3.11251 0.00633240 **
demanda_income       0.2985505 0.0419454 7.11760 1.7249e-06 ***
oferta_(Intercept) 61.9661660 11.0807901 5.59222 4.0480e-05 ***
oferta_price         0.1468841 0.0944351 1.55540 0.13940780
oferta_farmPrice     0.2140040 0.0398684 5.36776 6.2829e-05 ***
oferta_trend         0.3393039 0.0679113 4.99628 0.00013185 ***
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

El modelo SUR se utiliza en sistemas de ecuaciones donde las ecuaciones están relacionadas entre sí a través de sus términos de perturbación aleatoria, los cuales están correlacionados. Como vimos previamente, al estimar el sistema mediante MCO observamos que los errores de ambas ecuaciones están efectivamente correlacionados positivamente. Esto hace que los estimadores obtenidos por MCO sean ineficientes. En cambio, el modelo SUR estima conjuntamente todas las ecuaciones del sistema y tiene en cuenta la correlación entre los errores, lo que conduce a estimadores más eficientes. Al observar las salidas vemos que al comparar los errores estándar de los coeficientes entre la estimación por MCO y la estimación por SUR, observamos que los del modelo SUR son en general menores.

e) Explicar brevemente en qué consisten los métodos de **2SLS**, **3SLS** y **FIML**, sus principales características, ventajas y desventajas.

Del libro de Moneta Pizarro (2021) definimos:

Mínimos Cuadrados en 2 Etapas(2SLS): Método que consiste en reemplazar las variables endógenas de cada ecuación por sus valores ajustados obtenidos de estimar por OLS ecuación por ecuación de la forma estructural.

Mínimos Cuadrados en 3 Etapas (3SLS): Aplicación del método SUR a un sistema de ecuaciones simultáneas. Las ecuaciones estructurales se estiman primero por 2SLS, los residuos resultantes se utilizan para estimar Σ y finalmente con esta información se estiman los parámetros estructurales en forma conjunta por Mínimos Cuadrados Generalizados Factibles.

Teniendo en cuenta lo expuesto en Kmenta (1986) este método implica una aplicación directa de la estimación generalizada de Aitken al sistema de ecuaciones estructurales. La idea subyacente es considerar la correlación de las perturbaciones entre ecuaciones, tratándolas como un conjunto de ecuaciones aparentemente no relacionadas.

Máxima Verosimilitud con Información Completa (FILM): Se aplica 3SLS en forma iterativa. Siguiendo a Kmenta (1986), este método implica la aplicación habitual del principio de máxima verosimilitud a todas las ecuaciones estocásticas del sistema simultáneamente. Estos estimadores son consistentes, asintóticamente eficientes y su distribución asintótica es normal. Esto significa que tienen las mismas propiedades asintóticas (y la misma matriz de varianza-covarianza asintótica) que los estimadores de mínimos cuadrados de tres etapas. La matriz de varianza-covarianza asintótica de los estimadores de máxima verosimilitud con información completa puede estimarse de la forma habitual utilizando la matriz de información adecuada.

Los últimos dos métodos son de información completa, realizan una estimación conjunta de todos los parámetros del sistema (útiles cuando los términos de error están correlacionados). Mientras que el primer método (2SLS) es un método de información limitada, estima los parámetros ecuación por ecuación.

f) Estimar el modelo aplicando los métodos de **2SLS**, **3SLS** y **FIML**.

SCRIPT:

```
est2SLS<- systemfit(eqsystem, method="2SLS", inst=~
income+farmPrice+trend, data= Kmenta); summary(est2SLS, equations=
FALSE)
est3SLS<- systemfit(eqsystem, method="3SLS", inst=~
income+farmPrice+trend, data= Kmenta); summary(est3SLS, equations=
FALSE)
estFIML<- systemfit(eqsystem, method="3SLS", inst=~
income+farmPrice+trend, maxiter=500, data= Kmenta);
summary(estFIML, equations= FALSE)
```

SALIDA DE CONSOLA:

```
> est2SLS<- systemfit(eqsystem, method="2SLS", inst=~ income+farmPrice+trend,
data= Kmenta); summary(est2SLS, equations= FALSE)

systemfit results
method: 2SLS

              N DF      SSR detRCov   OLS-R2 McElroy-R2
system 40 33 162.362 4.36424 0.697214 0.548127

              N DF      SSR      MSE      RMSE      R2      Adj R2
demanda 20 17 65.7291 3.86642 1.96632 0.754847 0.726005
oferta 20 16 96.6332 6.03958 2.45756 0.639582 0.572004

The covariance matrix of the residuals
      demanda oferta
demanda 3.86642 4.35744
oferta 4.35744 6.03958

The correlations of the residuals
      demanda oferta
demanda 1.000000 0.901724
oferta 0.901724 1.000000

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
demanda_(Intercept) 94.6333039 7.9208383 11.94738 1.0762e-09 ***
```

```

demanda_price      -0.2435565  0.0964843 -2.52431 0.02183240 *
demanda_income     0.3139918  0.0469437  6.68869 3.8109e-06 ***
oferta_(Intercept) 49.5324417 12.0105264  4.12409 0.00079536 ***
oferta_price       0.2400758  0.0999339  2.40235 0.02878451 *
oferta_farmPrice   0.2556057  0.0472501  5.40964 5.7854e-05 ***
oferta_trend       0.2529242  0.0996551  2.53800 0.02192877 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> est3SLS<- systemfit(eqsystem, method="3SLS", inst=~ income+farmPrice+trend,
data= Kmenta); summary(est3SLS, equations= FALSE)

systemfit results
method: 3SLS

              N DF      SSR detRCov   OLS-R2 McElroy-R2
system 40 33 173.643  1.0332 0.676177  0.786468

              N DF      SSR      MSE      RMSE      R2  Adj R2
demanda 20 17  65.7291 3.86642 1.96632 0.754847 0.726005
oferta  20 16 107.9138 6.74461 2.59704 0.597508 0.522041

The covariance matrix of the residuals used for estimation
      demanda oferta
demanda 3.86642 4.35744
oferta  4.35744 6.03958

The covariance matrix of the residuals
      demanda oferta
demanda 3.86642 5.00443
oferta  5.00443 6.74461

The correlations of the residuals
      demanda oferta
demanda 1.00000 0.97999
oferta  0.97999 1.00000

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
demanda_(Intercept) 94.6333039  7.9208383 11.94738 1.0762e-09 ***
demanda_price      -0.2435565  0.0964843 -2.52431 0.02183240 *
demanda_income     0.3139918  0.0469437  6.68869 3.8109e-06 ***
oferta_(Intercept) 52.1972042 11.8933720  4.38876 0.00045780 ***
oferta_price       0.2285892  0.0996732  2.29339 0.03570648 *
oferta_farmPrice   0.2281580  0.0439938  5.18614 9.0087e-05 ***
oferta_trend       0.3611384  0.0728894  4.95461 0.00014343 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> estFIML<- systemfit(eqsystem, method="3SLS", inst=~ income+farmPrice+trend,
maxiter=500, data= Kmenta); summary(estFIML, equations= FALSE)

```

```

systemfit results
method: iterated 3SLS

convergence achieved after 6 iterations

      N DF   SSR  detRCov   OLS-R2 McElroy-R2
system 40 33 178.16 0.983079 0.667753 0.814118

      N DF   SSR   MSE   RMSE   R2   Adj R2
demanda 20 17 65.7291 3.86642 1.96632 0.754847 0.726005
oferta  20 16 112.4313 7.02696 2.65084 0.580659 0.502033

The covariance matrix of the residuals used for estimation
      demanda oferta
demanda 3.86642 5.11719
oferta  5.11719 7.02683

The covariance matrix of the residuals
      demanda oferta
demanda 3.86642 5.11723
oferta  5.11723 7.02696

The correlations of the residuals
      demanda oferta
demanda 1.000000 0.981741
oferta  0.981741 1.000000

Coefficients:
              Estimate Std. Error  t value  Pr(>|t|)
demanda_(Intercept) 94.6333039   7.9208383 11.94738 1.0762e-09 ***
demanda_price       -0.2435565   0.0964843  -2.52431 0.02183240 *
demanda_income       0.3139918   0.0469437   6.68869 3.8109e-06 ***
oferta_(Intercept)  52.6618215  12.8051061   4.11256 0.00081480 ***
oferta_price         0.2265865   0.1074593   2.10858 0.05109577 .
oferta_farmPrice     0.2233723   0.0467735   4.77562 0.00020634 ***
oferta_trend         0.3800062   0.0720098   5.27715 7.5166e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

g) Realizar una tabla que permita **comparar** las estimaciones obtenidas mediante los diferentes métodos, desde OLS hasta FIML. Comentar las diferencias y seleccionar el método más apropiado para este caso.

SCRIPT:

```
extraer_mcElroy <- function(modelo) {
  resumen <- capture.output(summary(modelo, equations = FALSE))
  linea <- grep("^system", resumen, value = TRUE)
  if (length(linea) == 0) return(NA)
  valores <- unlist(strsplit(linea, "\\s+"))
  mcElroy <- as.numeric(tail(valores, n = 1))
  return(mcElroy)
}

coefOLS <- coef(estOLS)
coefSUR <- coef(estSUR)
coef2SLS <- coef(est2SLS)
coef3SLS <- coef(est3SLS)
coefFIML <- coef(estFIML)

todos_coef <- sort(unique(c(names(coefOLS), names(coefSUR),
names(coef2SLS), names(coef3SLS), names(coefFIML))))

alinear_coef <- function(coef_vector, nombres) {
  out <- rep(NA, length(nombres))
  names(out) <- nombres
  out[names(coef_vector)] <- coef_vector
  return(out)
}

coefOLS_al <- alinear_coef(coefOLS, todos_coef)
coefSUR_al <- alinear_coef(coefSUR, todos_coef)
coef2SLS_al <- alinear_coef(coef2SLS, todos_coef)
coef3SLS_al <- alinear_coef(coef3SLS, todos_coef)
coefFIML_al <- alinear_coef(coefFIML, todos_coef)
tabla_coef <- data.frame(
  Coeficiente = todos_coef,
  OLS = coefOLS_al,
  SUR = coefSUR_al,
  `2SLS` = coef2SLS_al,
  `3SLS` = coef3SLS_al,
  FIML = coefFIML_al,
  check.names = FALSE,
  row.names = NULL
)

mcElroy_vals <- c(
  OLS = extraer_mcElroy(estOLS),
  SUR = extraer_mcElroy(estSUR),
  `2SLS` = extraer_mcElroy(est2SLS),
  `3SLS` = extraer_mcElroy(est3SLS),
```



```

    FIML = extraer_mcElroy(estFIML)
  )
mcElroy_row <- data.frame(
  Coeficiente = "McElroy-R2",
  t(as.data.frame(mcElroy_vals)),
  check.names = FALSE,
  row.names = NULL
)

AIC_OLS <- AIC(estOLS)
AIC_SUR <- AIC(estSUR)
AIC_2SLS <- AIC(est2SLS)
AIC_3SLS <- AIC(est3SLS)
AIC_FIML <- AIC(estFIML)
BIC_OLS <- BIC(estOLS)
BIC_SUR <- BIC(estSUR)
BIC_2SLS <- BIC(est2SLS)
BIC_3SLS <- BIC(est3SLS)
BIC_FIML <- BIC(estFIML)

tabla_info <- data.frame(
  Criterio = c("AIC", "BIC"),
  OLS = c(AIC_OLS, BIC_OLS),
  SUR = c(AIC_SUR, BIC_SUR),
  `2SLS` = c(AIC_2SLS, BIC_2SLS),
  `3SLS` = c(AIC_3SLS, BIC_3SLS),
  FIML = c(AIC_FIML, BIC_FIML)
)

col_names <- c("Coeficiente", "OLS", "SUR", "2SLS", "3SLS", "FIML")
names(mcElroy_row) <- col_names
names(tabla_info) <- col_names
tabla_final <- rbind(tabla_coef, mcElroy_row, tabla_info)

print(tabla_final, row.names = FALSE)

```

SALIDA DE CONSOLA:

```

> extraer_mcElroy <- function(modelo) {
+   resumen <- capture.output(summary(modelo, equations = FALSE))
+   linea <- grep("^system", resumen, value = TRUE)
+   if (length(linea) == 0) return(NA)
+   valores <- unlist(strsplit(linea, "\\s+"))
+   mcElroy <- as.numeric(tail(valores, n = 1))
+   return(mcElroy)
+ }
>
>
> coefOLS <- coef(estOLS)
> coefSUR <- coef(estSUR)
> coef2SLS <- coef(est2SLS)
> coef3SLS <- coef(est3SLS)
> coefFIML <- coef(estFIML)
>
> todos_coef <- sort(unique(c(names(coefOLS), names(coefSUR), names(coef2SLS),
names(coef3SLS), names(coefFIML))))
>
> alinear_coef <- function(coef_vector, nombres) {
+   out <- rep(NA, length(nombres))
+   names(out) <- nombres
+   out[names(coef_vector)] <- coef_vector
+   return(out)
+ }
> coefOLS_al <- alinear_coef(coefOLS, todos_coef)
> coefSUR_al <- alinear_coef(coefSUR, todos_coef)
> coef2SLS_al <- alinear_coef(coef2SLS, todos_coef)
> coef3SLS_al <- alinear_coef(coef3SLS, todos_coef)
> coefFIML_al <- alinear_coef(coefFIML, todos_coef)
> tabla_coef <- data.frame(
+   Coeficiente = todos_coef,
+   OLS = coefOLS_al,
+   SUR = coefSUR_al,
+   `2SLS` = coef2SLS_al,
+   `3SLS` = coef3SLS_al,
+   FIML = coefFIML_al,
+   check.names = FALSE,
+   row.names = NULL
+ )
> mcElroy_vals <- c(
+   OLS = extraer_mcElroy(estOLS),
+   SUR = extraer_mcElroy(estSUR),
+   `2SLS` = extraer_mcElroy(est2SLS),
+   `3SLS` = extraer_mcElroy(est3SLS),
+   FIML = extraer_mcElroy(estFIML)
+ )
> mcElroy_row <- data.frame(
+   Coeficiente = "McElroy-R2",
+   t(as.data.frame(mcElroy_vals)),

```

```

+   check.names = FALSE,
+   row.names = NULL
+ )
>
> AIC_OLS <- AIC(estOLS)
> AIC_SUR <- AIC(estSUR)
> AIC_2SLS <- AIC(est2SLS)
> AIC_3SLS <- AIC(est3SLS)
> AIC_FIML <- AIC(estFIML)
> BIC_OLS <- BIC(estOLS)
> BIC_SUR <- BIC(estSUR)
> BIC_2SLS <- BIC(est2SLS)
> BIC_3SLS <- BIC(est3SLS)
> BIC_FIML <- BIC(estFIML)
>
>
> tabla_info <- data.frame(
+   Criterio = c("AIC", "BIC"),
+   OLS = c(AIC_OLS, BIC_OLS),
+   SUR = c(AIC_SUR, BIC_SUR),
+   `2SLS` = c(AIC_2SLS, BIC_2SLS),
+   `3SLS` = c(AIC_3SLS, BIC_3SLS),
+   FIML = c(AIC_FIML, BIC_FIML)
+ )
>
> col_names <- c("Coeficiente", "OLS", "SUR", "2SLS", "3SLS", "FIML")
> names(mcElroy_row) <- col_names
> names(tabla_info) <- col_names
> tabla_final <- rbind(tabla_coef, mcElroy_row, tabla_info)
>
>
> print(tabla_final, row.names = FALSE)

```

	Coeficiente	OLS	SUR	2SLS	3SLS	FIML
demanda_(Intercept)	99.8954229	99.3328942	94.6333039	94.6333039	94.6333039	
demanda_income	0.3346356	0.2985505	0.3139918	0.3139918	0.3139918	
demanda_price	-0.3162988	-0.2754857	-0.2435565	-0.2435565	-0.2435565	
oferta_(Intercept)	58.2754312	61.9661660	49.5324417	52.1972042	52.6618215	
oferta_farmPrice	0.2481333	0.2140040	0.2556057	0.2281580	0.2233723	
oferta_price	0.1603666	0.1468841	0.2400758	0.2285892	0.2265865	
oferta_trend	0.2483023	0.3393039	0.2529242	0.3611384	0.3800062	
McElroy-R2	0.5575590	0.7887220	0.5481270	0.7864680	0.8141180	
AIC	151.5916879	123.2289062	151.2707170	126.4550986	125.4605122	
BIC	165.1027236	140.1177007	164.7817527	143.3438931	142.3493068	

Como dijimos antes, el R^2 de McElroy mide el ajuste global del sistema estimado. En este caso, el método FIML presenta el mayor R^2 (0.814), lo cual indica el mejor ajuste conjunto del sistema. Además FIML presenta valores más bajos de Akaike y Schwartz, lo que implica que este método es más adecuado.

Por otro lado, los métodos OLS y 2SLS presentan un peor desempeño en cuanto a ajuste y criterios de información, lo que se espera dado que OLS no considera ni la simultaneidad ni la correlación entre ecuaciones, y 2SLS solo corrige por endogeneidad pero no por la correlación entre los errores.

Tanto SUR como 3SLS mejoran significativamente el ajuste respecto a OLS y 2SLS. SUR es útil cuando las ecuaciones están correlacionadas pero no hay endogeneidad, mientras que 3SLS, al igual que FIML, corrige simultaneidad y aprovecha la correlación entre ecuaciones.

En conclusión, el método más apropiado para este caso es el de Máxima Verosimilitud con Información Completa, ya que proporciona el mejor ajuste general del sistema (mayor R^2 de McElroy) y los mejores valores de Akaike y Schwartz.

Ejercicio de la unidad 6

En el archivo “**GDP_Arg_Bra_International_Financial_Statistics.txt**” se puede encontrar información sobre los índices de Producto Bruto Interno trimestrales de Argentina y Brasil para el período 1995:Q1-2016:Q2.

A partir del logaritmo natural de la serie correspondiente a **Brasil**, aplique la metodología de **Box y Jenkins** para seleccionar el modelo **ARIMA estacional** más apropiado.

Para una primera aproximación al tema se puede consultar el siguiente link:

<https://online.stat.psu.edu/stat510/>

Cargamos las librerías y hacemos el set up de los datos para leer la serie correspondiente como un objeto time series en logaritmo natural

SCRIPT:

```
# Librerías
library(forecast)
library(readr)
library(tseries)
library(FinTS)
```

```
#Set-up
datos_gdp <-
read_delim("GDP_Arg_Bra_International_Financial_Statistics.txt",
           delim = "\t",
           col_names = TRUE,
           skip = 0)

gdp_brasil_log <- log(datos_gdp$Brazil)
gdp_brasil_ts <- ts(gdp_brasil_log, start = c(1995, 1), frequency = 4)
```


Identificación del modelo


Observamos el gráfico de la serie en logaritmo natural y los gráficos de las funciones de autocorrelación y autocorrelación parcial para guiarnos hacia la identificación sobre el mismo

SCRIPT:

```
par(mfrow=c(2,1))
acf(gdp_brasil_ts, lag.max = 48, main = "ACF del Log(PBI) de Brasil")
pacf(gdp_brasil_ts, lag.max = 48, main = "PACF del Log(PBI) de Brasil")
par(mfrow=c(1,1))
```

SALIDA DE CONSOLA:





Dado que el análisis gráfico sugiere que la serie podría no ser estacionaria, realizamos un test de Dickey-Fuller Aumentado para sacar una conclusión rigurosa sobre la misma

SCRIPT:

```
print("Prueba ADF para la serie original:")
print(adf.test(gdp_brasil_ts))
```

SALIDA DE CONSOLA:

```
[1] "Prueba ADF para la serie original:"
> print(adf.test(gdp_brasil_ts))

Augmented Dickey-Fuller Test

data:  gdp_brasil_ts
Dickey-Fuller = -1.3785, Lag order = 4, p-value = 0.8312
alternative hypothesis: stationary
```


El test tiene como H0: No estacionariedad de la serie, y dado que el p-value = 0.8312 en el test, concluimos para un nivel de significancia de 0.05, que existe evidencia estadística de no estacionariedad en la serie por lo que procedemos a diferenciarla una vez (d=1). Observamos en el grafico la serie diferenciada y los correspondientes correlogramas de ACF y PACF.


SCRIPT:

```
gdp_brasil_diff1 <- diff(gdp_brasil_ts, differences = 1)
plot(gdp_brasil_diff1, main = "Primera Diferencia del Log(PBI) de
Brasil",
     ylab = "Diferencia Log(PBI)", xlab = "Año")

par(mfrow=c(2,1))
acf(gdp_brasil_diff1, lag.max = 48, main = "ACF (d=1)")
pacf(gdp_brasil_diff1, lag.max = 48, main = "PACF (d=1)")
par(mfrow=c(1,1))
```

SALIDA DE CONSOLA:





Realizamos otra prueba ADF para verificar la estacionariedad de la serie

SCRIPT:

```
# Prueba ADF serie diferenciada
print("Prueba ADF para la serie diferenciada:")
print(adf.test(gdp_brasil_diff1))
```

SALIDA DE CONSOLA:

```
[1] "Prueba ADF para la serie diferenciada:"
> print(adf.test(gdp_brasil_diff1))

Augmented Dickey-Fuller Test

data:  gdp_brasil_diff1
Dickey-Fuller = -3.1972, Lag order = 4, p-value = 0.09386
alternative hypothesis: stationary
```

Observamos que para un nivel de significancia del 0.05 deberíamos seguir aceptando la hipótesis nula de no estacionariedad, pero si trabajamos con un nivel de significancia del 0.1 podríamos aceptar la hipótesis alternativa de estacionariedad.

De todas maneras, observando los correlogramas de autocorrelación de los residuos de la serie diferenciada, observamos que sugieren un modelo con diferencia estacional de orden

1 (D=1). Procedemos a elaborarlo, observar gráficamente la serie, realizar el test de raíz unitaria Augmented Dickey-Fuller sobre la misma siguiendo a Enders (2015) y observar los correlogramas ACF y PACF

SCRIPT:

```
#Modelo Seasonal
gdp_brasil_diff_seas <- diff(gdp_brasil_diff1, lag = 4, differences = 1)
plot(gdp_brasil_diff_seas, main = "Diferencia Regular (d=1) y Estacional (D=1) del Log(PBI) de Brasil",
     ylab = "Diferencia Estacional y Regular Log(PBI)", xlab = "Año")

# Prueba ADF serie d=1 D=1
print("Prueba ADF para la serie d=1 D=1:")
print(adf.test(gdp_brasil_diff_seas))

par(mfrow=c(2,1))
acf(gdp_brasil_diff_seas, lag.max = 48, main = "ACF (d=1, D=1)")
pacf(gdp_brasil_diff_seas, lag.max = 48, main = "PACF (d=1, D=1)")
par(mfrow=c(1,1))
```

SALIDA DE CONSOLA:

```
[1] "Prueba ADF para la serie d=1 D=1:"
> print(adf.test(gdp_brasil_diff_seas))


Augmented Dickey-Fuller Test

data:  gdp_brasil_diff_seas
Dickey-Fuller = -5.0843, Lag order = 4, p-value = 0.01
alternative hypothesis: stationary


Warning message:
In adf.test(gdp_brasil_diff_seas) : p-value smaller than printed p-value
```

El p-value de la serie diferenciada con diferencia seasonal (d=1,D=1) es menos al nivel de significancia de 0.05 por lo que podemos aceptar la hipótesis alternativa de que la serie resultante es estacionaria y ya podemos trabajar el en desarrollo de un modelo para la serie.


Diferencia Regular (d=1) y Estacional (D=1) del Log(PBI) de Brasil



ACF (d=1, D=1)



PACF (d=1, D=1)



Observamos que los correlogramas de ACF y PACF sugieren un modelo con componente autorregresivo estacional de orden uno (SAR=1).

Modelo 1

Procedemos a desarrollar este modelo al que llamaremos “Modelo 1” el cual sera un SARIMA(0,1,0)(1,1,0)

SCRIPT:

```
# Armamos el SARIMA(0,1,0)(1,1,0)[s]
sarima_model_differenced <- arima(gdp_brasil_ts,
                                  order = c(0, 1, 0),
                                  seasonal = list(order = c(1, 1, 0),
period = 4))
```

Hacemos un summary del modelo para ver el valor de los parametros del mismo

SCRIPT:

```
summary(sarima_model_differenced)
```

SALIDA DE CONSOLA:

```
Call:
arima(x = gdp_brasil_ts, order = c(0, 1, 0), seasonal = list(order =
c(1, 1,
0), period = 4))

Coefficients:
          sar1
        -0.6567
s.e.      0.1235
```

Observamos los ACF y PACF para los residuos del mismo

SCRIPT:


```
modell_residuals <- residuals(sarima_model_differenced)

model_idenfier_string <- "Modelo Uno"
model_order_string <- "SARIMA(0,1,0)(1,1,0)[4]"
full_model_description <- paste(model_idenfier_string, "-",
model_order_string)

par(mfrow = c(2, 1))
acf(modell_residuals,
    lag.max = 48,
    main = paste("ACF of Residuals -", full_model_description),
    ylab = "ACF")
```

```
pacf(model1_residuals,
      lag.max = 48,
      main = paste("PACF of Residuals -", full_model_description),
      ylab = "PACF")
par(mfrow = c(1, 1))
```

SALIDA DE CONSOLA:




Observamos que los residuos los correlogramas correspondientes se encuentran bien comportados por lo que podríamos estar ante un modelo válido.
Procedemos ahora a la validación del mismo a través de tests sobre el cumplimiento de los supuestos sobre los residuos del mismo

Graficamos los residuos

SCRIPT:

```
# Validación del Modelo
#Gráfico de los residuos
plot(model1_residuals, main = "Residuos del Modelo
SARIMA(0,1,0)(1,1,0)[4]",
      ylab = "Residuos", xlab = "Tiempo")
abline(h=0, col="red")
```

SALIDA DE CONSOLA:



Procedemos a realizar los tests correspondientes sobre los mismos
Prueba de autocorrelación:

SCRIPT:

```
# Test de Autocorrelacion de los residuos
ljung_box_test <- Box.test(model1_residuais,
                           lag = 20,
                           type = "Ljung-Box",
                           fitdf = 1)

print(paste("Ljung-Box test for residuals of", full_model_description,
            ":"))
print(ljung_box_test)
```

SALIDA DE CONSOLA:

```
> print(paste("Ljung-Box test for residuals of", full_model_description,
            ":"))
[1] "Ljung-Box test for residuals of Modelo Uno -
```

```
SARIMA(0,1,0)(1,1,0)[4] :"  
> print(ljung_box_test)  
  
Box-Ljung test  
  
data:  model1_residuals  
X-squared = 19.383, df = 19, p-value = 0.4325
```

El test de Ljung-Box prueba si los residuos del modelo de series temporales se comportan como ruido blanco, es decir, que no tienen autocorrelación significativa y son aleatorios. La H0 es que los residuos no presentan autocorrelación, por lo que con un p-value = 0.4325 podemos afirmar, con un nivel de significancia de 0.05, que hay evidencia estadística significativa de que los residuos del modelo no están autocorrelacionados.

Prueba de heterocedasticidad:

SCRIPT:

```
# Hacemos test de Heteroscedasticidad  
arch_test_lags <- 5 # sugerido como punto de partida para series  
trimestrales  
arch_test_result <- ArchTest(model1_residuals, lags = arch_test_lags,  
demean = FALSE)  
  
# Print de resultados del test ARCH-LM  
cat("\n--- Heteroscedasticity Test (ARCH-LM) ---\n")  
cat("Model: Modelo Uno - SARIMA(0,1,0)(1,1,0)[4]\n")  
print(arch_test_result)
```

SALIDA DE CONSOLA:

```
Model: Modelo Uno - SARIMA(0,1,0)(1,1,0)[4]  
> print(arch_test_result)  
  
ARCH LM-test; Null hypothesis: no ARCH effects  
  
data:  model1_residuals  
Chi-squared = 20.787, df = 5, p-value = 0.0008888
```

El test tiene como H0: No hay heterocedasticidad condicional y como H1: Hay heterocedasticidad condicional de tipo ARCH, la varianza de los errores depende de valores pasados de los errores al cuadrado.

Dado que el p-value = 0.0008888 es menor al nivel de significancia de 0.05 observamos que hay evidencia estadística de que los residuos de la serie presentan heterocedasticidad, es decir, la varianza de los mismos no es constante a lo largo del tiempo.

Test de normalidad:

Realizamos un histograma de los valores de los residuos y luego realizamos el test de Shapiro-Wilk sobre los mismos

SCRIPT:


```
# Test de normalidad de residuos
hist(model1_residuals,
     breaks = 20,
     freq = FALSE,
     main = "Histograma de Residuos Modelo Uno",
     xlab = "Residuos",
     ylab = "Densidad")

mu_residuals <- mean(model1_residuals)
sd_residuals <- sd(model1_residuals)

curve(dnorm(x, mean = mu_residuals, sd = sd_residuals),
     col = "darkblue",
     lwd = 2,
     add = TRUE)

shapiro_test_result <- shapiro.test(model1_residuals)
cat("\n--- Normality Test for Residuals (Shapiro-Wilk) ---\n")
cat("Model: Modelo Uno - SARIMA(0,1,0)(1,1,0)[4]\n")
print(shapiro_test_result)
```

SALIDA DE CONSOLA:



```
Model: Modelo Uno - SARIMA(0,1,0)(1,1,0)[4]
> print(shapiro_test_result)
```

Shapiro-Wilk normality test

```
data:  model1_residuals
W = 0.90732, p-value = 1.326e-05
```

El test de normalidad Shapiro-Wilk tiene como H0: Los residuos tienen una distribución normal. Observamos que el p-value = 0.00001326 es mucho menor al nivel de significancia de 0.05 por lo que hay evidencia estadística suficiente para aceptar la hipótesis alternativa H1: Los residuos no siguen una distribución normal.

Observando que el modelo no cumple con los supuestos del homocedasticidad ni de normalidad de los residuos, procedemos a elaborar otro modelo.

Para la realización del segundo modelo que denominaremos “Modelo 2” utilizaremos la función de R “autoarima()” que selecciona un modelo para los datos basado en minimizar el criterio AIC del mismo.

Modelo 2

Desarrollamos el modelo

SCRIPT:

```
# Desarrollo del Modelo
modelo_2 <- auto.arima(gdp_brasil_ts,
                        seasonal = TRUE, # Permitir modelos estacionales
                        stepwise = FALSE, # Búsqueda más exhaustiva
                        approximation = FALSE, # No usar aproximaciones
para AICc
                        trace = TRUE, # Muestra los modelos probados
                        ic = "aic") # Usar AIC para la selección

model2_residuals <- residuals(modelo_2)
```

SALIDA DE CONSOLA:

```
Best model: ARIMA(1,0,0)(1,1,0)[4] with drift
```

Por lo que el modelo que minimiza el criterio de información AIC será un SARIMA(1,0,0)(1,1,0) con drift. Vemos que a diferencia del Modelo 1 este no presenta diferencia d=1, presenta un coeficiente autorregresivo AR(1) y drift. Observamos ahora el summary del modelo para ver los valores de los parámetros

SCRIPT:

```
summary(modelo_2)
```

SALIDA DE CONSOLA:




```
Series: gdp_brasil_ts  
ARIMA(1,0,0)(1,1,0)[4] with drift  
  
Coefficients:  
          ar1      sar1    drift  
      0.8459 -0.5998  0.0062  
s.e.  0.0719  0.1377  0.0023
```

Procedemos a observar los correlogramas ACF y PACF de los errores del mismo y graficamos los residuos.

SCRIPT:

```
# Denominación del modelo para facilitar los gráficos  
model2_identifier_string <- "Modelo Dos"  
model2_order_string <- "SARIMA(1,0,0)(1,1,0)[4]"  
full_model2_description <- paste(model2_identifier_string, "-",  
model2_order_string)  
  
# Validación del Modelo  
par(mfrow = c(2, 1))  
acf(model2_residuals,  
    lag.max = 48,  
    main = paste("ACF of Residuals -", full_model2_description),  
    ylab = "ACF")  
pacf(model2_residuals,  
    lag.max = 48,  
    main = paste("PACF of Residuals -", full_model2_description),  
    ylab = "PACF")  
par(mfrow = c(1, 1))  
# Grafico de los residuos  
plot(model2_residuals, main = "Residuos del Modelo  
SARIMA(1,0,0)(1,1,0)[4]",  
     ylab = "Residuos", xlab = "Tiempo")  
abline(h=0, col="red")
```

SALIDA DE CONSOLA:



Observamos en los correlogramas de residuos ACF y PACF que la mayoría de estos se encuentran sobre las bandas de confianza por lo que podrían sugerir que los residuos se comportan como ruido blanco.

Procedemos a realizar los test correspondientes sobre los mismos
Test de autocorrelación de los residuos:

SCRIPT:

```
# Test de Autocorrelacion de los residuos
ljung_box_test2 <- Box.test(model2_residuals,
                             lag = 20,
                             type = "Ljung-Box",
                             fitdf = 1)
print(paste("Ljung-Box test for residuals of", full_model2_description,
            ":"))
print(ljung_box_test2)
```

SALIDA DE CONSOLA:

```
[1] "Ljung-Box test for residuals of Modelo Dos -
SARIMA(1,0,0)(1,1,0)[4] :"
```

> print(ljung_box_test2)

```
Box-Ljung test
data: model2_residuals
X-squared = 19.093, df = 19, p-value = 0.4509
```

Dado que el p-value = 0.4509 es mayor al nivel de significancia de 0.05 y como la hipótesis nula es H_0 : No hay correlación en los residuos, concluimos que hay evidencia estadística suficiente de que los residuos no están autocorrelacionados

Test de heterocedasticidad

SCRIPT:

```
# Hacemos test de Heterocedasticidad
arch_test2_lags <- 5
arch_test2_result <- ArchTest(model2_residuals, lags = arch_test2_lags,
                              demean = FALSE)

# Print los resultados del test ARCH-LM
cat("\n--- Heteroscedasticity Test (ARCH-LM) ---\n")
cat("Model: Modelo Dos - SARIMA(1,0,0)(1,1,0)[4]\n")
print(arch_test2_result)
```

SALIDA DE CONSOLA:

```
--- Heteroscedasticity Test (ARCH-LM) ---
> cat("Model: Modelo Dos - SARIMA(1,0,0)(1,1,0)[4]\n")
Model: Modelo Dos - SARIMA(1,0,0)(1,1,0)[4]
> print(arch_test2_result)
```

ARCH LM-test; Null hypothesis: no ARCH effects

```
data: model2_residuals  
Chi-squared = 34.006, df = 5, p-value = 2.375e-06
```

Observamos que el p-value = 0.000002375 es mucho menor al nivel de significancia de 0.05 por lo que concluimos con evidencia estadística suficiente que los residuos del modelo presentan efectos ARCH, es decir la varianza de los mismos no es constante en el tiempo para el periodo de la serie en cuestión.


Test de normalidad

Observamos el histogram de frecuencias de los valores de los residuos y realizamos el test Shapiro-Wilk sobre los mismos para determinar normalidad

SCRIPT:

```
# Test de normalidad de residuos  
# Histograma de residuos  
hist(model2_residuals,  
      breaks = 20,  
      freq = FALSE,  
      main = "Histograma de Residuos Modelo Dos",  
      xlab = "Residuos",  
      ylab = "Densidad")  
  
mu2_residuals <- mean(model2_residuals)  
sd2_residuals <- sd(model2_residuals)  
curve(dnorm(x, mean = mu2_residuals, sd = sd2_residuals),  
      col = "darkblue",  
      lwd = 2,  
      add = TRUE)  
  
# Test Shapiro-Wilk  
shapiro_test2_result <- shapiro.test(model2_residuals)  
cat("\n--- Normality Test for Residuals (Shapiro-Wilk) ---\n")  
cat("Model: Modelo Dos - SARIMA(0,1,0)(1,1,0)[4]\n")  
print(shapiro_test2_result)
```

SALIDA DE CONSOLA:



```

--- Normality Test for Residuals (Shapiro-Wilk) ---
> cat("Model: Modelo Dos - SARIMA(0,1,0)(1,1,0)[4]\n")
Model: Modelo Dos - SARIMA(0,1,0)(1,1,0)[4]
> print(shapiro_test2_result)

```

Shapiro-Wilk normality test

```

data: model2_residuals
W = 0.92651, p-value = 0.0001116

```

El test arroja un p-value = 0.0001116 < 0.05 de significancia por lo que hay evidencia estadística suficiente de la no normalidad en la distribución de los residuos

Dado que ninguno de los dos modelos cumple con los supuestos de ruido blanco en el error (homocedasticidad y normalidad del término de error), y aunque sabemos que el Modelo 2 presenta una métrica AIC menor, procederemos a comparar un forecast fuera de la muestra utilizando cada uno de los modelos para realizar una elección entre los mismos.

Pronóstico

Procedemos a establecer el set up para hacer los forecasts para cada modelo, realizando la transformación inversa del logaritmo realizada previamente en la serie para hacer el forecast sobre los datos originales.

SCRIPT:

```
# Creamos la serie de tiempo con los datos originales
gdp_brasil_orig_ts <- ts(datos_gdp$Brazil, start = c(1995, 1), frequency
= 4)

# Usamos la serie de tiempo con los datos log para hacer los pronósticos
gdp_brasil_log_ts <- log(gdp_brasil_orig_ts)

# Set up para el pronóstico fuera de muestra
n_test <- 8 # Número de observaciones para el set de testeo del modelo

# Creamos los set de training y de testeo con los datos en logaritmo
train_log_ts <- window(gdp_brasil_log_ts, end =
time(gdp_brasil_log_ts)[length(gdp_brasil_log_ts) - n_test])
test_log_ts <- window(gdp_brasil_log_ts, start =
time(gdp_brasil_log_ts)[length(gdp_brasil_log_ts) - n_test + 1])

# Creamos los sets de training y test para los datos originales para
luego usar en los gráficos y en las métricas de precisión del pronóstico
train_orig_ts <- window(gdp_brasil_orig_ts, end =
time(gdp_brasil_orig_ts)[length(gdp_brasil_orig_ts) - n_test])
test_orig_ts <- window(gdp_brasil_orig_ts, start =
time(gdp_brasil_orig_ts)[length(gdp_brasil_orig_ts) - n_test + 1])
```

Hacemos los forecasts para ambos modelos

SCRIPT:

```
# Modelo 1: Fit SARIMA(0,1,0)(1,1,0)[4] en los datos de entrenamiento
model1_oos <- Arima(train_log_ts,
                    order = c(0, 1, 0),
                    seasonal = list(order = c(1, 1, 0), period = 4),
                    include.mean = TRUE)

# Generamos el forecast fuera de la muestra para el Modelo 1 (horizon =
longitud de test_ts)
forecast_model1_log <- forecast(model1_oos, h = length(test_log_ts))

# Hacemos la transformación inversa a los datos para volver a la escala
original
forecast_model1_orig <- forecast_model1_log
forecast_model1_orig$mean <- exp(forecast_model1_log$mean)
forecast_model1_orig$lower <- exp(forecast_model1_log$lower)
forecast_model1_orig$upper <- exp(forecast_model1_log$upper)
forecast_model1_orig$x <- train_orig_ts
if (!is.null(forecast_model1_log$fitted)) {
```

```

forecast_model1_orig$fitted <- exp(forecast_model1_log$fitted)
}

# Modelo 2: Hacemos el fit del autoarima de nuevo
model2_oos <- auto.arima(train_log_ts,
                        seasonal = TRUE,
                        stepwise = FALSE,
                        approximation = FALSE,
                        trace = FALSE,
                        ic = "aic")

# Generamos el forecast fuera de muestra para el Modelo 2 (horizon =
longitud de test_ts)
forecast_model2_log <- forecast(model2_oos, h = length(test_log_ts))

# Hacemos la transformación inversa a los datos para volver a la escala
original
forecast_model2_orig <- forecast_model2_log # Copy the structure
forecast_model2_orig$mean <- exp(forecast_model2_log$mean)
forecast_model2_orig$lower <- exp(forecast_model2_log$lower)
forecast_model2_orig$upper <- exp(forecast_model2_log$upper)
forecast_model2_orig$x <- train_orig_ts
if (!is.null(forecast_model2_log$fitted)) {
  forecast_model2_orig$fitted <- exp(forecast_model2_log$fitted)
}

```

Graficamos los forecast en la serie original con los valores observados y predichos para ambos modelos

SCRIPT:

```


# Graficamos el forecast fuera de muestra para el Modelo 1
autoplot(forecast_model1_orig) +
  autolayer(test_orig_ts, series = "Datos Observados (Original)") +
  ggtitle("Pronostico fuera de muestra (Escala Original):
SARIMA(0,1,0)(1,1,0)[4]") +
  xlab("Año") +
  ylab("PBI Brasil (Escala Original)") +
  guides(colour = guide_legend(title = "Series"))


# Graficamos el forecast fuera de muestra del Modelo 2
autoplot(forecast_model2_orig) +
  autolayer(test_orig_ts, series = "Datos Observados (Original)") +
  ggtitle("Pronostico fuera de muestra (Escala Original):
SARIMA(1,0,0)(1,1,0)[4] with drift") +

```

```
xlab("Año") +
ylab("PBI Brasil (Escala Original)") +
guides(colour = guide_legend(title = "Series"))
```

SALIDA DE CONSOLA:





Observamos que aunque ninguno de los modelos presenta un rendimiento deseable. Realizando forecasts similares, el Modelo 1 presenta una mayor varianza en los pronósticos con estos dentro de sus bandas de confianza, mientras que el Modelo 2 presenta menor varianza en los intervalos de confianza pero su pronóstico está completamente por fuera de las mismas.

Podemos comparar las métricas de precisión de los pronósticos

SCRIPT:

```
print(accuracy(forecast_model1_orig, test_orig_ts))
print(accuracy(forecast_model2_orig, test_orig_ts))
```

SALIDA DE CONSOLA:

```
> print(accuracy(forecast_model1_orig, test_orig_ts))
```

	ME	RMSE	MAE	MPE	MAPE
MASE	ACF1	Theils	U		

```

Training set -0.08985707 1.126803 0.7850126 -0.1674192 1.480247
0.4037457 -0.07891037 NA
Test set -4.11459884 4.878523 4.1145988 -5.9163524 5.916352
2.1162101 0.71525235 4.056081
> print(accuracy(forecast_model2_orig, test_orig_ts))
ME RMSE MAE MPE MAPE
MASE ACF1 Theils U
Training set -0.01486415 1.052209 0.7691477 -0.06325921 1.448048
0.3955861 0.03095658 NA
Test set -5.99003164 6.820633 5.9900316 -8.59322467 8.593225
3.0807780 0.70537848 5.657487

```

Basándonos en la mayoría de las métricas de error (RMSE, MAE, MAPE) y sesgo (ME, MPE), el Modelo 1 (SARIMA(0,1,0)(1,1,0)[4] ajustado manualmente) parece ser superior al Modelo 2 (SARIMA(1,0,0)(1,1,0)[4] con drift (seleccionado por auto.arima) en el conjunto de prueba pero ambos modelos presentan resultados no muy satisfactorios.

REFERENCIAS BIBLIOGRAFICAS:

Moneta Pizarro, A. M. (2021). Econometría..pdf

Kmenta, Jan (1986), Elements of Econometrics, Second Edition, Macmillan, New York.
Capítulo 13

Judge, G. G., Hill, R. C., Griffiths, W. E., Luetkepohl, H. y Lee, T. C. (1988), Introduction to the Theory and Practice of Econometrics, Second Edition, Wiley, New York.

Layard, P.R.G. y Walters, A.A. (1978), Microeconomic Theory, McGrawHill, New York, Cap. 5.

Silberberg, E. y Suen, W. (1990), The Structure of Economics – A Mathematical Analysis, McGrawHill, New York.

Enders, W. (2015), Applied Econometric Time Series, Wiley, New York. Fourth Edition.