

Introducción: El estudio se fundamenta en una base de datos de 90 empleados de una empresa de servicios de computación. El análisis se centra en cuatro variables cuantitativas: edad (en años), días trabajados (anuales), sueldo anual (en dólares), y días de vacaciones asignados. El informe completo incluye un análisis descriptivo univariado, un análisis multivariado, y posteriormente, análisis de componentes principales (PCA) para reducir la dimensionalidad y un análisis de conglomerados para identificar grupos de empleados con características similares.

Análisis Descriptivo Univariado


Las cuatro variables fueron caracterizadas individualmente, utilizando medidas de tendencia central, dispersión y distribución.

Edad: La edad oscila entre 22 y 64 años, con una media de 41,5 años. La distribución es centrada (mediana de 42 años) y moderadamente dispersa (desviación estándar de 12). La mayoría de los empleados se concentra entre los 30 y 50 años.

Días Trabajados: Esta variable se sitúa entre 200 y 260 días al año, con una media de 230,2 días. La distribución es simétrica (mediana de 231,5 días), presenta una variabilidad relativamente baja (SD de 16,8 días), y muestra una concentración homogénea alrededor del promedio.

Sueldo Anual (USD): El rango es amplio, desde \$25.901 hasta \$100.916. La media es de \$55.834 USD y la desviación estándar es considerable (\$15.240 USD). La asimetría positiva (0,35) indica un sesgo a la derecha, caracterizado por la existencia de salarios más altos, aunque la mayor parte se ubica entre \$40.000 y \$70.000.

Días de Vacaciones: La asignación varía de 10 a 30 días, con una media de 19,7 días. La distribución es simétrica (asimetría prácticamente nula de -0,015) y uniforme, con una dispersión moderada (SD de 6,48 días).




Análisis Descriptivo Multivariado

El análisis de correlación concluyó que las relaciones entre la Edad, Días trabajados, Sueldo anual y Días de Vacaciones son, en su mayoría, débiles o prácticamente inexistentes.

La correlación más notable es negativa, aunque baja (-0,11), entre la Edad y los Días de Vacaciones. Esta asociación sugiere una leve disminución de días de vacaciones a medida que la edad aumenta, pero su magnitud es demasiado baja para considerarse estadísticamente significativa.

Las correlaciones entre Edad y Sueldo anual (0,04), y entre Edad y Días trabajados (0,08), son positivas, pero de baja intensidad, lo que indica la ausencia de una relación lineal clara.

Las asociaciones entre Sueldo anual y Días trabajados (-0,00), así como entre Sueldo anual y Vacaciones (-0,01), son prácticamente nulas, reforzando la independencia entre estas variables. Los gráficos de dispersión confirmaron esta falta de patrones definidos, mostrando nubes de puntos distribuidas aleatoriamente.



Análisis de componentes principales

Configuración del Conjunto de Datos y Necesidad de Estandarización

El Análisis de Componentes Principales (PCA) se aplicó a la base de datos. Las variables, todas de tipo numérico (*float64*) y sin valores nulos. El objetivo central del PCA es reducir la dimensionalidad, sintetizando la información contenida en estas cuatro variables originales en un número menor de componentes principales (CP) que conserven la mayor parte de la variabilidad/información de los datos.

Un requisito previo para el PCA es que las variables sean cuantitativas, lo cual se cumple. Sin embargo, se identificó que las variables se encuentran en escalas muy diferentes (por ejemplo, el sueldo se mide en miles, mientras que las vacaciones se miden en unidades). Esta disparidad de magnitudes hace crítica la necesidad de una estandarización posterior para evitar que una variable domine el análisis.

En el análisis preliminar de correlación, se observó que la asociación lineal entre pares de variables es muy débil, con valores cercanos a cero. Por ejemplo, la correlación entre Edad y Días trabajados fue de 0.08, y entre Edad y Vacaciones_días fue de -0.11 (una relación negativa muy débil). Este hallazgo es favorable para el PCA, ya que indica que las variables aportan información relativamente independiente, lo que permite que el PCA identifique combinaciones para concentrar la variabilidad dispersa.

El Problema de Escala y la Aplicación de la Estandarización

Al realizar un análisis inicial de los valores propios sin estandarización, se manifestó el problema de escala:

El primer componente principal (CP1) capturó una cantidad de varianza extremadamente elevada (2.323×10^8), superando masivamente a los siguientes tres componentes, que retuvieron varianza del orden de cientos o decenas.


La suma de los valores propios, que representa la varianza total, fue muy alta (232.254.577,97), confirmando la influencia desproporcionada de las diferentes escalas originales.

La varianza acumulada mostró que el primer componente explicaba el 100% de la varianza total.


Este resultado indicó que el PCA estaba siendo completamente dominado por la variable de mayor

magnitud, por lo que el primer componente resumía de manera casi completa la dispersión de los datos. Para corregir este sesgo y asegurar que todas las variables contribuyeran de forma comparable, se procedió a estandarizar el conjunto de datos.

Tras la estandarización, cada variable obtuvo una media cercana a 0 y una desviación estándar de 1. Esto permitió que el PCA se concentrara en la estructura real de los datos, y la varianza total explicada por todos los componentes pasó a ser igual al número de variables, es decir, 4.



Resultados y Dimensionalidad tras la Estandarización




Al aplicar el modelo PCA a los datos estandarizados, los autovalores obtenidos fueron: $\lambda = [1.154, 1.025, 1.007, 0.859]$. Proporción de varianza explicada: CP1: $1.154/4 \approx 28.5\%$, CP2: $1.025/4 \approx 25.3\%$, CP3: $1.007/4 \approx 24.9\%$, CP4: $0.859/4 \approx 21.2\%$. Esta distribución confirma que ningún componente domina fuertemente la explicación de la varianza.

Respecto a la varianza acumulada: Los dos primeros componentes (CP1 y CP2) acumulan más del 50% de la varianza total y los tres primeros componentes alcanzan

casi el 80% de la varianza. Debido a que los primeros dos componentes retienen más del 50% de la información original, una reducción a 2 dimensiones (visualizando solo PC1 vs PC2) es una opción razonable, aunque una representación más fiel podría requerir hasta el tercer componente.

Interpretación de los Componentes Principales y Conclusiones Gráficas: El análisis de los vectores propios reveló cómo se construye cada componente:



CP1: Muestra una alta carga en Edad (+) y Vacaciones_días (-). Se interpreta como una relación inversa entre la edad y las vacaciones.


CP2: Carga alta en Días_trabajados (+) y también en Vacaciones_días (+). Representa una combinación de cantidad de trabajo y descanso.

CP3: Muestra una carga muy alta en Sueldo_anual_USD (+), siendo esencialmente el factor salarial.

CP4: Mucha carga en Edad (+) y en Vacaciones_días (+). Esta distribución explica por qué dos o tres componentes logran retener gran parte de la varianza: CP1 y CP2 combinan Edad, Vacaciones y Días trabajados, mientras que CP3 concentra la información del Sueldo.

El análisis gráfico (Biplot PCA) complementa esta interpretación:


- **Influencia:** Edad y Días_trabajados son las más influyentes en la construcción de PC1 (vectores largos).
- **Correlación Positiva:** Los vectores de Edad y Días_trabajados forman un ángulo pequeño, sugiriendo una alta correlación positiva: a mayor edad, probablemente se trabajen más días.
- **Correlación Negativa:** Los vectores de Vacaciones_días y Días_trabajados están en direcciones casi opuestas, indicando que a más días trabajados, menos vacaciones.
- **Baja Correlación:** El Sueldo_anual_USD forma ángulos cercanos a 90° con Días_trabajados y Vacaciones_días, sugiriendo que el sueldo no está directamente relacionado con la cantidad de días trabajados o de vacaciones.



En conclusión, PC1 captura la dimensión de la Edad y la experiencia laboral (Días_trabajados), mientras que PC2 refleja la dimensión de Vacaciones, mostrando el contraste entre descanso y ganancia. Las variables Edad y Días trabajados resultaron ser las claves para explicar la mayor parte de la varianza en el conjunto de datos estandarizado.

Análisis de conglomerados

El análisis de conglomerados se aplicó a variables (Edad, Sueldo anual en USD, Días trabajados y Días de vacaciones) con el fin de identificar grupos homogéneos de individuos, abordando la estructura de los datos mediante Análisis de Componentes Principales (PCA), agrupamiento jerárquico (Ward) y K-Means.



Metodología: La Necesidad de Estandarización y agrupación jerárquica de Ward:

Antes de la agrupación, se determinó que los datos iniciales se distribuían de forma dispersa sin outliers claros, lo que justificó no eliminar observaciones. Para el agrupamiento, la aplicación del método jerárquico de Ward sin estandarización de variables demostró que variables de mayor escala, como el sueldo anual en USD, ejercían un peso desproporcionado, sesgando la formación de los grupos.


Por lo tanto, se concluyó que la estandarización de los datos (media 0 y varianza 1) era necesaria para asegurar que todas las variables contribuyeran de

manera equilibrada a la estructura de los clústeres.

A partir de la jerarquización con datos estandarizados por la aglomeración de Ward, se observaron hasta la construcción de 10 grupos distintos para poder compararlos con la agrupación posterior de K-means.

Agrupación No Jerárquica con K-means:

En primer lugar, se calcularon los valores del coeficiente de Silhouette para distintas cantidades de clusters (de 2 a 10) con la base de datos estandarizada. Los resultados oscilaron entre 0.16 y 0.22,



lo cual se encuentra por debajo del umbral de 0.25 que indica la existencia de una estructura considerable. Esto sugiere que la separación entre los grupos es débil y que los clusters formados no presentan una estructura clara. En segundo lugar, se aplicó el método del codo, que analiza la inercia de los clusters en función de su número. El gráfico mostró una disminución pronunciada de la inercia hasta aproximadamente tres o cuatro clusters, a partir de los cuales la reducción se hace más gradual. Esto señala que, desde un punto de vista parsimonioso, la solución más adecuada estaría entre tres y cuatro grupos.

Si bien el análisis de codo nos indica una mejor agrupación de 3 o 4 grupos, se decidió trabajar con 9 grupos dado que el coeficiente de silueta era el que más alto daba.

Mediante la matriz de medias, se identificaron grupos altamente favorecidos (como el Clúster 0 y 3), caracterizados por altos sueldos y beneficios.

- El **Clúster 0** representó perfiles productivos con sueldo alto y días trabajados elevados, pero con pocos días de vacaciones.
- El **Clúster 3** agrupó a empleados de alto nivel, con edad por encima de la media, que trabajan muchos días, tienen sueldos altos y también disfrutaban de muchos días de vacaciones.


En contraste, se identificaron segmentos vulnerables (como el Clúster 6 y 8).

- El **Clúster 6** se asoció a una edad inferior a la media, con pocos días trabajados, sueldo bajo y participación laboral baja.
- El **Clúster 8** consistió en perfiles con menor inserción laboral, bajo acceso a beneficios, sueldo muy bajo y muy pocos días trabajados.

El análisis por *box plot* confirmó que los clústeres permitieron segmentar claramente a los individuos en términos de perfiles etarios, intensidad de jornada laboral, nivel de remuneración y beneficios laborales.

En conclusión, aunque los métodos de agrupamiento produjeron resultados similares, los bajos índices de silueta indican y deben interpretarse como perfiles aproximados de individuos en lugar de grupos estrictamente separados.

Comparación entre Ward y K-means



Matriz de confusión:

La matriz evidencia que existe una correspondencia clara entre varios clusters de Jerárquico y KMeans:

-Jerárquico 1 se alinea con KMeans 4.


-Jerárquico 6 con KMeans 0 (coinciden en 6).

-Jerárquico 9 con KMeans 6 (coinciden en 8).

Muestra que, aunque hay diferencias en cómo cada método asigna algunos casos, ambos identifican de manera consistente 9 clusters. Varios grupos coinciden claramente, lo que respalda que la estructura natural de los datos se organiza en nueve clusters óptimos.

Visualización de los clústers:

El siguiente gráfico indica que ambos métodos confirman la presencia de subestructuras en los datos, pero muestran que la separación no es totalmente nítida. La existencia de 9 clústeres se refleja, aunque con diferencias en cómo cada algoritmo asigna los casos.



Índice de Rand Ajustado (ARI)

El valor obtenido fue 0.39, lo cual indica una concordancia moderada entre los clusters generados por el método jerárquico y K-Means.

Este resultado refleja que ambos algoritmos identificaron ciertas similitudes en la agrupación, pero no existe coincidencia completa.

En conclusión, los métodos capturan parte de la misma estructura, aunque con diferencias relevantes.

Índice de Información Mutua Ajustado (AMI)

El valor calculado fue 0.56, considerado un nivel intermedio de acuerdo entre las dos segmentaciones.

Esto significa que hay una cantidad importante de información compartida entre los clusters de ambos métodos.

Sin embargo, la similitud no es total, lo que indica que cada técnica captura patrones distintos en los datos.

Índice de Silueta

El clustering jerárquico alcanzó un valor de 0.22, mientras que K-Means obtuvo 0.21, ambos por debajo del umbral de 0.25.

Esto indica que, independientemente del algoritmo, los grupos formados presentan baja homogeneidad interna y escasa heterogeneidad externa.

Por lo tanto, los clusters son débiles y no reflejan una estructura sustancial en los datos.