


Regresión Lineal Múltiple

Se emplea un modelo de regresión lineal múltiple debido a que permite analizar la relación entre una variable dependiente continua en este caso, **minutes_on_site** y múltiples variables explicativas de tipo cuantitativo y cualitativo. El objetivo es identificar qué factores inciden en el nivel de interacción o permanencia de los clientes en la plataforma digital. Como variables predictoras se consideran indicadores asociados al comportamiento de compra y navegación (**digital_tenure_months**, **share_digital_orders**, **assortment_coverage**, **avg_minutes_per_page**, **unique_pages_visited**, **add_to_cart_count**, **revome_from_cart_count**, **minutes_purchase** y **suggested_purchase**), que reflejan tanto la experiencia digital del cliente como su grado de participación en el canal online. La variable **customer_size**, al ser categórica, se codifica mediante variables dummy, lo que permite incorporar sus distintas categorías al modelo manteniendo la correcta interpretación de los coeficientes estimados.

El conjunto de datos se dividió en tres subconjuntos: entrenamiento (192 observaciones), validación (48 observaciones) y prueba (60 observaciones), con el fin de garantizar una evaluación objetiva del desempeño del modelo. Se entrenó un modelo de regresión lineal múltiple empleando el conjunto de entrenamiento, estimando los coeficientes que minimizan la diferencia entre los valores observados y los predichos de la variable **minutes_on_site**. Posteriormente, el modelo se aplicó al conjunto de prueba para generar predicciones y evaluar su capacidad de generalización. El desempeño se midió mediante el **Error Cuadrático Medio (MSE)**, cuyo valor fue de 2257.52, lo que refleja la magnitud promedio del error de predicción y permite cuantificar el margen de mejora potencial frente a especificaciones más complejas.

Gráfico 1: Residuos del Modelo de Regresión Lineal Múltiple



En el gráfico 1 se observan los residuos en el eje vertical y las predicciones del modelo en el eje horizontal. La línea roja punteada representa el eje de referencia donde los residuos deberían concentrarse alrededor de cero, mientras que la línea azul suavizada (LOESS) muestra la tendencia general de los errores. Idealmente, los puntos deberían distribuirse de forma aleatoria alrededor del eje horizontal sin seguir ningún patrón definido, lo cual indicaría que el modelo explica correctamente la relación entre las variables y que los errores son aleatorios.

Sin embargo, en este caso se puede notar que los residuos presentan cierta dispersión creciente a medida que aumentan las predicciones, lo que sugiere la posible presencia de **heterocedasticidad** (variabilidad no constante de los errores).

Además, se observan algunos valores atípicos alejados del resto, que podrían estar afectando la calidad del ajuste. En síntesis, aunque el modelo logra capturar una tendencia general, el patrón observado en los residuos indica que podría haber limitaciones en

la capacidad del modelo lineal para representar completamente la relación entre las variables, lo que justificaría explorar otros modelos.

Finalmente, se evaluó el **desempeño del modelo de regresión** sobre el conjunto de prueba, es decir, sobre datos que no fueron utilizados durante el entrenamiento. Primero, el modelo generó las predicciones y, dado que la variable dependiente no admite valores negativos, se ajustaron manualmente estimaciones menores a cero, reemplazándolas por cero para mantener coherencia con el fenómeno estudiado (que son minutos). Posteriormente, se calcularon distintas métricas de error que permiten cuantificar la precisión del modelo y comparar su capacidad predictiva.

En cuanto a los resultados obtenidos, el **MAE (Mean Absolute Error)** fue de aproximadamente **28.26**, lo que indica que, en promedio, las predicciones del modelo difieren de los valores reales en unas 28 unidades. Este valor relativamente moderado sugiere un nivel de error aceptable en términos absolutos. El **MSE (Mean Squared Error)**, de **2257.53**, muestra que existen errores individuales de mayor magnitud, dado que esta métrica penaliza fuertemente los desvíos grandes. El **RMSE (Root Mean Squared Error)**, calculado en **47.51**, reafirma esta idea: en promedio, los errores se ubican alrededor de 47 unidades respecto a los valores observados, lo que implica cierta dispersión en las predicciones. Finalmente, el **RMSLE (Root Mean Squared Logarithmic Error)** fue de **1.27**, lo cual sugiere que, en términos relativos, el modelo tiende a tener una buena capacidad para predecir correctamente los valores de menor magnitud, pero presenta mayores desvíos cuando los valores reales son más grandes. En conjunto, las métricas reflejan un rendimiento razonable, aunque con margen de mejora, especialmente si se busca reducir los errores más extremos mediante un modelo más complejo.

Regresión Polinómica:


Con el fin de evaluar si la relación entre el tiempo total en el sitio y las variables explicativas presenta una forma no lineal, se ajustaron distintos modelos de regresión polinómica. Este tipo de modelo permite incorporar términos de mayor orden que capturan curvaturas en la relación entre las variables. Para este análisis se trabajó inicialmente con modelos univariados, considerando las variables con mayor relación potencial con `minutes_on_site`: **`share_digital_orders`**, **`minutes_purchase`**, **`add_to_cart_count`** y **`avg_minutes_per_page`**. Posteriormente, se estimaron modelos combinados con múltiples predictores y diferentes grados polinómicos, evaluando el desempeño mediante el **Error Cuadrático Medio (MSE)** en los conjuntos de validación y prueba.

En primer lugar, el modelo que consideró la variable **`share_digital_orders`**, con un grado óptimo de 3, el modelo elaborado obtuvo un error cuadrático medio de **19.454,23**. Si bien este resultado mostró cierta capacidad explicativa, el error fue significativamente superior al del modelo lineal múltiple, lo que indica que la relación entre la participación digital de compras y el tiempo de permanencia no se beneficia de la inclusión de términos polinómicos.

Para la variable **`minutes_purchase`**, el modelo polinómico de grado 18 alcanzó un error cuadrático medio de **19.117,50**. A pesar de capturar posibles curvaturas en la relación, el aumento del grado no mejoró sustancialmente el ajuste, y el error permaneció elevado. Esto sugiere que el tiempo total de compra no sigue una relación polinómica estable con la variable dependiente.

En el caso de la variable **`add_to_cart_count`**, el modelo obtuvo un error cuadrático medio de **18.946,26**, presentando un patrón similar a los anteriores: ligeras mejoras al aumentar el grado polinómico, pero sin una reducción significativa del error. La variable muestra cierta relación positiva con el tiempo en el sitio, aunque el patrón no parece justificar un modelo de orden superior.

Grafico 2: Comparación de Modelos según Error Cuadrático Medio



El modelo basado en la variable **`avg_minutes_per_page`**, con un grado óptimo de 2, presentó el mejor desempeño entre los modelos polinómicos univariados, con un error cuadrático medio de **3.945,40**. Esto indica una relación cuadrática moderada entre el tiempo promedio por página y el tiempo total en el sitio.

Finalmente, se estimaron modelos polinómicos combinando varias variables, primero con cuatro de ellas (**`share_digital_orders`**, **`avg_minutes_per_page`**, **`add_to_cart_count`**, **`minutes_purchase`**) y luego con la totalidad de las variables explicativas. Los errores cuadráticos medios obtenidos en cada caso fueron de **6311,05** y de **10511,44**.

El **grafico 2**, muestra la **comparación entre los errores cuadráticos medios** de los distintos modelos. En él se observa que el modelo de **regresión lineal múltiple** supera ampliamente a las versiones polinómicas. Esta evidencia sugiere que las relaciones entre las variables explicativas y el tiempo en el sitio son esencialmente lineales, sin una estructura funcional que justifique la incorporación de términos no lineales de mayor orden. Por consiguiente, el modelo lineal múltiple no solo ofrece el mejor desempeño en términos de precisión, sino que además presenta una estructura más parsimoniosa y estable, constituyendo la especificación más adecuada para explicar el comportamiento observado en la plataforma digital.

Clasificación:

El objetivo de este análisis fue examinar la distribución de la variable categórica **`suggested_purchase`**, que representa si un producto fue o no sugerido para compra. Para ello, se elaboró una tabla de frecuencias absolutas y relativas, y posteriormente se representaron los resultados mediante un gráfico

circular (pie chart). En la tabla de frecuencias, se observa que el 90% (aparece 270 veces) de los registros corresponden a casos en los que no se sugiere la compra (0), mientras que solo el 10% (aparece 30 veces) representan sugerencias positivas (1).

El gráfico circular refuerza visualmente esta desproporción: la gran mayoría de los datos (en rojo) pertenecen a la categoría 0, y una pequeña porción (en verde) corresponde a la categoría 1. La variable `suggested_purchase` presenta un fuerte desequilibrio de clases, con predominio de la categoría “no sugerido”. Este desbalance puede tener implicancias en el rendimiento de modelos predictivos posteriores, ya que la clase minoritaria (1) podría requerir técnicas de balanceo para evitar sesgos en el aprendizaje.

Modelo Logit: El objetivo de este análisis fue construir un modelo Logit (regresión logística) para estimar la probabilidad de que una compra haya sido realizada a partir de recomendaciones. Se partió de la variable dependiente `suggested_purchase` (0=no recomendado, 1=recomendado) y de un conjunto de posibles predictores relacionados con la interacción del usuario en la plataforma:

`share_digital_orders`: participación digital de las compras.
`minutes_on_site`: minutos totales en la página.
`avg_minutes_per_page`: tiempo promedio por página.
`add_to_cart_count`: cantidad de productos agregados al carrito.
`minutes_purchase`: minutos de duración de la compra.

Modelo 1 (sin filtrar variables): Del resumen estadístico se observó que únicamente las variables `avg_minutes_per_page` ($p=0.013$) y `add_to_cart_count` ($p=0.001$) resultaron estadísticamente significativas ($p < 0.05$). El resto de las variables presentaron valores p elevados, indicando una baja contribución al modelo.

Modelo 2 (ajustado): Se construyó un segundo modelo considerando únicamente las variables significativas. La ecuación resultante fue:

$$\text{suggested_purchase} = -0.73 + 0.048 \times \text{avg_minutes_per_page} - 0.192 \times \text{add_to_cart_count}$$

Interpretación de coeficientes:

`avg_minutes_per_page`: coeficiente positivo (0.0486), lo que implica que a mayor tiempo promedio por página, mayor probabilidad de que la compra haya sido recomendada.

`add_to_cart_count`: coeficiente negativo (-0.192), indicando que a medida que se agregan más productos al carrito, disminuye la probabilidad de que la compra haya sido producto de una recomendación.

Odds Ratios: Al calcular los odds ratios ($\exp(\text{coef})$):

`avg_minutes_per_page` = 1.049, lo que indica que cada minuto adicional promedio por página incrementa en 4.9% la probabilidad de una compra recomendada.
`add_to_cart_count` = 0.825, lo que sugiere que cada producto adicional agregado al carrito reduce en 17.5% la probabilidad de que la compra sea recomendada.
 El modelo final es estadísticamente significativo y refleja relaciones coherentes con el comportamiento esperado de los usuarios: quienes permanecen más tiempo en cada página tienden a seguir recomendaciones, mientras que los usuarios con un comportamiento más activo (mayor número de productos agregados) suelen realizar compras más autónomas.

Predicciones del modelo logit: En esta etapa, se analizaron las predicciones generadas por el modelo logit ajustado (modelo2), que estima la probabilidad de que una compra haya sido realizada por recomendación. Para ello, se creó una tabla con dos columnas: `compra_recomendada_pred`: valores predichos por el modelo (probabilidades estimadas). `compra_recomendada_obs`: valores observados en los datos originales (0=no recomendada, 1=recomendada).


El dataset contiene un total de 300 observaciones, donde las probabilidades predichas varían entre valores cercanos a 0.001 y 0.34. Al comparar las columnas se observa que los casos donde el valor observado es 1 (compra recomendada) tienden a asociarse con probabilidades predichas más altas,

mientras que la mayoría de los casos con 0 presentan probabilidades bajas, lo que indica una coherencia general del modelo.

El modelo logra identificar tendencias en la probabilidad de compra por recomendación, aunque los valores predichos aún son moderados, sin probabilidades extremas (cercanas a 0 o 1). Esto sugiere que el modelo tiene capacidad de discriminación limitada, posiblemente debido al desbalance de clases observado previamente (solo 10% de compras recomendadas). La comparación entre predicciones y valores reales muestra una buena coherencia direccional del modelo.

Evaluación del modelo predictivo: Para evaluar el desempeño del modelo de predicción de compra recomendada, se analizaron métricas de exactitud (accuracy), así como la matriz de confusión, sensibilidad y especificidad.

Accuracy: El modelo obtiene un 89.67% de precisión, lo que indica que, en promedio, casi 9 de cada 10 predicciones coinciden con el valor real observado. Este resultado, si bien es elevado, no es suficiente por sí solo para considerar que el modelo es realmente bueno, ya que puede estar influenciado por un desbalance de clases (es decir, muchos más casos de “no compra” que de “compra”).




Matriz de confusión: Verdaderos Negativos (VN): 269; El modelo predijo correctamente que no comprarían, falsos Positivos (FP): 1; Predijo compra cuando en realidad no ocurrió, falsos Negativos (FN): 30; El modelo no identificó compras reales y verdaderos Positivos (VP): 0; No acertó ningún caso de compra real. Esto indica que el modelo acierta casi siempre cuando el cliente no compra, pero no detecta correctamente a los clientes que sí compran.

Sensibilidad y especificidad: A partir de la matriz de confusión, se calcularon los siguientes indicadores:

Sensibilidad = 0%: el modelo no detecta los casos positivos (compra).

Especificidad ≈ 99.6%: clasifica muy bien los casos negativos (no compra). El modelo tiene alta precisión global, pero no es útil para identificar compradores reales.

Curva ROC: En el gráfico se observa: La línea azul representa el desempeño del modelo y la línea roja punteada es la línea de referencia (clasificador aleatorio con AUC = 0.5). Resultado del AUC=0.80. Esto significa que el modelo tiene una capacidad de discriminación “buena” entre clientes que realizan una compra recomendada y los que no.




El umbral utilizado inicialmente (0.5) genera una sensibilidad nula (el modelo no detecta compradores). Sin embargo, el AUC = 0.80 indica que el modelo sí contiene información útil para separar compradores de no compradores, pero el umbral actual no es el adecuado.

Entrenamiento con división Train/Test: Para evaluar de forma más robusta el modelo de regresión logística, se dividió la base de datos en: 80% entrenamiento (X_{train} , y_{train}) y 20% test (X_{test} , y_{test}).

Se utilizó `stratify=y` para mantener la proporción de clases: Clase 0: 270 casos y clase 1: 30 casos. Esto confirma nuevamente que el dataset está

desbalanceado (90% vs 10%). Tras entrenar el modelo con `LogisticRegression()` y predecir sobre el conjunto de test:


Matriz de confusión: Accuracy (test): 0.9167 (91.67%), 54 verdaderos negativos, 1 verdadero positivo, 5 falsos negativos (clientes que compraron pero no fueron detectados) y 0 falsos positivos. El modelo sigue mostrando una alta precisión para la clase 0 (no compra), pero detecta solo 1 de 6 compras reales (sensibilidad aún baja).



Para mejorar el accuracy se aplicó: Pipeline + StandardScaler (escalado de variables) y GridSearchCV probando: Diferentes valores de regularización ($C = 0.01$ a 1), diferentes algoritmos de optimización (liblinear, newton-cg, lbfgs, sag, saga) y validación cruzada con $cv=5$. Mejor combinación encontrada: $C = 0.01$, solver = 'newton-cg', dando un Best Score (cross-validation)=0.9.


El modelo identifica correctamente a casi todos los clientes que no realizan la compra (clase "no"), con un recall del 100%. Sin embargo, solo detecta correctamente el 17% de los clientes que sí compran, lo que refleja una baja sensibilidad en la clase minoritaria ("sí"). Esto indica que el modelo está sesgado hacia la clase mayoritaria, lo cual es esperable dado el desequilibrio de los datos (90% "no" vs. 10% "sí").

Curva ROC: El área bajo la curva (AUC = 0.66) sugiere una capacidad de discriminación moderada del modelo, es decir, distingue con cierto nivel de éxito entre clientes que compran y los que no, aunque hay margen de mejora.




El modelo optimizado mejora la estabilidad, pero sigue teniendo baja sensibilidad para detectar compras reales. El accuracy es alto debido al desbalance de clases (mayoría clase 0).

Modelo con Balanceo de Clases:



Matriz de confusión: Verdaderos negativos: 40, verdaderos positivos: 4, falsos negativos: 2 y falsos positivos: 14. Accuracy: 73.3%



Curva ROC: AUC = 0.68; Ligera mejora en la capacidad de discriminación general. El ajuste de pesos permitió mejorar significativamente la detección de clientes que sí compran (recall de 0.67 frente a 0.17 en el modelo base). Aunque la exactitud global disminuyó (de 91% a 73%), el modelo ahora logra un equilibrio más realista entre las dos clases, reduciendo el sesgo hacia la clase "no compra".